大数据应用

BIG DATA





大数据应用

CONTENTS

01 推荐系统
Recommender system

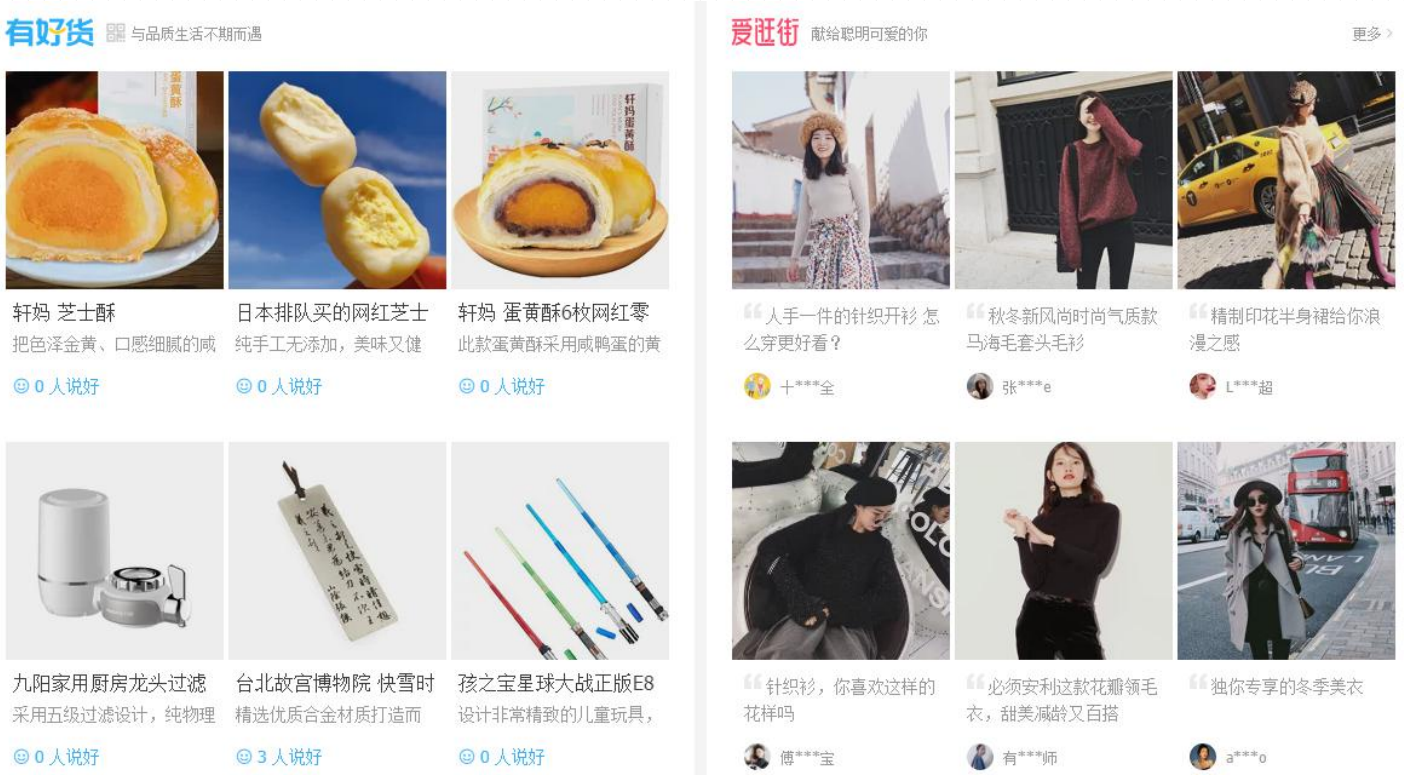
02 地震大数据
Seismic bigdata

03 交通大数据
Traffic bigdata

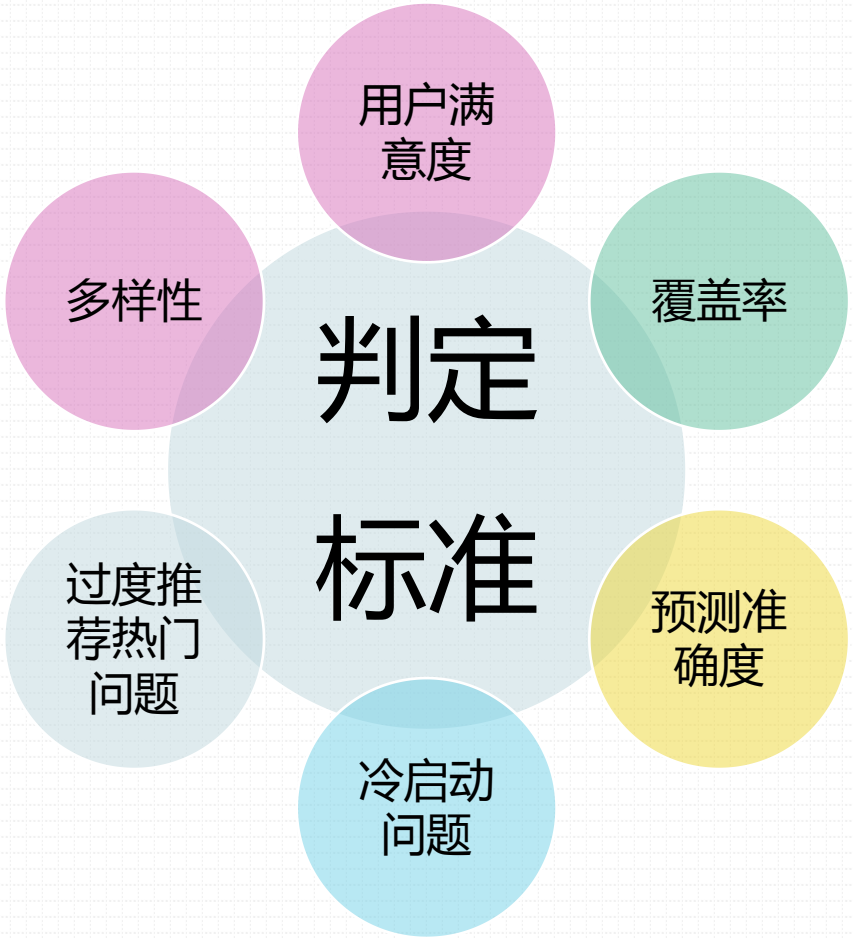
04 环境大数据
Environmental bigdata

1.1 推荐系统概述

- **个性化推荐**在我们的生活中无处不在。早餐买了几根油条，老板就会顺便问一下需不需要再来一碗豆浆；去买帽子的时候，服务员会推荐围巾。随着互联网的发展，这种线下推荐也逐步被搬到了线上，成为各大网站吸引用户、增加收益的法宝



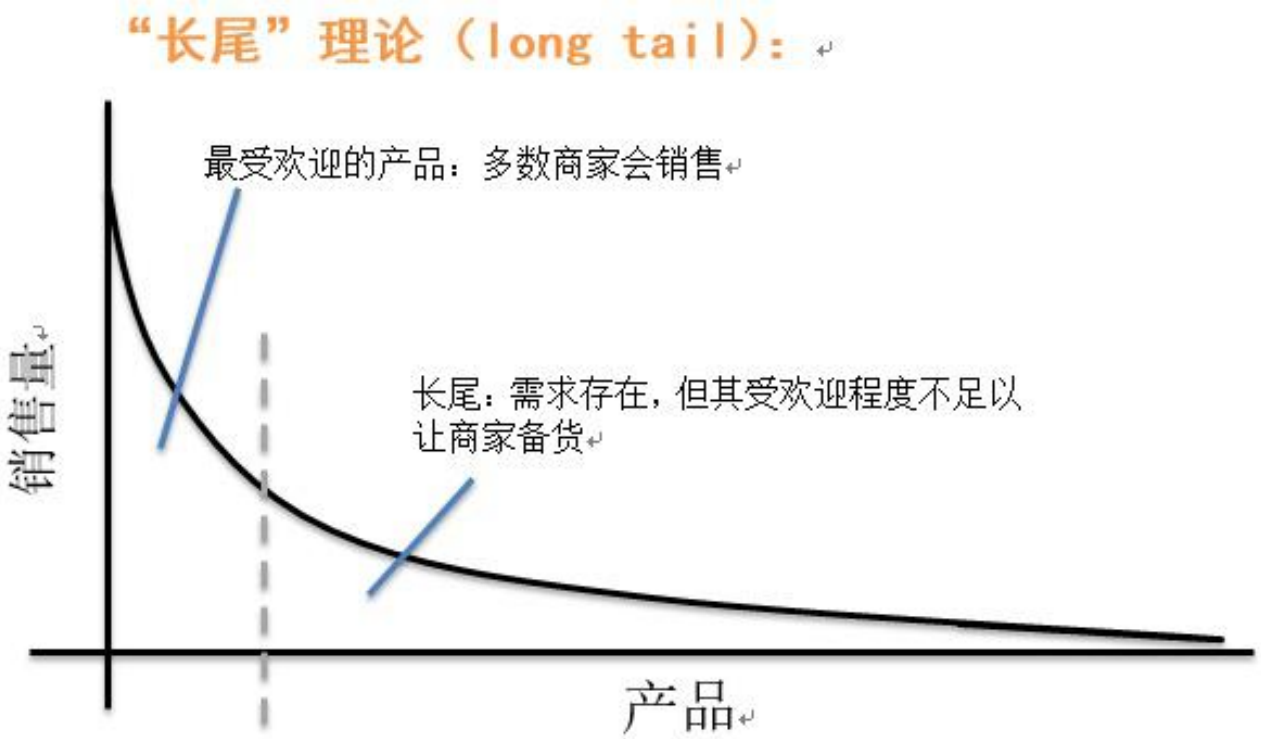
1.1 推荐系统概述



推荐系统判定标准

- **用户满意度**：通过调查问卷的形式，用户对推荐系统的满意度分为不同的层次
- **预测准确度**：最重要的推荐系统离线评测指标
- **覆盖率**：覆盖率的定义是推荐系统能够推荐出来的物品占总物品集合的比例，覆盖率描述了一个推荐系统对物品长尾的发掘能力
- **多样性**：用户的兴趣在较长的时间跨度中是一样的，但具体到用户访问推荐系统某一刻，其兴趣往往是单一的，如果推荐列表只能覆盖用户一个兴趣点，而这个兴趣点不是用户这个时刻的兴趣点，推荐就不会让用户满意
- .....

1.1.1 长尾理论



- “长尾”概念于2004年提出，用来描述以亚马逊为代表的电子商务网站的商业和经济模式
- 电子商务网站销售种类繁多，虽然绝大多数商品都不热门，但不热门的商品总数量极其庞大，所累计的总销售额将是一个可观的数字，也许会超过热门商品所带来的销售额
- 因此，可以通过发掘长尾商品并推荐给感兴趣的用户来提高销售额，这需要通过个性化推荐来实现

1.1.2 推荐方法

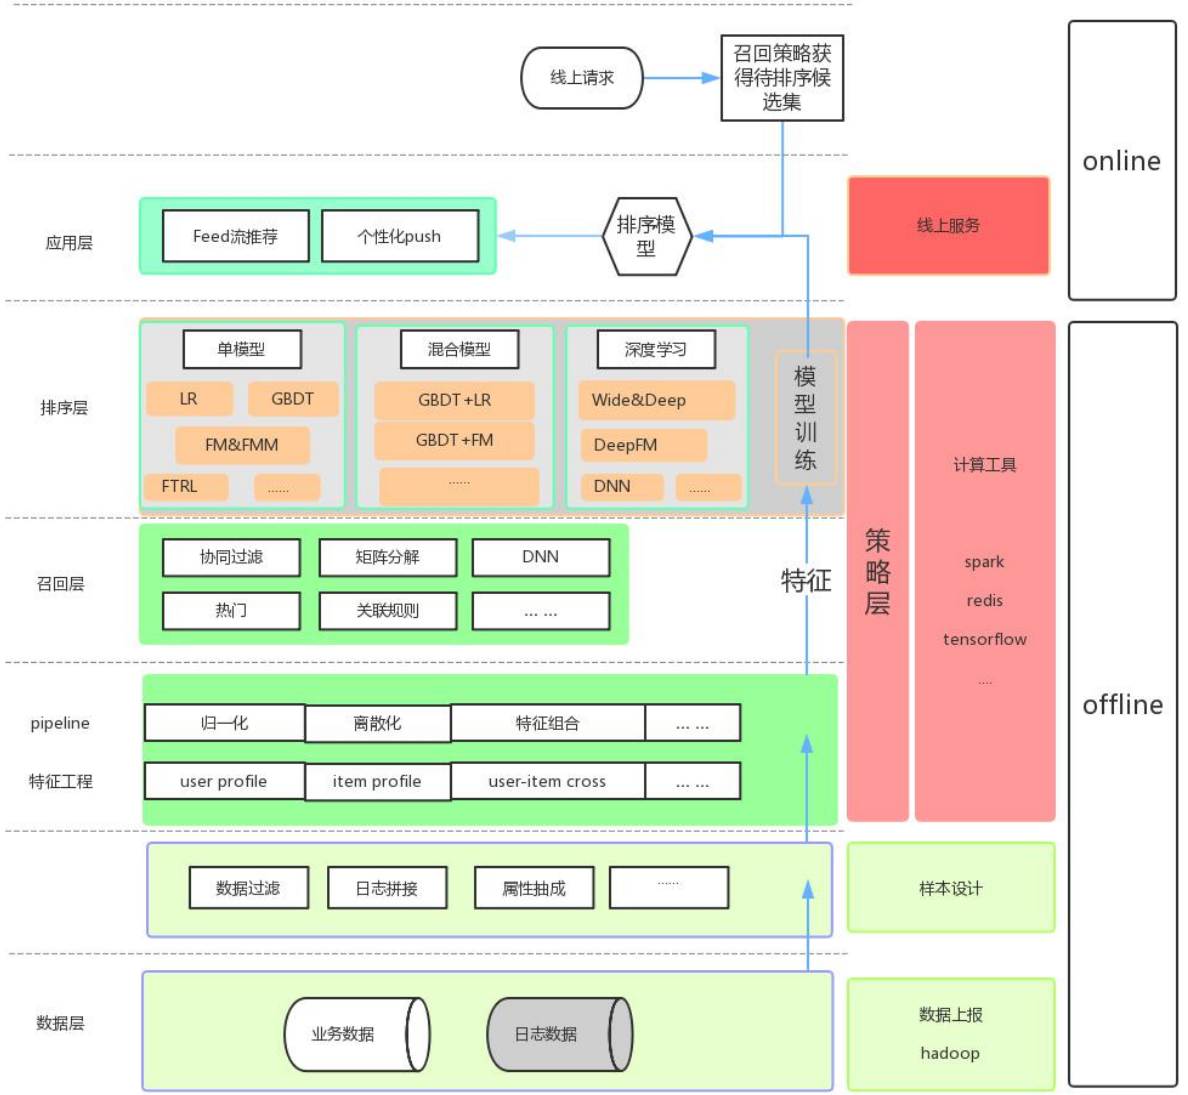
根据推荐算法的不同，推荐方法包括如下几类：

- **专家推荐**：人工推荐，由资深的专业人士来进行物品筛选推荐，需要较多人力成本
- **基于统计的推荐**：基于统计信息的推荐（如热门推荐），易于实现对用户个性化偏好描述能力较弱
- **基于内容的推荐**：通过机器学习的方法去描述内容特征，基于内容特征发现与之相似内容
- **协同过滤推荐**：应用最早和最为成功的推荐方法之一，利用与目标用户相似的用户已有的商品评价信息，来预测目标用户对特定商品的喜好程度

1.1.3 推荐系统模型

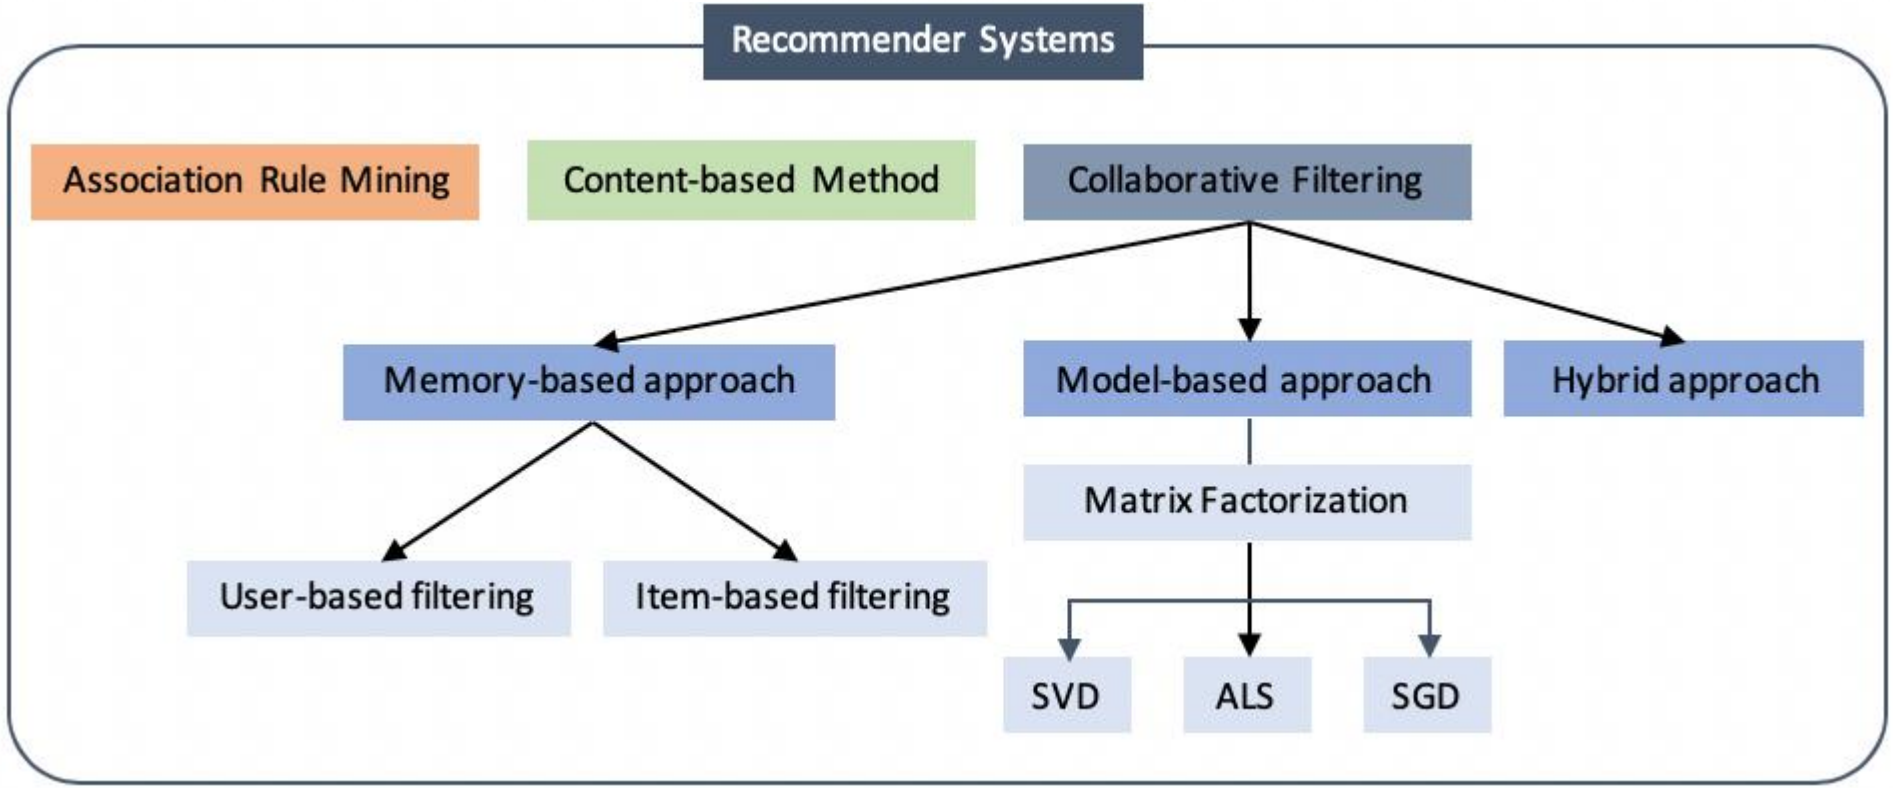
推荐系统组成

- 用户建模模块：对用户进行建模，根据用户行为数据和用户属性数据来分析用户的兴趣和需求
- 推荐对象建模模块：根据对象数据对推荐对象进行建模
- 推荐算法模块：基于用户特征和物品特征，采用推荐算法计算得到用户可能感兴趣的对象，并根据推荐场景对推荐结果进行一定调整，将推荐结果最终展示给用户



1.2 推荐算法

- 推荐技术从被提出到现在已有十余年，可以分为多种：基于规则推荐、基于内容推荐、协调过滤推荐..



- 传统推荐系统上的数据集通常被表示为用户项目矩阵，特别侧重于矩阵完成技术的推荐。基于矩阵完成的推荐的一个关键思想是预测r并为目标用户找出最有希望的项目，如下所示:



- 左图，对于一个用户a，项目2和4未被发现。在这种情况下，推荐者所做的是预测缺失的元素，并决定哪个项目更可能被用户偏好。

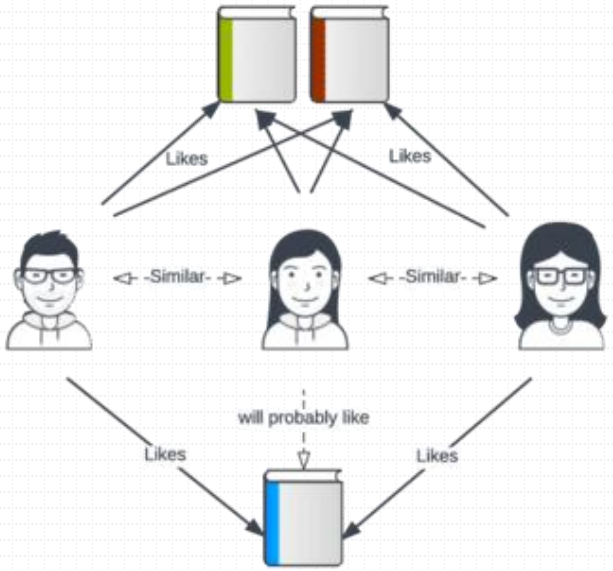
- **协同过滤** 是最流行的基于矩阵完成的推荐器之一，它最初是由Goldberg等人1992年提出。CF算法的目标是通过对用户-用户和项目-项目相似性建模，为特定用户推荐新项目。

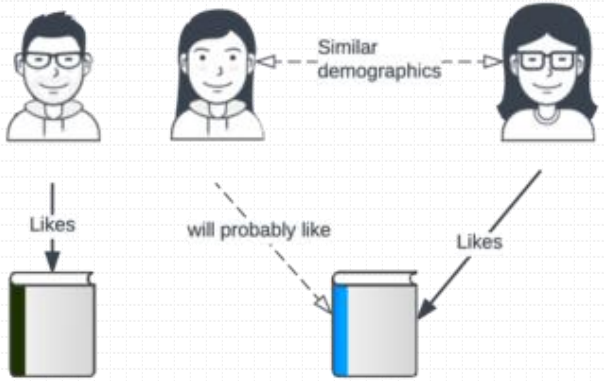
1.2.1 协调过滤推荐算法

- 协同过滤(*Collaborative Filtering*)作为推荐算法中最经典的类型，一般来说，协同过滤推荐分为三种类型。第一种是**基于用户(user-based)的协同过滤**，第二种是**基于项目(item-based)的协同过滤**，第三种是**基于模型(model based)的协同过滤。**



基于用户协同过滤



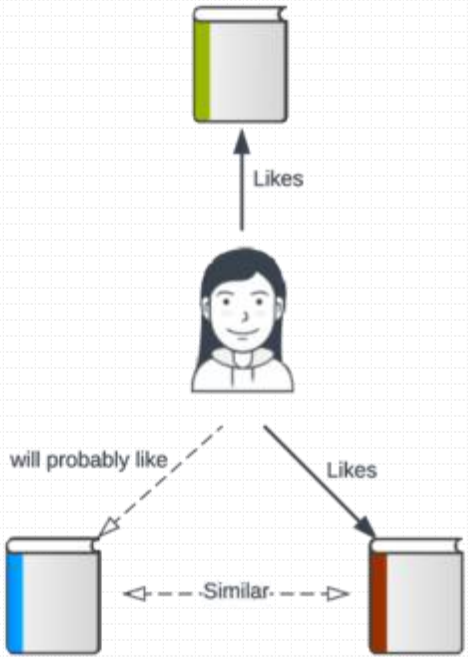


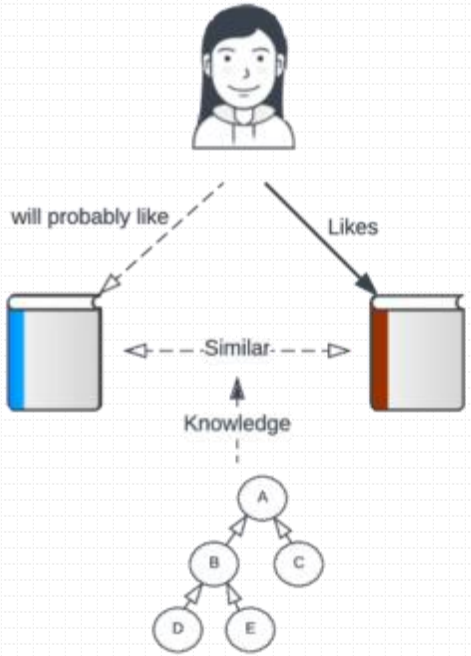
- **基于用户(*user-based*)的协同过滤**：主要考虑的是用户和用户之间的相似度，只要找出相似用户喜欢的物品，并预测目标用户对对应物品的评分，就可以找到评分最高的若干个物品推荐给用户

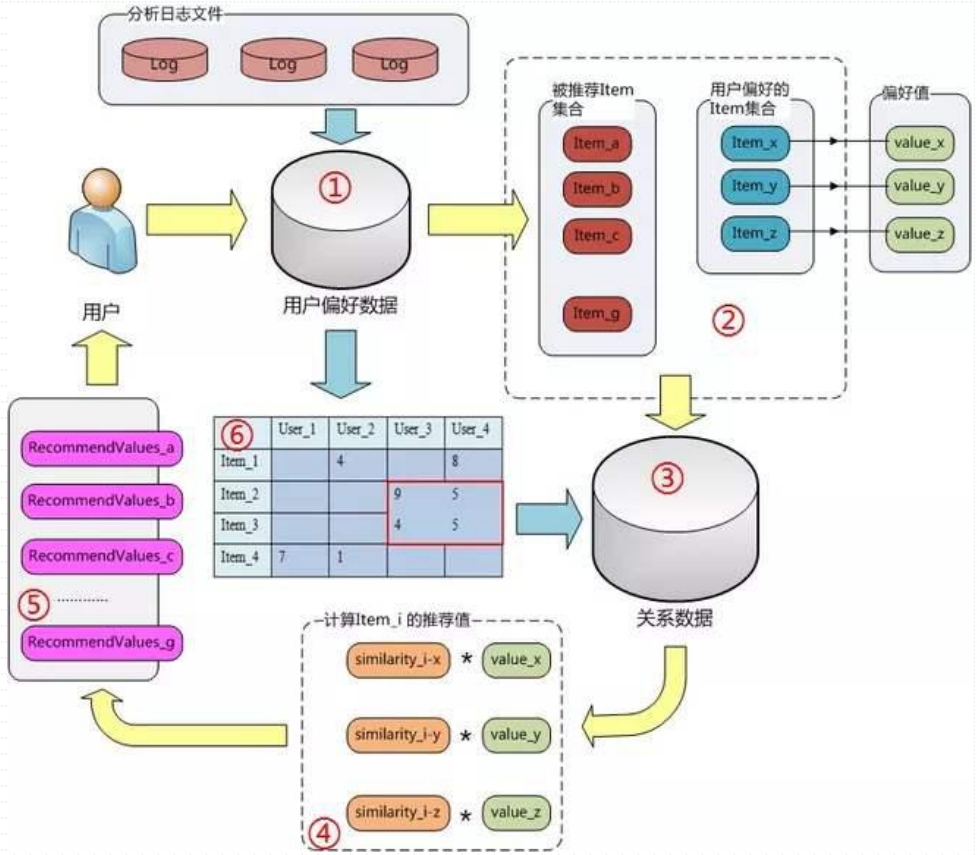
- **而基于项目(*item-based*)的协同过滤**：和基于用户的协同过滤类似，不过我们转向找到物品和物品之间的相似度，只有找到了目标用户对某些物品的评分，那么我们就可以对相似度高的类似物品进行预测，将评分最高的若干个相似物品推荐给用户

基于项目协同过滤

- 如左图，在网上买了一本机器学习相关的书，网站马上会推荐一堆机器学习，大数据相关的书给你，这里就明显用到了基于项目的协同过滤思想







基于模型协同过滤

- 基于模型的协同过滤
  - **目前最主流的协同过滤类型**，其相关算法较多
  - **核心思想**：存在m个物品，m个用户的数据，只有部分用户和部分数据之间是有评分数据的，其它部分评分是空白，此时我们要用已有的部分稀疏数据来预测那些空白的物品和数据之间的评分关系，找到最高评分的物品推荐给用户

- 机器学习方法
  - 关联算法，聚类算法，分类算法，回归算法，矩阵分解，神经网络,图模型以及隐语义模型来解决



大数据应用

CONTENTS

01 推荐系统
Recommender system

02 地震大数据
Seismic bigdata

03 交通大数据
Traffic bigdata

04 环境大数据
Environmental bigdata

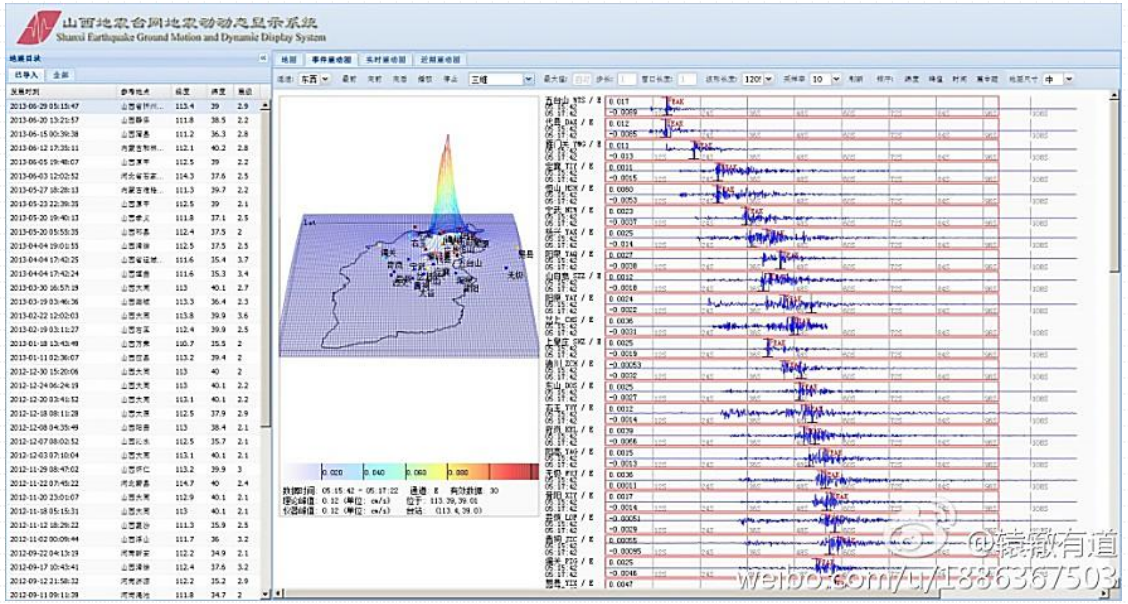
2.1 大数据时代与地震

- 美国地质调查局（USGS）启动了8个新的研究项目，目标是重新评估发生在所有主要板块边界和板块内部环境的地震等级、发生频率和震级分布，以及最大震级，以改进地震预警（测）模型，并使美国的灾害评估建立在更为强大的全球数据及其分析基础之上。
- 高新技术和信息技术的发展，一直推动地震观测技术的进步。
- 在移动互联网和物联网时代，微机电传感器（MEMS）技术和互联网智能技术使地震观测设备也遵循大数据产生的规律，即从精密到简单，从笨重到智能、从昂贵到低廉、从量少到量大。
- 这完全是适应了地震预警和烈度速报应用需求，催生了密集地震观测网，也将地震行业带进了大数据时代。

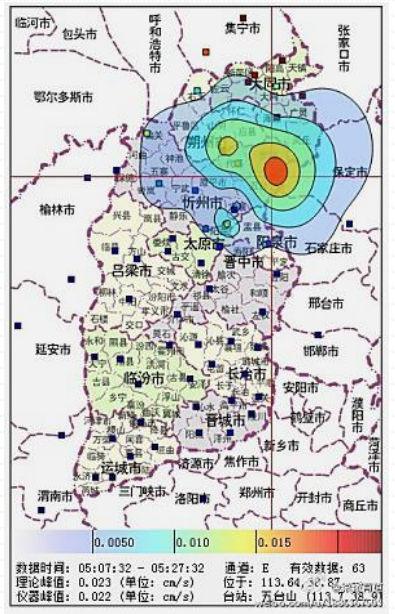
2.1.1 地震烈度速报

- 烈度速报就是在破坏性地震发生时能够快速给出不同地区的烈度分布情况

发生大地震 → 地震烈度速报 → 震动图(ShakeMap)



山西地震台网的观测烈度速报



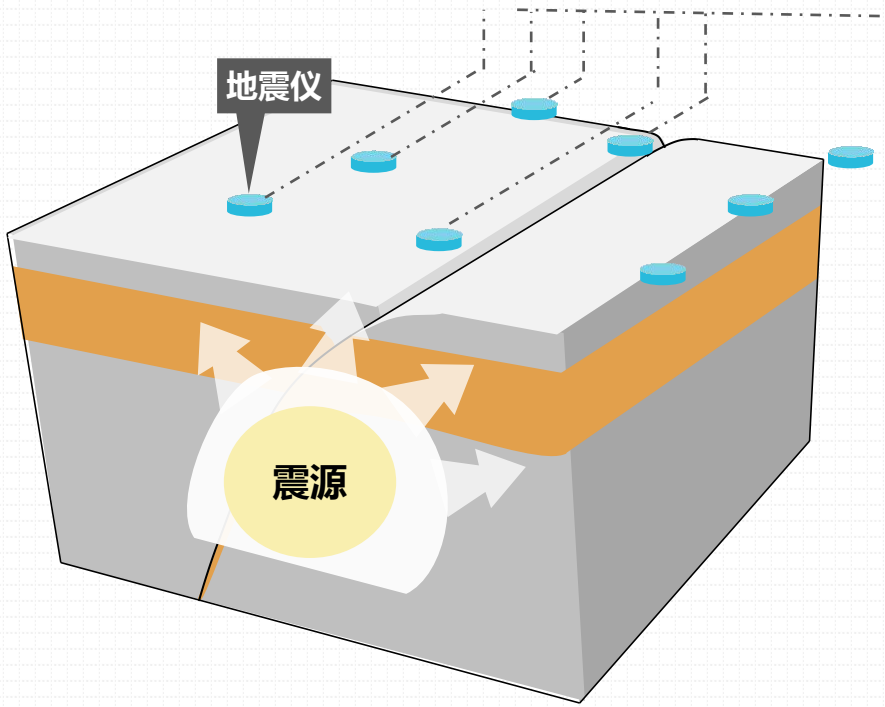
震动图

@我爱有道
weibo.com/u/1886367503

2.1.2 地震预警

汶川大地震/日本3·11地震

Earthquake Early Warning（地震报警或地震警报）



1 地震仪监测并及时处理，传达至震波传达相关部门



2 公共通信发布地震预警信息



3 个人终端、地震报警设备收到地震预警信息

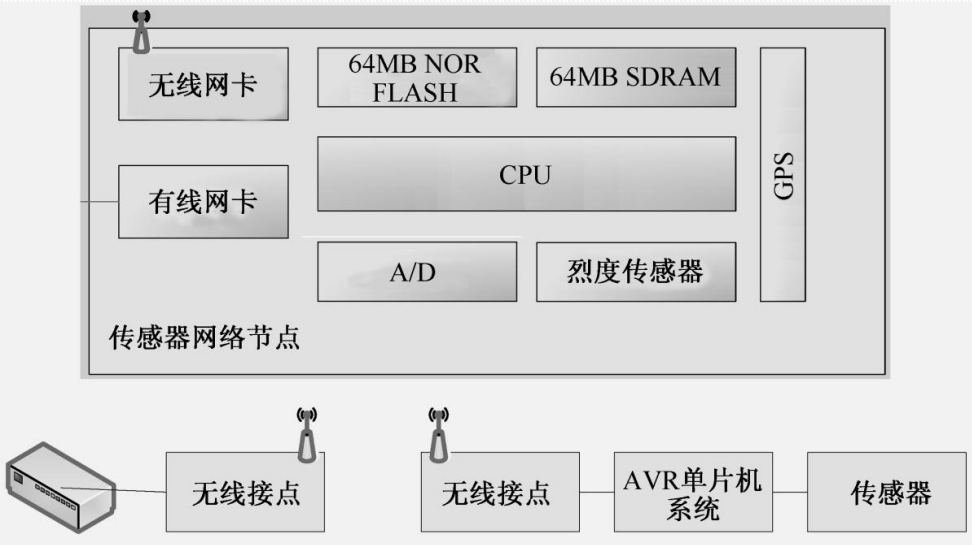


4 用户采取措施居民避难



2.1.3 MEMS传感器烈度计和智能设备

- 中国地震局在发改委的支持下，在下一代互联网地震应用的开发项目中，开发了一系列移动互联网应用技术。
- 特别是以智能手机为基础结合MEMS技术开发了地震烈度计和动态地震烈度网技术，这种技术可以适合大量密集地震观测网的布设。



MEMS烈度计和移动互联网传递地震信号



台湾生产的MEMS地震预警台站设备

2.1.4 密集地震观测网将地震带入大数据时代



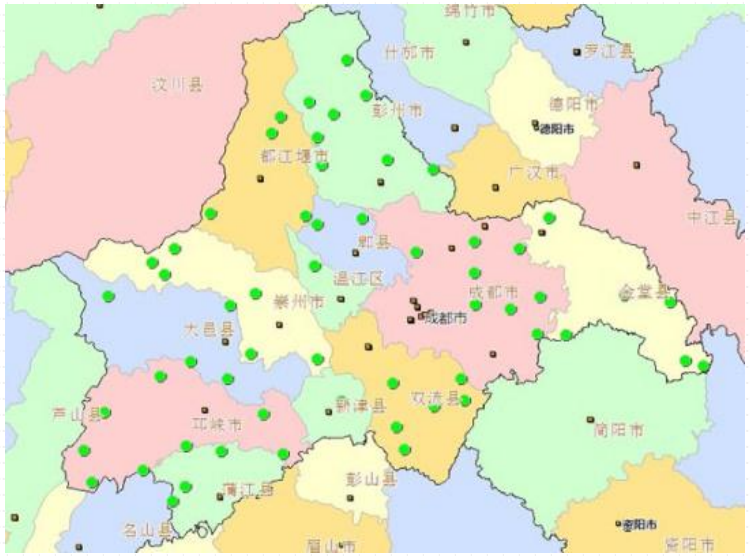
- 如上所述，密集地震观测网完全遵循了大数据产生的规律，从精密的传统地震仪到简单的MEMS烈度计，从昂贵的设备到廉价的MEMS设备，从高精度仪器到智能化的设备，从100～200千米稀疏的量少台站到10千米左右量大的密集地震观测网

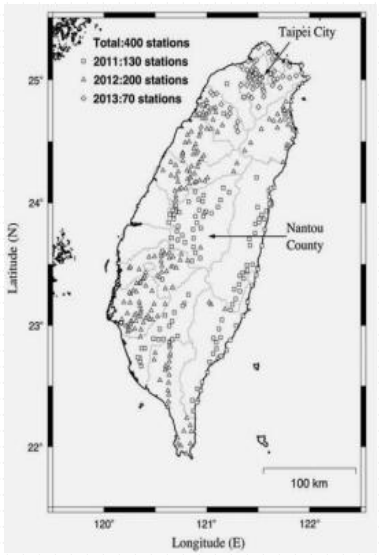
- 地震观测的数据从小数据变成了大数据。所以，**密集地震观测网将会把地震带进大数据时代**

重庆大学 CHONGQING UNIVERSITY

1. 地震大数据一定是巨量数据

成都市和中国台湾密集地震观测网

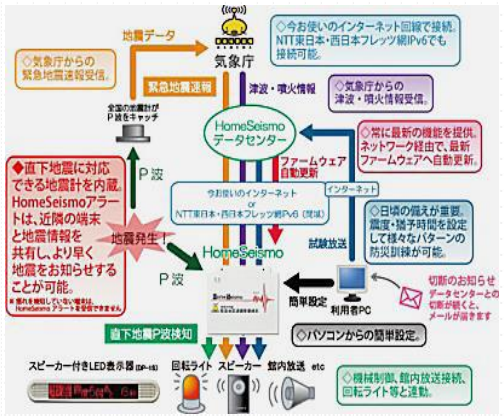




日本家庭地震报警器及工作流程

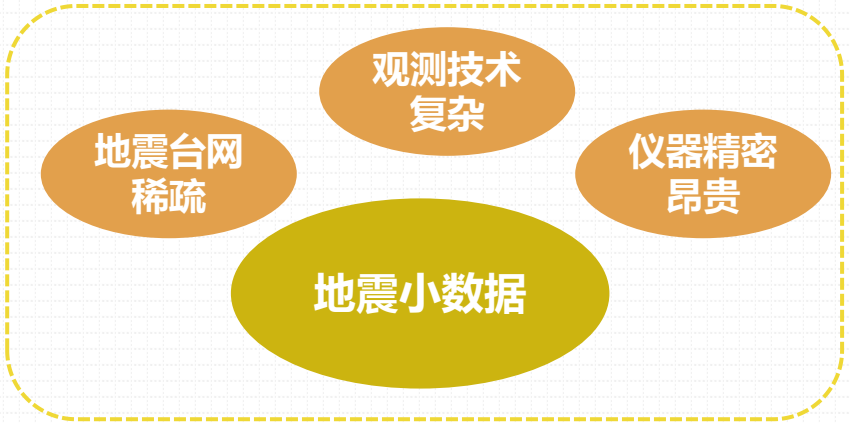




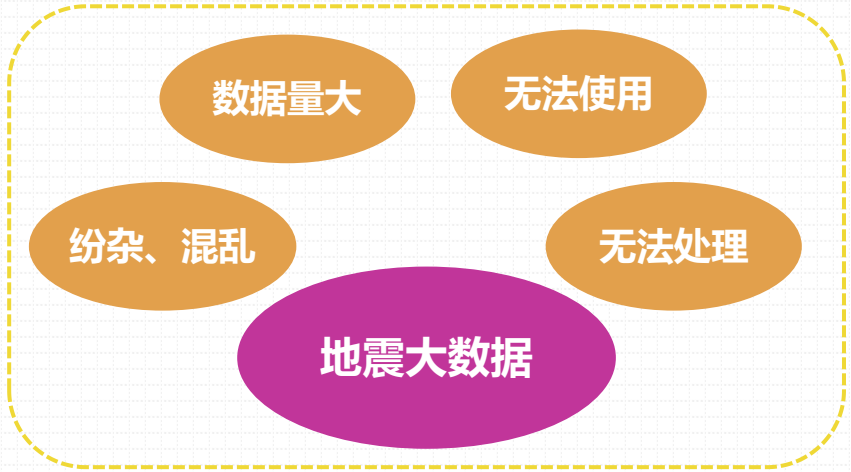


2. 地震大数据找关联

因果关系范式

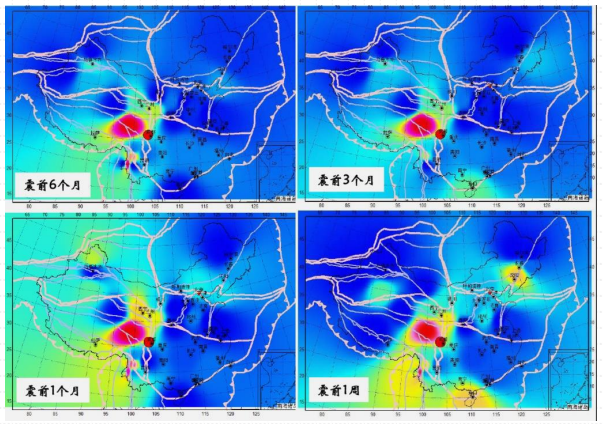


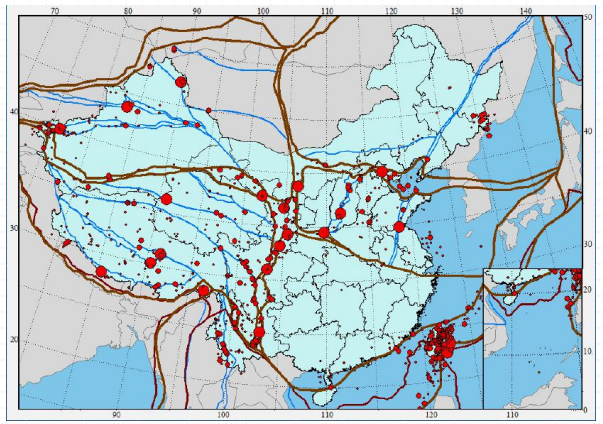
前兆异常度



- 使用大数据关联方法地震前兆异常度的研究表明：地震前兆观测数据是和构造体有关的，它们是相关联的。汶川地震前前兆异常度的变化，和巴颜克拉块体有关联，这和各方面研究成果一致。

$$A_{\mathrm{ZCL}}(\varepsilon,t)=\lim_{\varepsilon\to S}\frac{N_A(\varepsilon,t)}{N(\varepsilon,t)}$$





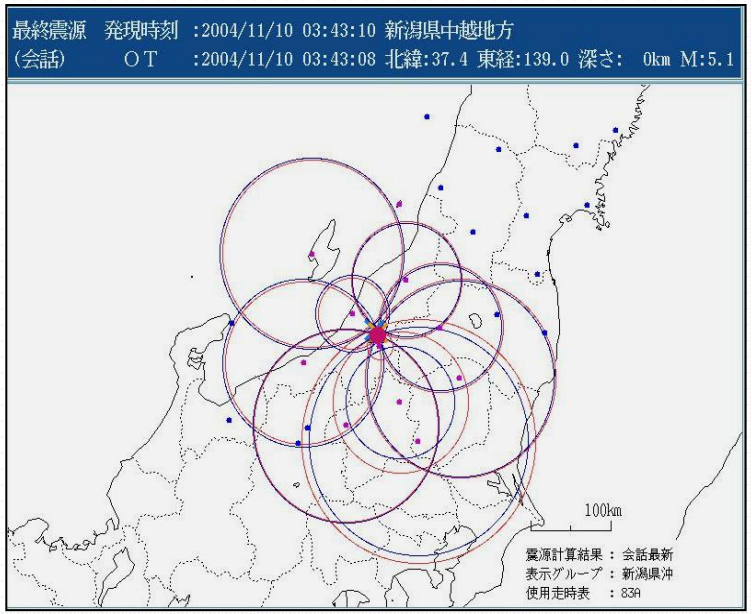
地震前兆异常度

重庆大学 CHONGQING UNIVERSITY

3. 地震处理从复杂到简单-从“复杂算法”到“简单算法”

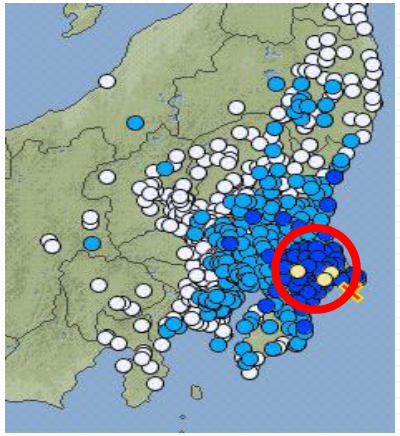
小数据时代

- 小数据时代，在数据的限制无法突破的情形下，数据处理算法的研究越来越深入，发明的算法越来越复杂

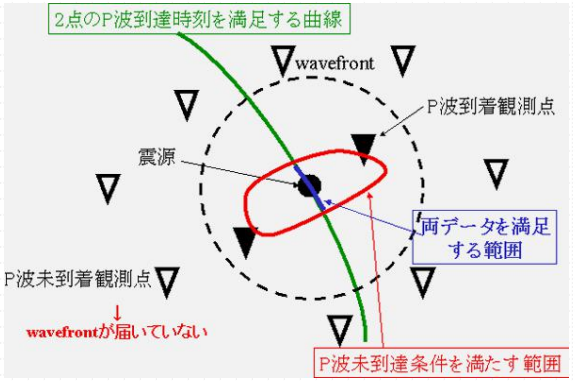


大数据时代

- 当数据量以指数级扩张时，在小数量级的数据中表现很差的简单算法，准确率会大幅提高；大数据的简单算法比小数据复杂算法更有效



极其简单地震参数处理



“着未着法”

4. 地震处理从复杂到简单-从“审慎的决策”到“快速的决策”

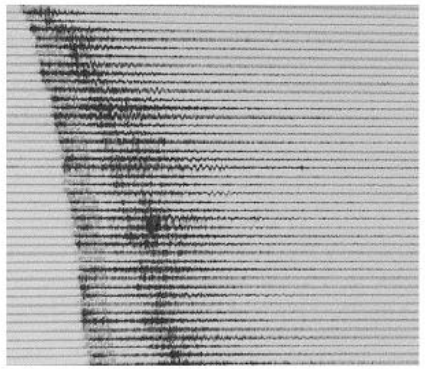
- 传统地震台网处理和决策都非常慎重，通过收集和分析数据来验证这种假设；如果有一些数据有问题，就影响原有假设，决策与行动是审慎的。小数据的地震速报可以较快地进行自动速报，但是处理复杂，要多中心审慎决策，特别是终报更需要审慎决策。原因是小数据依靠模型解算方程，由于空间数据间隔太大，往往初值确定度准确，大量计算可能仍然得不到可高的结果，必然影响快速决策

- 密集地震台网的大数据，不再受限于传统的方式，在密集的大数据中可以简单而准确地得到地震发生在哪里、多大，无须一而再地检查和复核，足以做出快速决定，地震预警的警报可以在数秒发出，地震烈度速报可以在几分钟就发出。快速决策无疑对于大地震的减轻灾害和挽救生命无疑具有重要的意义

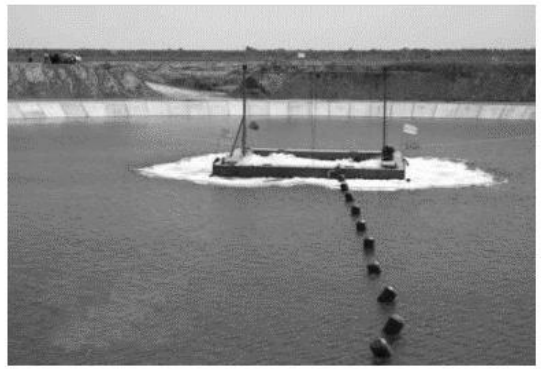
2.2 大数据推进地震新模式和新业态

1．密集地震观测网带来的创新

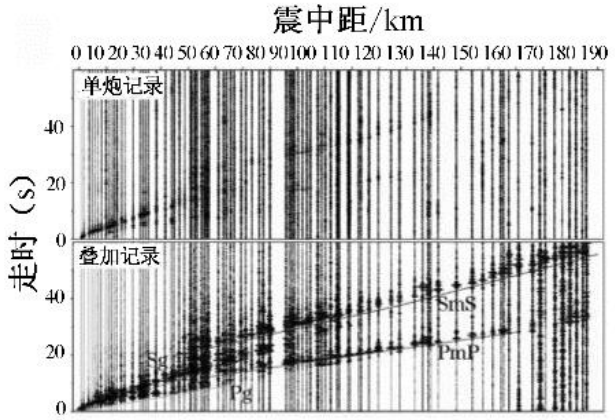
- 传统的精密昂贵的地震台站到密集地震观测网的，从精密的传统地震仪到简单的MEMS烈度计，从高精度设备到智能化的仪器，从量少到量大，这样地震台网完全遵循大数据产生的规律



密集地震台网小震记录



新疆呼图壁可控震源-水枪

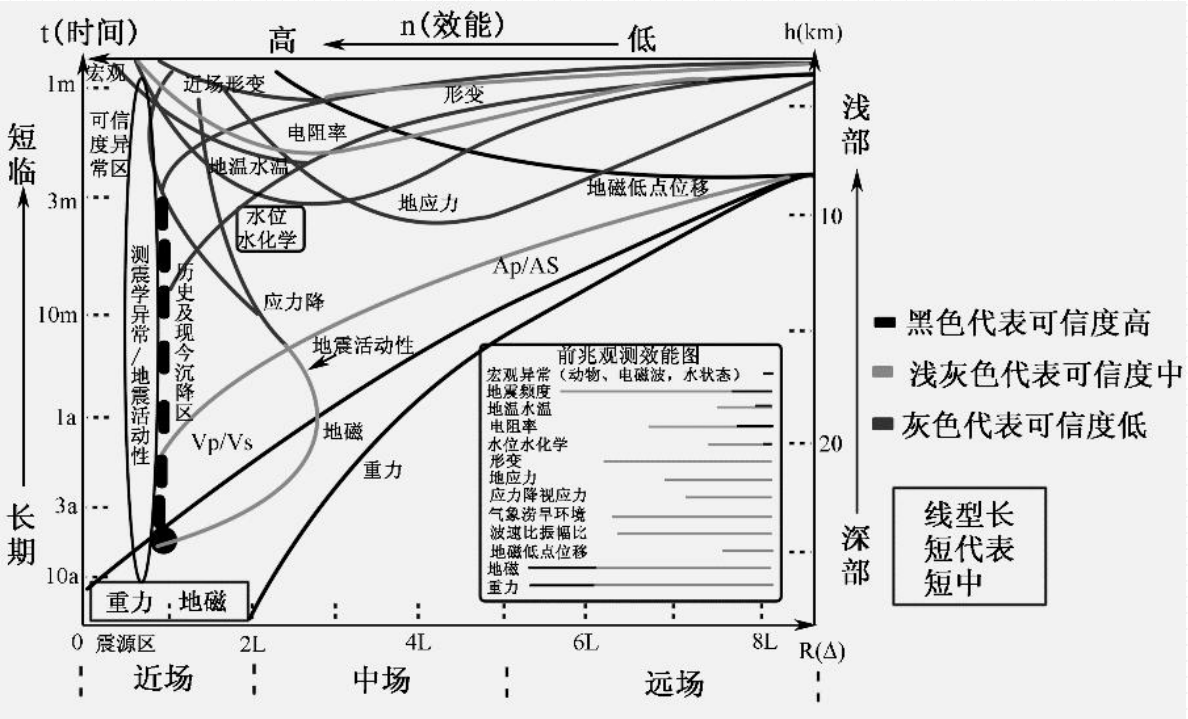


可控震源产生的地震记录

动态监视地下活动

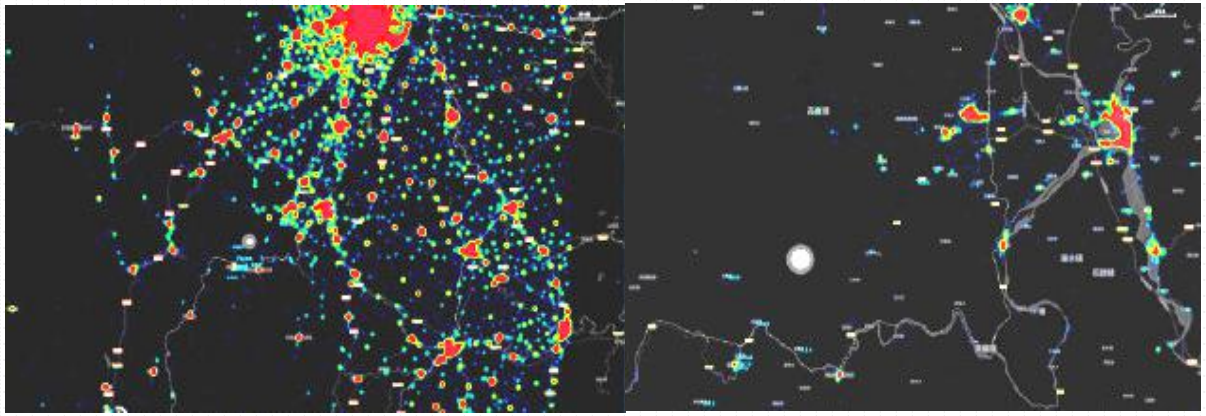
2．大数据为探寻地震前兆开辟新途径

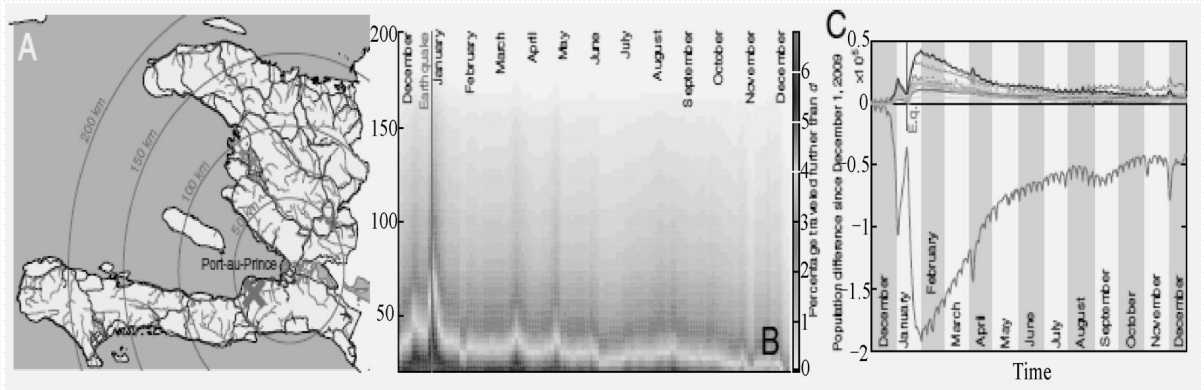
- 现代高新技术和互联网发展迅猛，各种新型传感器和信息技术，可以为地震前兆提供廉价的设备，为加密观测提供了条件，将推进地震科学的创新



地震前兆效能图

3．大数据支撑地震应急救援





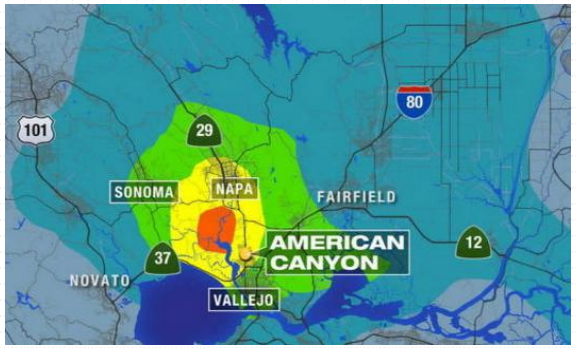


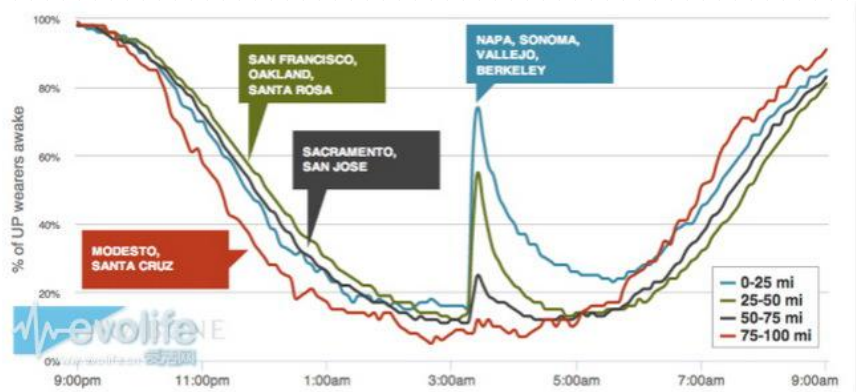
重庆大学 CHONGQING UNIVERSITY

4．物联网大数据的地震应用









手环地震惊醒记录曲线



大数据应用

CONTENTS

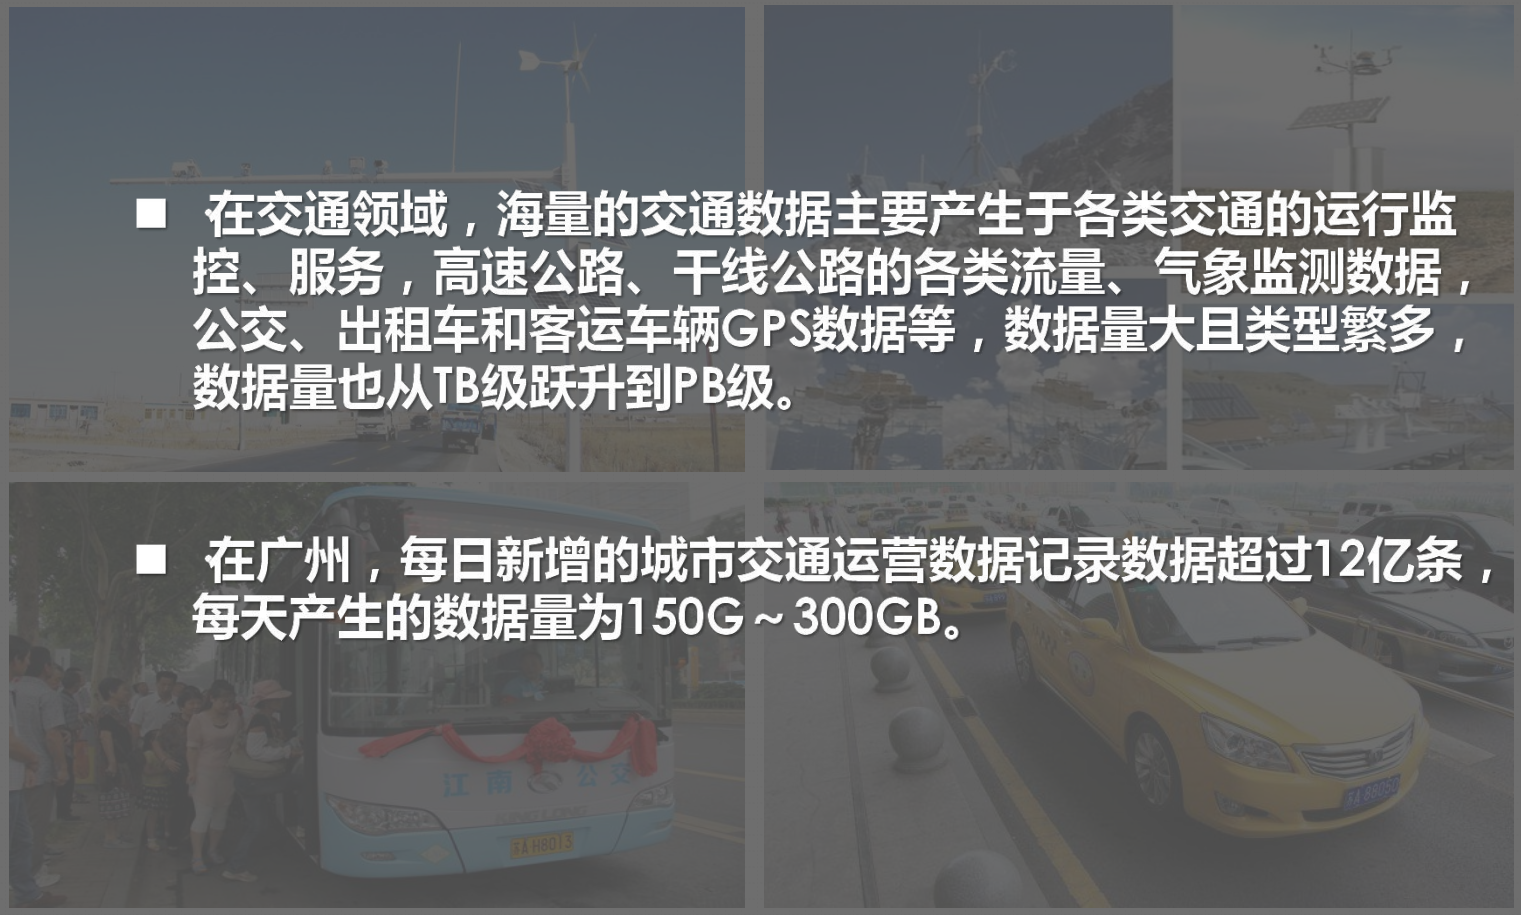
01 推荐系统
Recommender system

02 地震大数据
Seismic bigdata

03 交通大数据
Traffic bigdata

04 环境大数据
Environmental bigdata

3.1 智慧交通与大数据



- 在交通领域，海量的交通数据主要产生于各类交通的运行监控、服务，高速公路、干线公路的各类流量、气象监测数据，公交、出租车和客运车辆GPS数据等，数据量大且类型繁多，数据量也从TB级跃升到PB级。

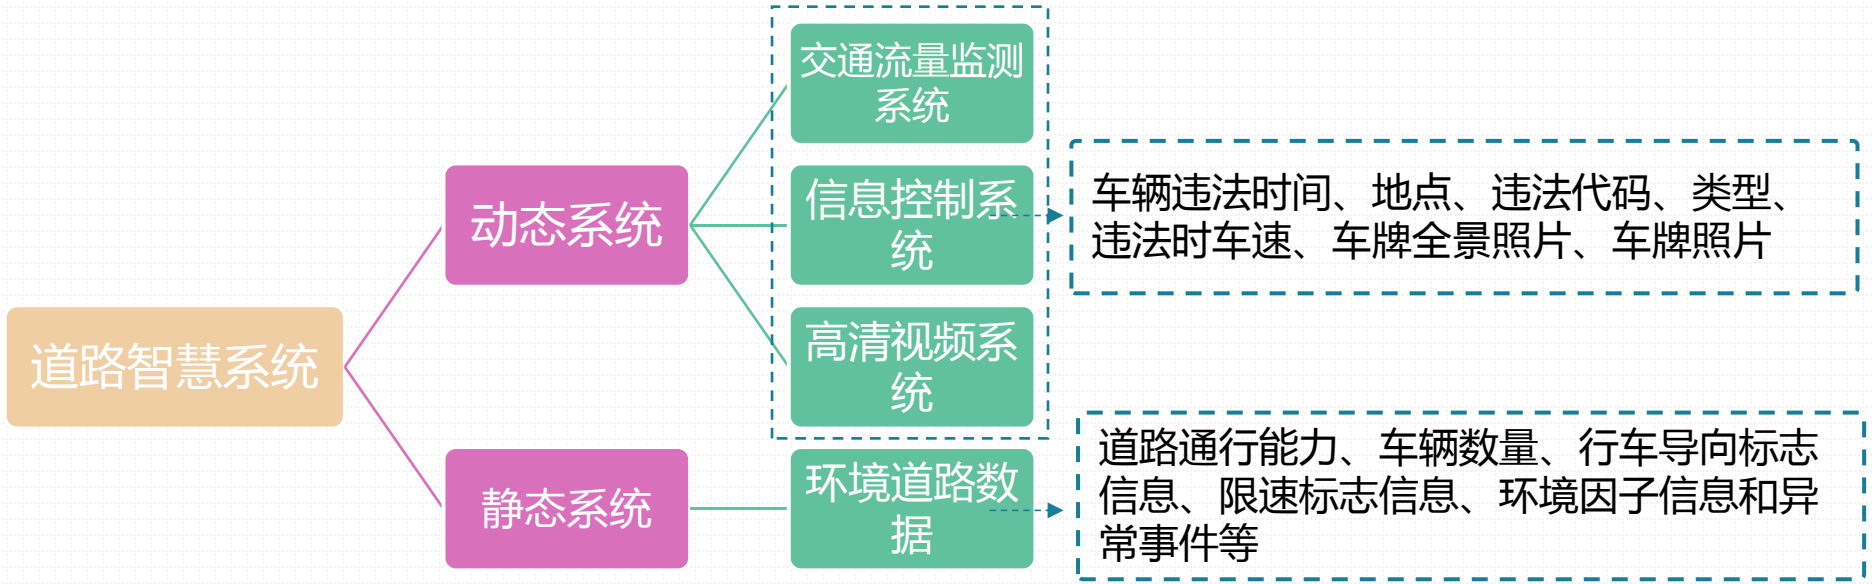
- 在广州，每日新增的城市交通运营数据记录数据超过12亿条，每天产生的数据量为150G～300GB。

3.2 交通大数据的意义

- 大数据提供环境监测方式同时大数据拥有信息集成优势和信息组合效率
- 大数据的智能性可以合理配置公共交通资源、提高交通安全水平



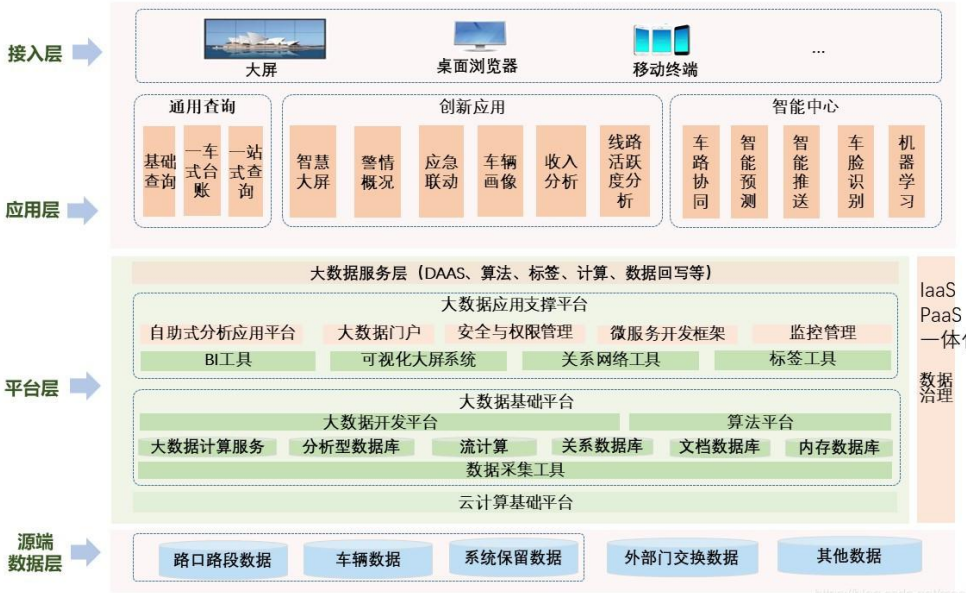
3.3 交通大数据数据挖掘技术



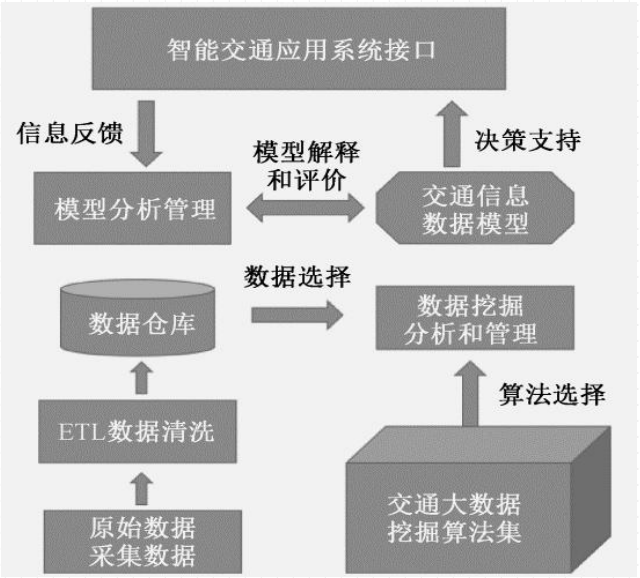


3.3.1 智慧交通系统中数据挖掘的系统模型

- 在各种智能交通应用系统中，交通数据挖掘来源于不同类型的操作数据库，且获得的数据需要通过清洗、装载、转换等一系列处理，整合到智慧交通的数据库
- 数据挖掘在基于此数据库的大数据平台上，实现众多深度挖掘的功能，常见的有分类、聚类、关联算法等



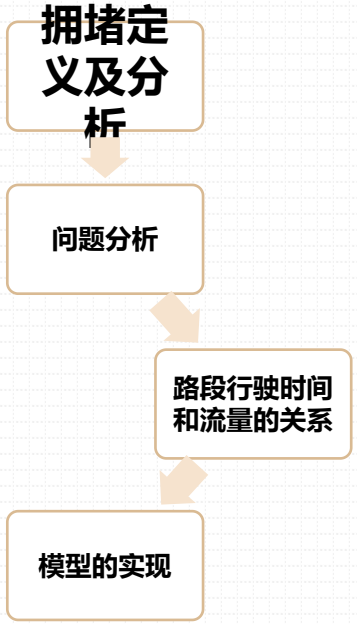
某交通大数据系统架构图



传统交通大数据挖掘的系统模型

3.4 大数据挖掘技术在智能交通中的应用

- 通过对交通数据进行宏观或微观的分析、统计和推理，利用现有的数据推断和预判未知的数据。数据挖掘是将人们对于交通信息的处理从最基本的查找、删改提高到了预测、预判。城市交通规划、交通管理、事件信息管理等都可以广泛使用数据挖掘



- 影响因素： 驾驶员和行人等的安全交通意识；非机动车对交通的影响；恶劣天气的影响；交通事故； 道路本身的通行能力
- 行驶过程中会受到各种干扰因素的影响，或多或少阻碍了车辆运行过程中的通畅程度
- 交通量（Q）、速度（V）和密度（K）$t = t_0 \left(\frac{2}{\left(1 \pm \sqrt{1 - \frac{Q}{C}}\right)} \right)$
- 通常使用MapReduce进行离线分析计算

3.5 河北交通卡口数据分析系统

■ 简介

- 河北交通卡口数据研判分析系统充分利用交管局卡口系统建设成果，将各卡口采集的车辆号牌基础数据实时传送到公安网内，整合各类警务信息资源，通过集中整合整理、海量关联查询、多维智能比对、综合分析研判、信息对流互动等，供情报中心实现对被盗抢机动车、涉案嫌疑机动车、交通肇事逃逸车辆、重点管控车辆等黑名单车辆的实时查控

■ 设计原则

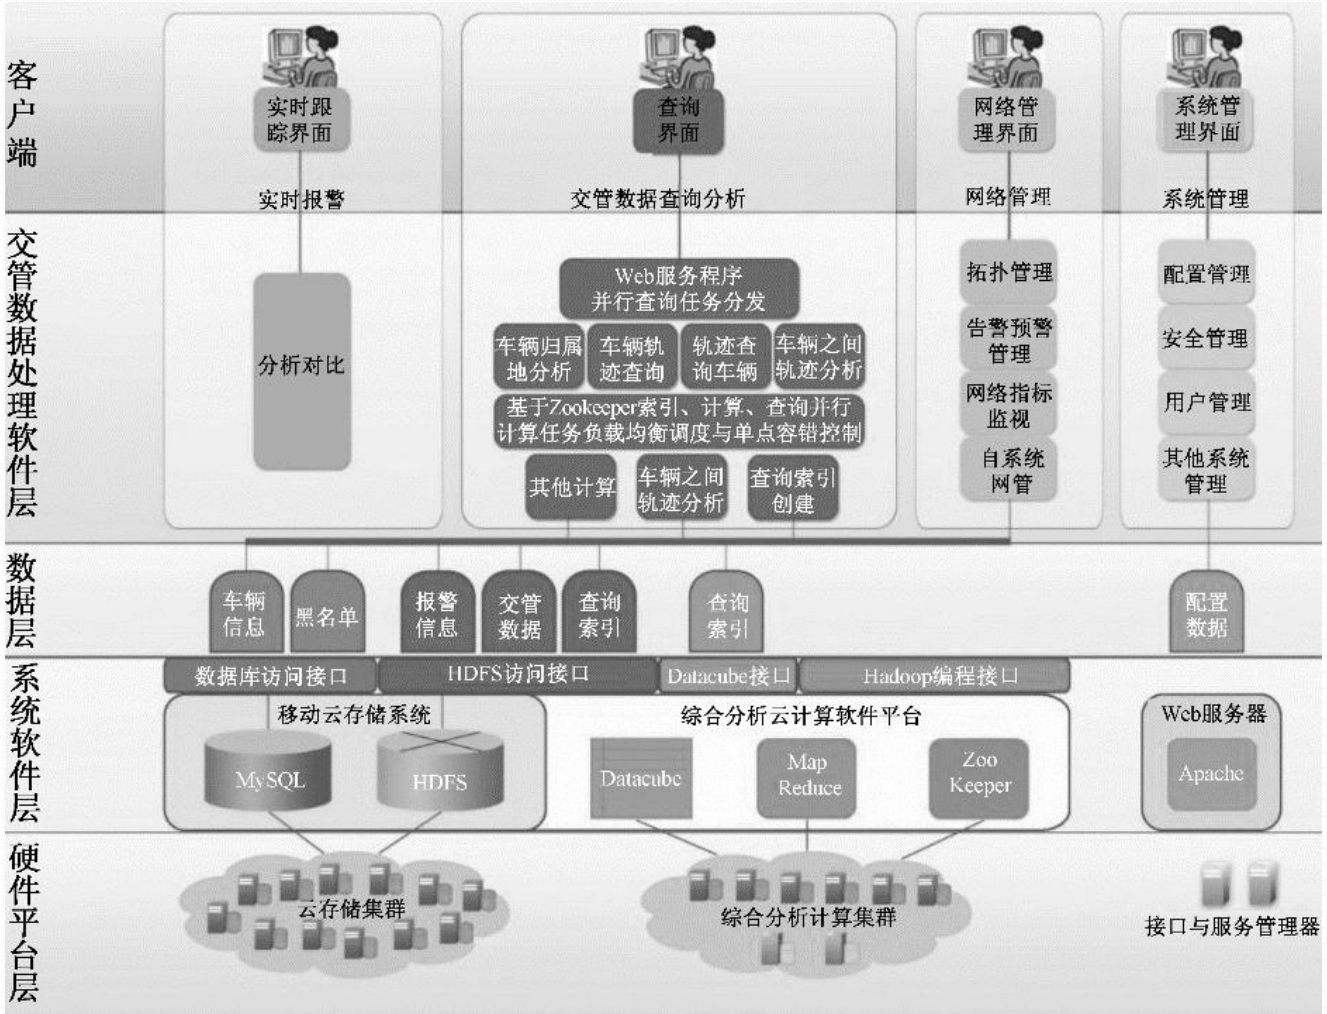
a. 前瞻性技术与实际应用环境相结合

b. 学习借鉴国外先进技术与自主创新相结合

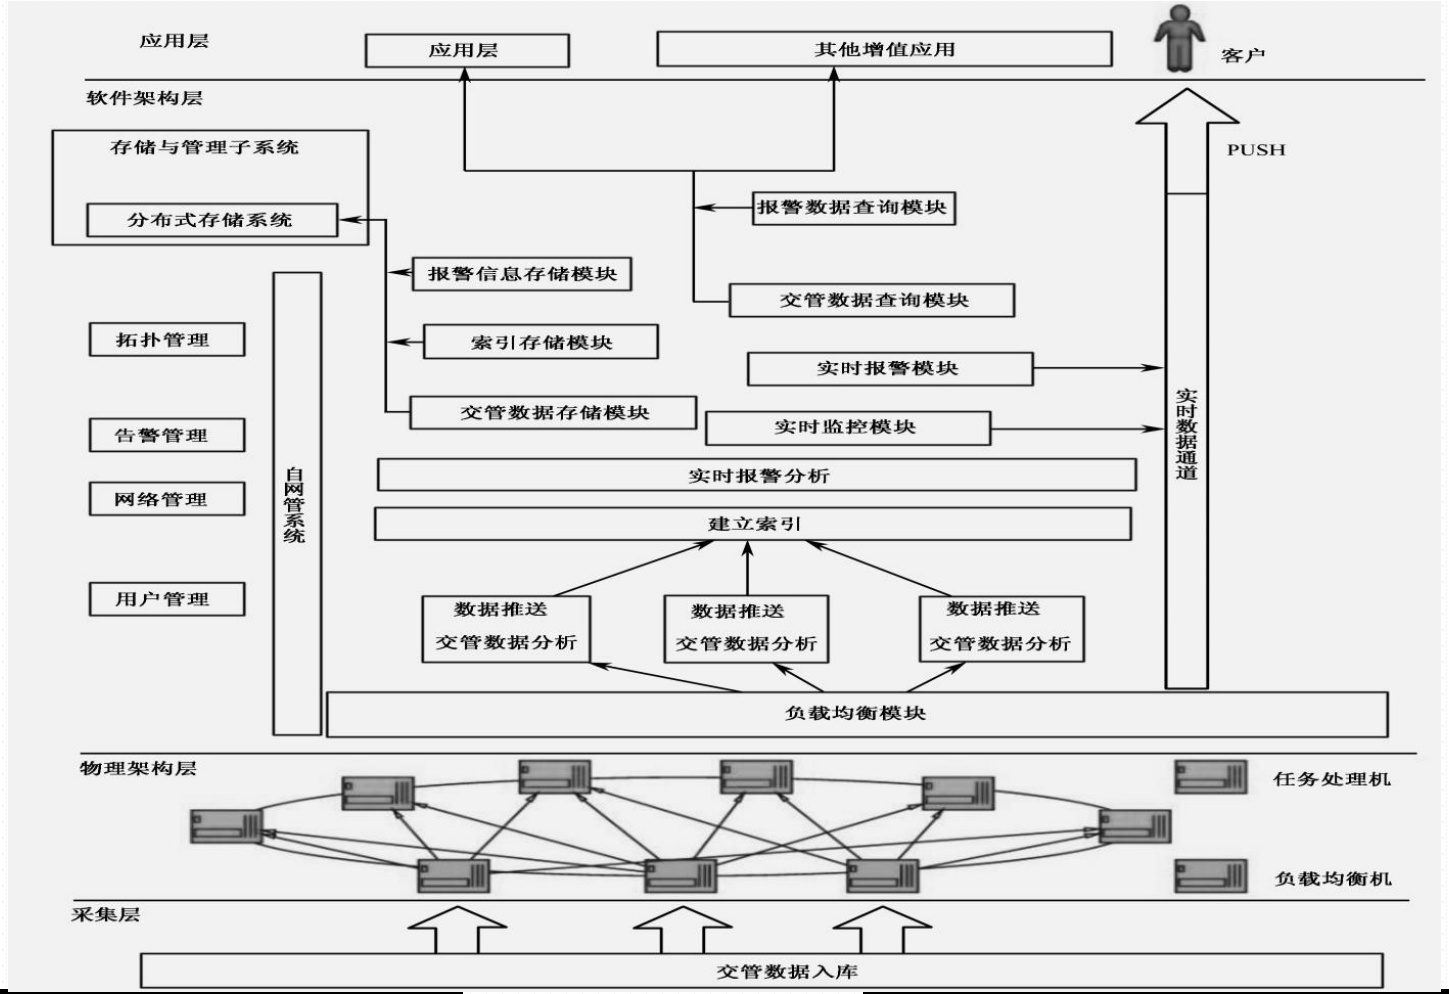
■ 系统基本组成和构架

- 该共享平台由7个主要部分组成：历史数据汇总处理系统、上报数据上报系统、实时数据入库系统、交管数据存储系统、交管数据查询分析应用系统、数据管理系统及系统管理
- 在基础设施构架上，该系统将构建在云计算平台之上，利用现有的计算资源、存储资源和网络资源，作为云平台的基础设施和支撑平台

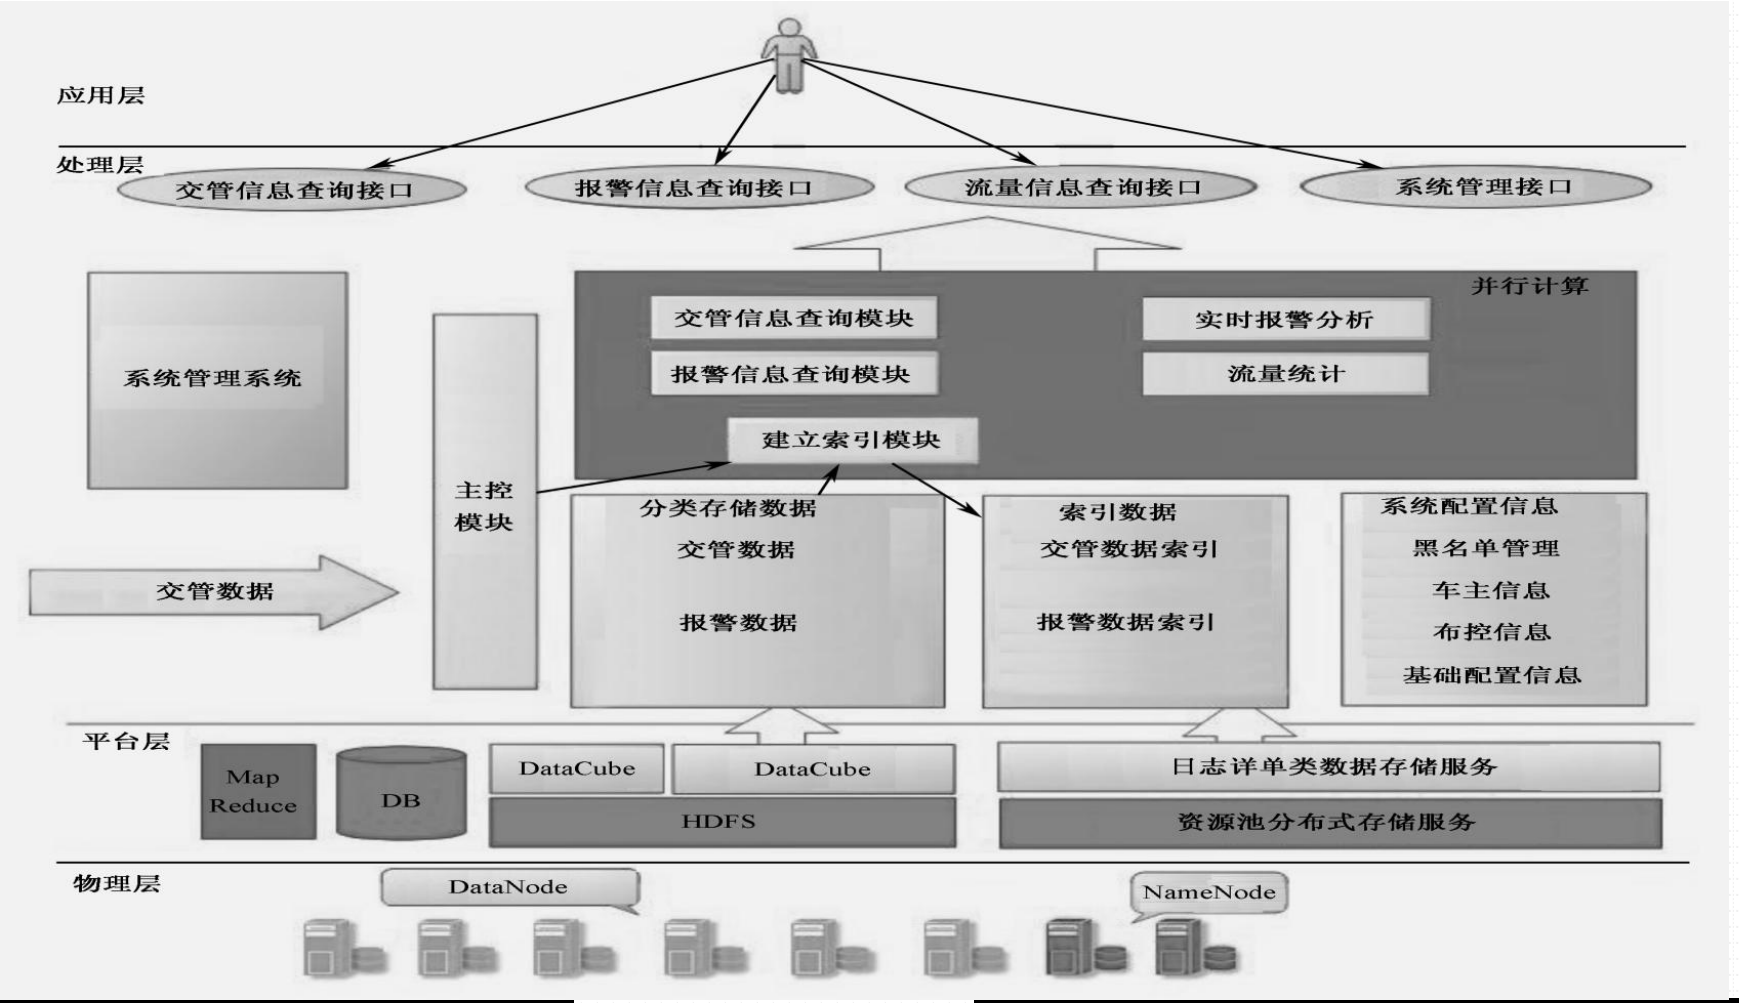
3.5.1 系统架构


客户端
交管数据处理软件层
数据层
系统软件层
硬件平台层
实时跟踪界面
查询界面
网络管理界面
系统管理界面
实时报警
交管数据查询分析
网络管理
系统管理
分析对比
Web服务程序并行查询任务分发
车辆归属地分析
车辆轨迹查询
轨迹查询车辆
车辆之间轨迹分析
基于Zookeeper索引、计算、查询并行计算任务负载均衡调度与单点容错控制
其他计算
车辆之间轨迹分析
查询索引创建
拓扑管理
告警预警管理
网络指标监视
自系统网管
配置管理
安全管理
用户管理
其他系统管理
车辆信息
黑名单
报警信息
交管数据
查询索引
查询索引
配置数据
数据库访问接口
HDFS访问接口
Datacube接口
Hadoop编程接口
移动云存储系统
MySQL
HDFS
综合分析云计算软件平台
Datacube
Map Reduce
Zoo Keeper
Web服务器
Apache
云存储集群
综合分析计算集群
接口与服务管理器

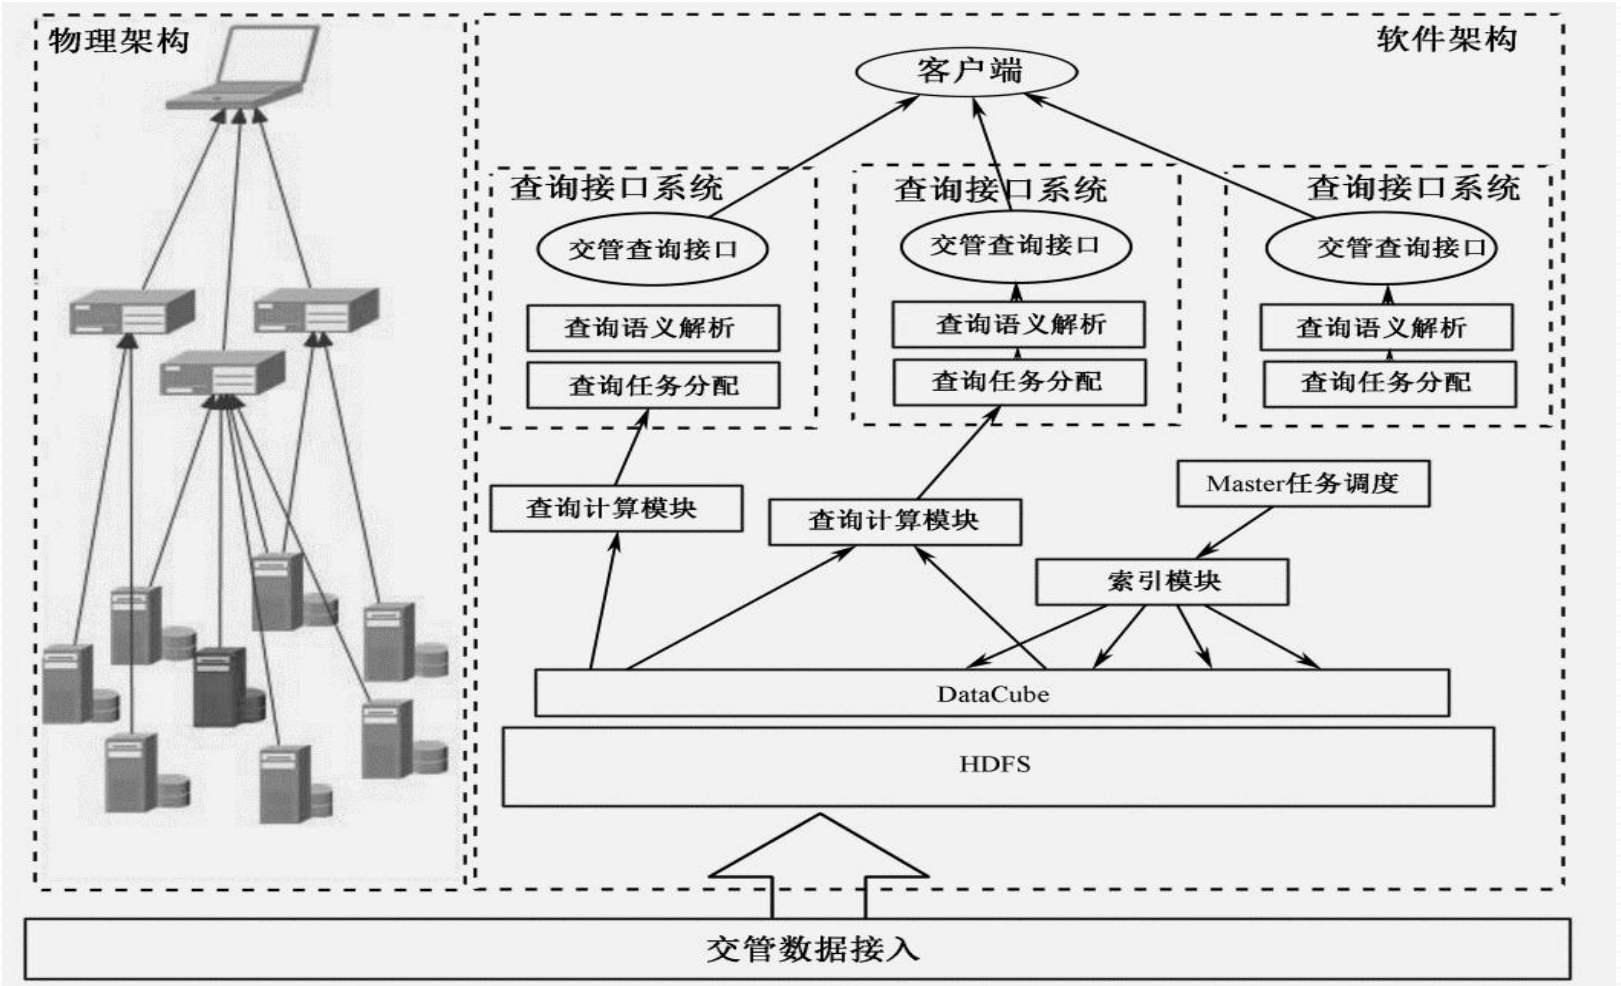
3.5.2 交管卡口数据入库功能与处理方案



3.5.3 数据存储功能与处理方案



3.5.4 查询分析功能与处理方案



3.5.5 项目成果

成果	具体介绍
统一平台	全省卡口数据集中于统一的公安业务管理平台，便于省厅对全省车辆流动状况情报进行宏观掌控
车辆查询	提供车辆参数条件多维查询，实现高速精确查找在任意时段途经任意卡口任意车辆图片数据
实时监测	卡口数据库内实时检测到符合侦查条件车辆数据入库，将自动提供报警提示
追踪侦查	综合全省卡口数据，轻松实现针对特定车辆的移动轨迹分析和追溯，如套牌车辆、嫌疑车辆的追踪侦查等。
提高效率	避免了数据入库效率不足而产生的堆积现象，极大地提高了业务系统的工作效率
安全可靠	彻底解决硬件设备故障率带来的数据安全隐患，保障重要业务数据的高可用性和业务的连续性
成本低廉	采用X86架构服务器集群构建的云存储和处理平台，比传统的小型机加商用数据库方案节省10倍左右的成本，并具备良好的兼容扩展性



大数据应用

CONTENTS

01 推荐系统
Recommender system

02 地震大数据
Seismic bigdata

03 交通大数据
Traffic bigdata

04 环境大数据
Environmental bigdata

4.1 环境大数据意义

互联网技术、物联网技术

↓ 高速发展期

环境信息化

↓ 迅猛发展

国家环保部门

↓ 重视

通过方案

环境数据服务和环保产业

↓ 巨大发展前景

国家发展还是市场需求

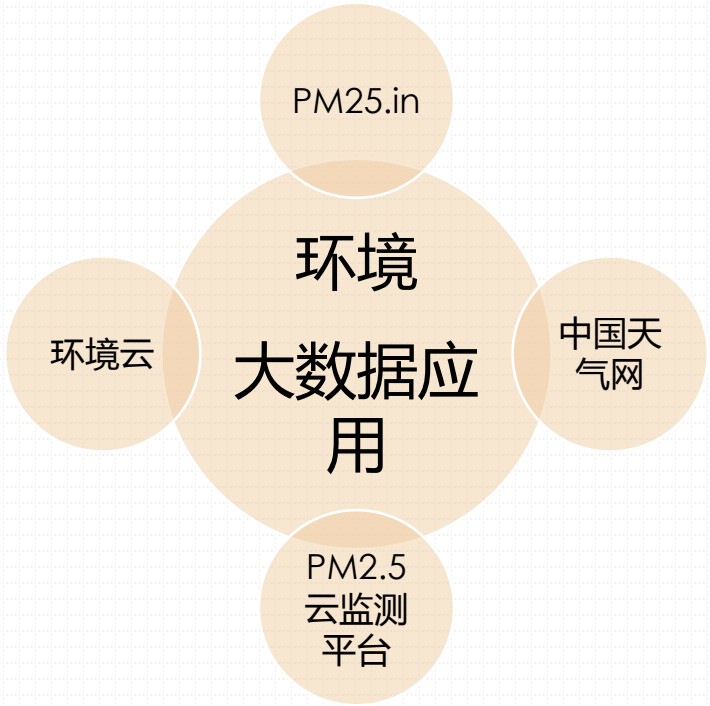
环 境 大 数 据 意 义

政府决策	企业转型	公众生活
促进政府生态环境综合决策科学化、监管精准化、公共服务便民化	有助于企业加快产业转型，发现新的商机，拓宽更广阔的市场	给公众生活带来更多便利，提升生活质量，吸引公众关注和重视

4.2 环境大数据概念

- 环境传感器数据的特点是除了信息本身所包含的环境物理量的测量值之外，其信息本身的时间和空间特征也是非常关键的
- 在时间维度上，环境数据可分为历史数据和实时数据，而各种预报系统则可以产生预报数据





4.2.1 多层次的数据采集

国家环保部和各省级环保部门-传统环境数据监测





专人值守或巡值

设备本身及其运行维护成本很高

控点监测项目全面

测量精确

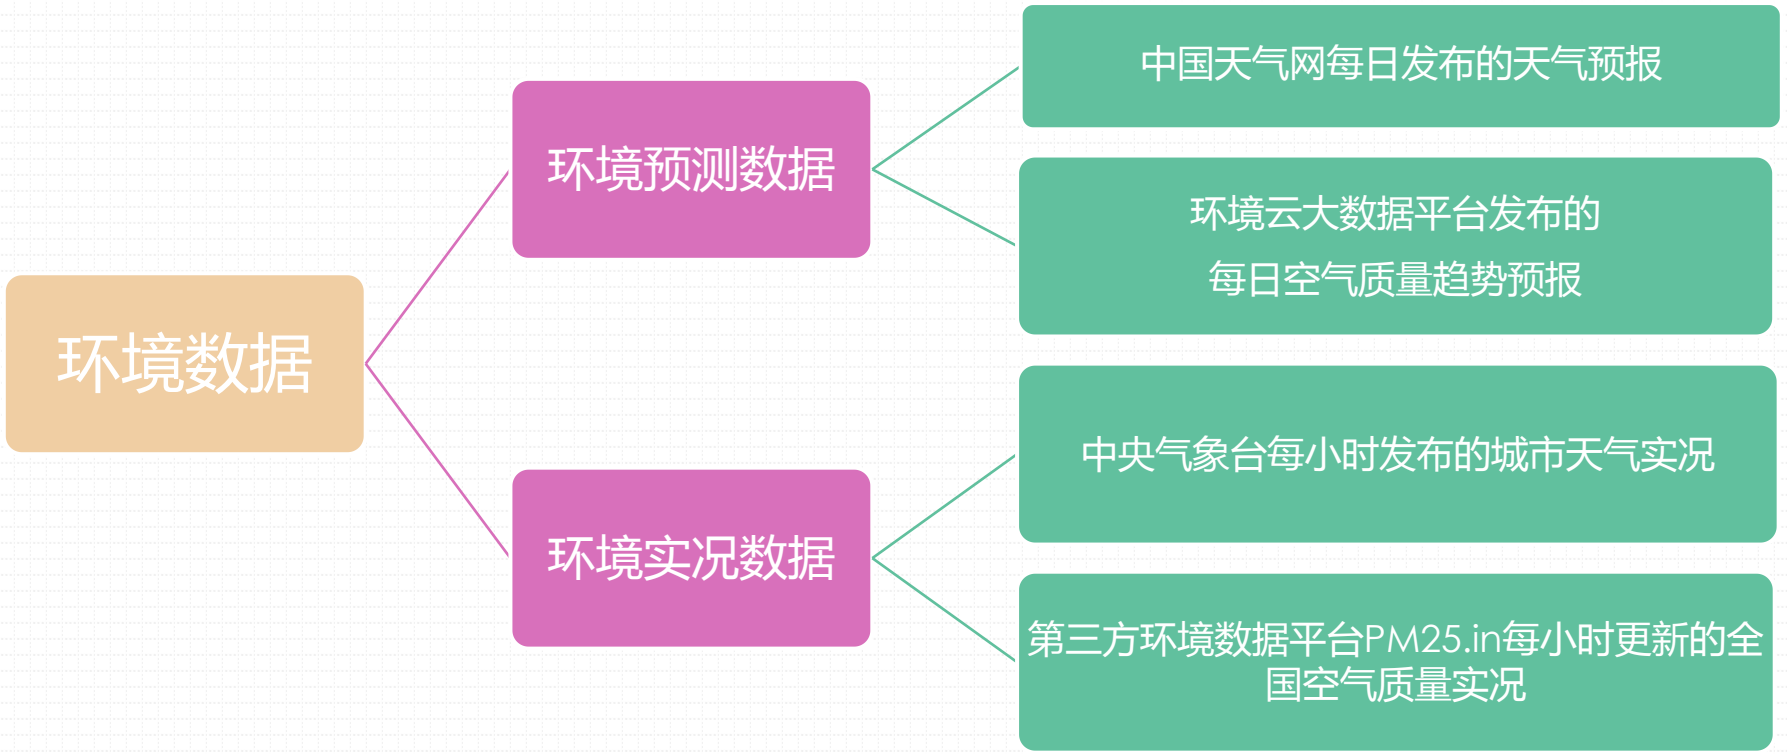
难以大规模布设，有时需要采用间接方式

4.2 多维度的环境数据整合

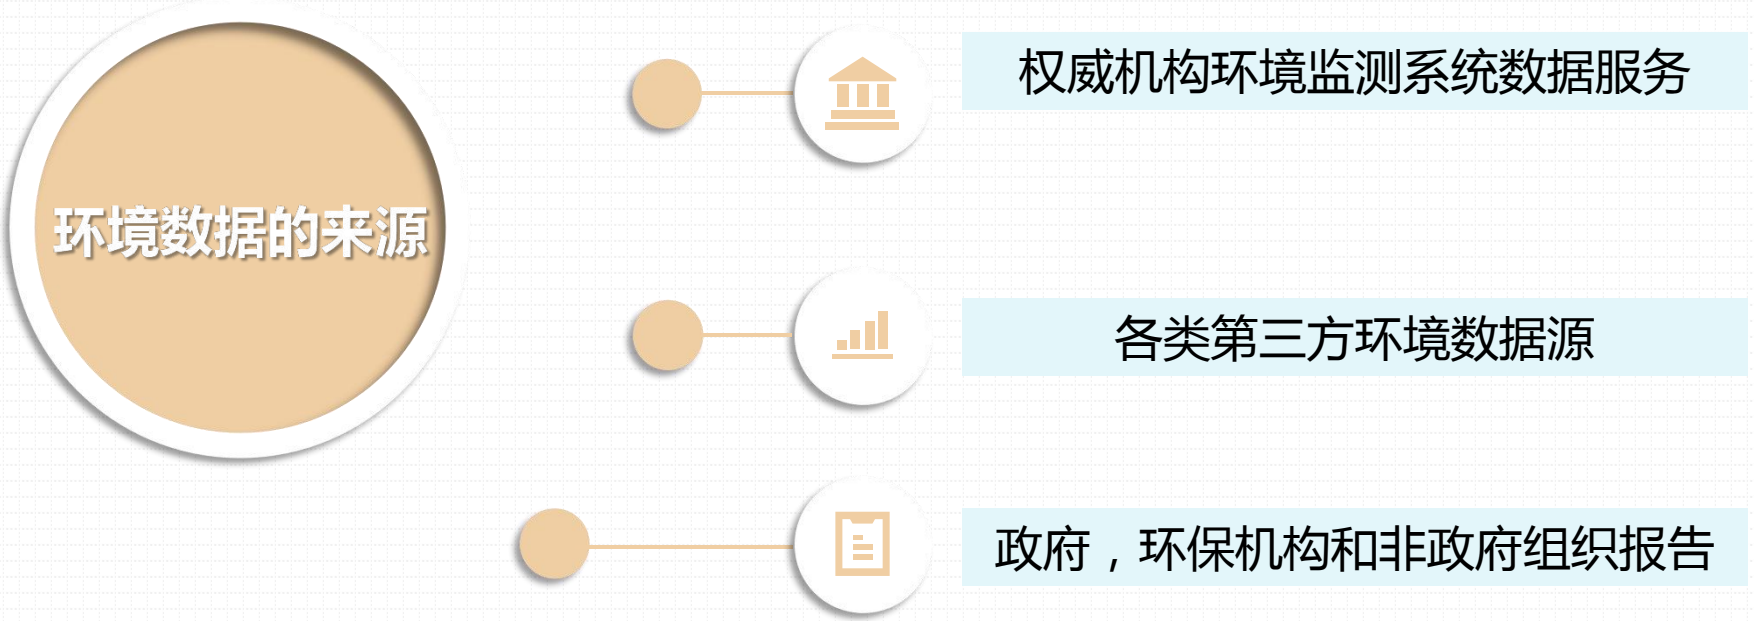
气象气候数据	大气质量数据	水体水质数据	土壤质量	自然灾害数据	污染排放历史
最为常用的环境数据是气象数据。主要的气象数据包括天气现象、温度、气压、相对湿度、风力风向、降雨量、紫外线辐射强度以及气象预警事件等	通过特征因子检测仪器及PM2.5监测设备监测污染因子：PM2.5、NO2、SO2、O3等空气中的主要污染物、H2S、NH3、NO2、SO2，以及有机溶剂气体，可燃气体等污染因子等	监视和测定水体中污染物的种类、各类污染物的浓度及变化趋势，包括未被污染和已受污染的天然水（江、河、湖、海和地下水）及各种各样的工业排水等。	通过对影响土壤环境质量因素的代表值的测定，确定环境质量（污染程度）及其变化趋势。监测因子包括pH、湿度、氮磷含量等。	台风、地震、洪水、龙卷风、泥石流、雷击等自然灾害的发生时间、地点、影响范围等。	污染物及其他有害物质排放数据：用水量、用电量、化石燃料的用量。定量地衡量地区的工业化和城市化水平

4.3 环境大数据采集和获取

- 环境数据的特点首先是海量，其次是数据应该包括时间和空间的信息



4.3.1 环境数据采集策略的确定



4.3.2 环境数据采集有效性

首先

对于同一数据源，为了避免网络震荡造成的影响，应采取重传机制，即采集数据超时之后，立即或间隔很短的一段时间后再次进行尝试。

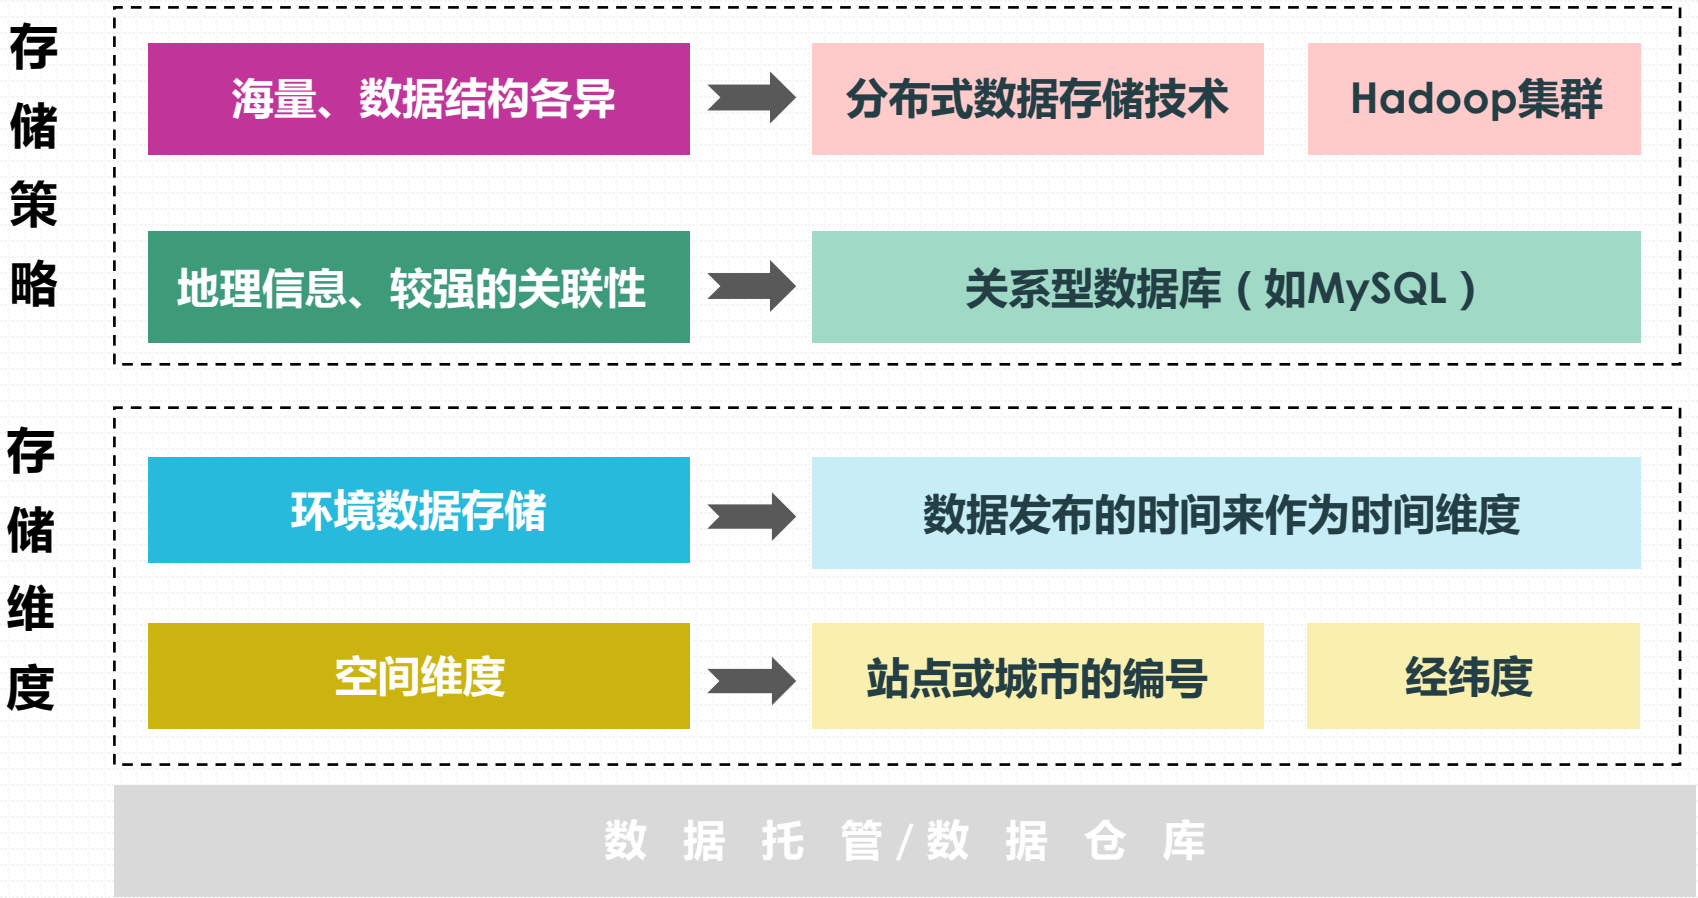
如果

对于同一数据源多次尝试采集均失败，应该采用备用的数据源进行该类环境数据的采集，考虑不同的数据源提供的数据的差异，采取相应的处理。

最后

对于采集到的数据，如果包含明显无效或异常的数据值，需要进行过滤处理，以保证只存储有效的环境数据采集值。

4.4 环境大存储和处理


存储策略
海量、数据结构各异
分布式数据存储技术
Hadoop集群
地理信息、较强的关联性
关系型数据库（如MySQL）
存储维度
环境数据存储
数据发布的时间来作为时间维度
空间维度
站点或城市的编号
经纬度
数 据 托 管 / 数 据 仓 库

4.4.1 存储环境数据时的处理



重庆大学 CHONGQING UNIVERSITY

4.5 环境大数据的应用



气象数据服务

提供天气预报和历史天气查询
支持全国2565个县级以上地市
帮助开发者快速开发天气应用

天气预报数据	海区天气预报	历史天气数据	天气实况数据
查询全国2565个县级以上城市的天气预报数据	查询全国海区天气预报	查询全国2374个县级以上城市的历史天气数据	查询全国2374个县级以上城市的天气实况数据



环境数据服务

想知道水资源、大气和污染排放环境数据？
一次查询，触手可及

水体环境数据	大气环境数据	污染排放数据	大气辐射数据	空气质量预报
查询环保部水环境监测站点发布的水资源环境数据	查询全国城市的空气质量指数实况及历史数据	查询全国所有省份的污染物排放历史数据	查询全国每日辐射环境数据	查询全国主要城市的空气质量预报数据



灾害数据服务

想了解历史上全国各地发生的地质和气象灾害信息？
简单查询，轻松获取

地质灾害数据	气象灾害数据	灾害预警数据
查询全国的地震、洪水、泥石流等地质灾害的历史数据	查询全国的台风、暴雨、雷击等气象灾害的历史数据	查询全国、指定省份或城市的实时灾害预警数据



地理数据服务

想知道自己的城市的经纬度和海拔？
想知道指定范围内有哪些城市？
查询一下，你就知道

城市位置数据	坐标范围数据	城市编码数据
查询全国2565个县级以上城市的地理位置数据	根据距离或范围查询区域内覆盖的城市的地理位置数据	根据地市中文名称查询对应的城市编码数据

4.5.1 环境大数据可视化





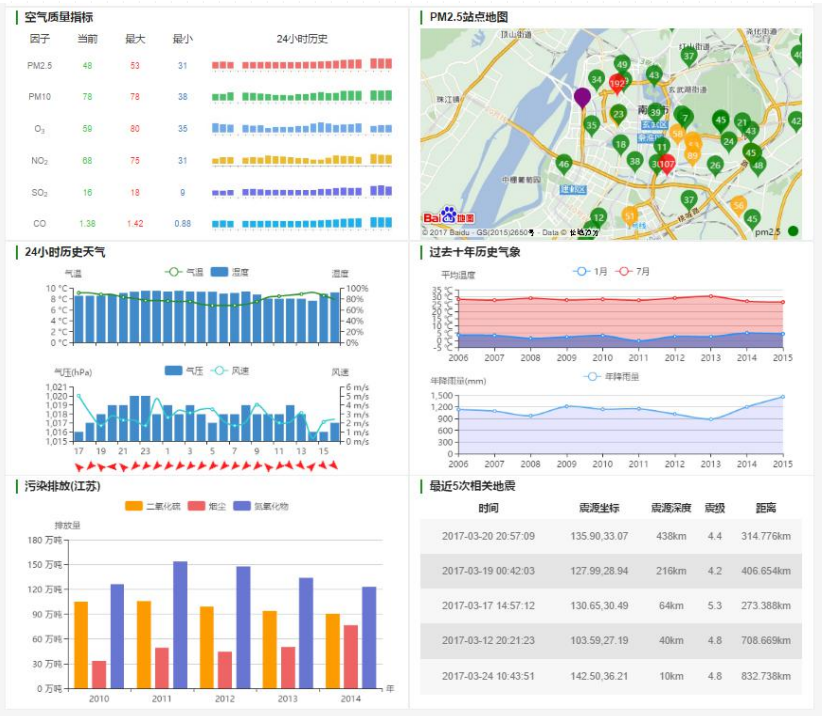




重庆大学 CHONGQING UNIVERSITY

4.5.2 环境大数据聚合





4.5.3 环境大数据应用价值

- 推动政府环保数据开放，引导更多企业、社会组织、个人、高校、科研院所、创投机构对环境保护大数据进行挖掘、分析和商业模式创新，形成“数据采集—数据开放—数据消费”的良性循环

- 通过对历史环境数据的挖掘与分析，可以更好地建立环境数据模型，从而提高环境数据预测的准确性。可以更好地建立环境数据模型，从而提高环境数据预测的准确性

- 此外，还可以结合环境数据和一些其他行业的数据来做综合分析，比如气象对交通的影响，关联环境数据和某些疾病发病数据可以跟踪流行病的发病趋势，环境对水利、电力、交通、农业的影响也可以通过对各种数据的时空关联来实现，针对干旱、暴雨洪涝、森林火险、冰雹、雷电等灾害性天气的气象灾害预警，为各相关行业提供有力的数据支撑，发挥环境数据应有的价值



大数据应用

BIG DATA

Thank You!