大数据概述

BIG DATA

教材

大数据应用案例		场景化众智案例
大数据可视化技术		基于像素、几何投影、基于图符、层次可视化、可视化复杂对象与关系、ECharts
大数据计算与分析		MapReduce、SparkRDD、Flink、数据挖掘、机器学习、深度学习
大数据存储与管理		HDFS、Yarn、HBase、MongoDB、数据库
大数据预处理与质控		数据认知、数据清洗、数据集成、数据归约、数据变换与离散化、数据降维
大数据获取与采集		分布式爬虫、日志采集、物联网数据采集
大数据操作系统		操作系统
大数据硬件环境		计算平台

教材及课程群

重庆大学 CHONGQING UNIVERSITY

冯永 主编; 钟将, 周明亮 副主编; 大数据架构与技术--融合国产技术体系. 西安电子科技大学出版社，ISBN: 978-7-5606-7870-2，2026年1月第1版.

耐劳苦 尚俭朴
勤学业 爱国家

参考书目

[1]《大数据导论》，梅宏 主编， 高等教育出版社, 最新版.

[2]《大数据处理》，金海 主编，高等教育出版社，最新版.

[3] 《大数据分析》，程学旗 主编，高等教育出版社，最新版.

[4] 斯坦福大学公开课: http://mmds.org/

[5] http://hadoop.apache.org/

[6] http://spark.apache.org/

期末项目评价要求

成绩构成

考核方式	总分	占总成绩的比例
课程项目及报告	100分	40%
实验项目	100分/实验，共4个实验，求取算术平均值	20%
平时作业	100分	20%
课程答辩	针对课程报告的课程答辩，100分	20%

一、成绩及说明：

课程报告及课程作品（总成绩40%）：详细要求参见二。

课程答辩（总成绩20%）：课堂答辩PPT制作及讲解，按照课程小组进行，假设20个小组，则每个小组每次讲解5分钟（100分钟/20小组），采用的大数据平台和技术架构、使用的组件和具体模块、作品设计思路、作品具体实现流程、作品实现效果分析、作品亮点和总结、确认自己实现的截屏或录像视频。

二、课程报告及课程作品具体要求和评价说明：

1、（必选）收集一份数据集：需要说明数据集的结构和格式，数据集的使用方式，需要强调如何部署到hadoop或spark平台上；

2、（必选）部署hadoop或spark平台或hadoop+spark，并能在部署好的平台上成功运行一个map-reduce算例（如wordcount等），要有部署成功和运行成功的佐证材料；

3、（必选）根据一定的应用场景或主题，基于自己收集的数据集，选取或设计一个算法（如数据挖掘的算法等，当然也可以自己写算法）并将之并行化实现，并且在部署好的大数据平台上运行成功，并结合设定好的应用场景给出算法的评价，要不同于实验；

4、（加分点，决定期末成绩差异）算法或应用的复杂性及可用性；部署且使用的平台及其模块种类（如hadoop+spark，完全分布部署；又比如利用到了Hive、图计算框架、流计算框架、MongoDB等）；算法和应用的量化可评价度量性；分析计算结果的可视化效果等；

5、（必选）需要制作课程答辩PPT，参见一中“课程答辩”要求；

6、（必选）按照提供的课程报告样例，撰写课程报告，每个小组完成一份，课程报告包括但不限于：具体的小组成员分工，平台搭建的详细过程，测试案例运行过程及结果，并行化算法设计运行的过程和结果，数据集的格式、收集、说明和使用方案，课程总结；

7、（必选）课程结束后两周内（含两周）每个小组将答辩PPT、课程报告、程序（代码+注释+运行配置说明）、数据集和媒体资源存储至百度云盘并将链接发送给助教。

《大数据架构与技术》课程项目答辩方式

重庆大学 CHONGQING UNIVERSITY

1、由于课程分组较多，分两次进行，倒数第二次课为第一次答辩，倒数第一次课为第二次答辩，已经列入本学期课程教学日历；

2、第一次答辩主要包括：数据集采集及预处理方法、系统安装部署情况、课程项目设计思路等；

3、第二次答辩主要包括：项目设计流程与算法分析、实验效果及结果评价、结果可视化展示等；

4、请大家采用PPT的排练计时功能，严格控制答辩时间，按照组号进行课程答辩；

《大数据架构与技术》课程项目答辩方式

5、评价团队：任课教师1名、院内专家1名（按需）、企业专家1名（按需）、助教1名，对评价团队分数进行加权求和；

6、课程项目评价维度：

- 课程项目及报告，100分，期末综合成绩占比40%：数据收集及预处理15分，大数据框架使用15分，项目及算法设计25分，算法评价及结果展示25分，团队协作（含开源贡献）10分，提交资料质量10分；
- 课程答辩，100分，期末综合成绩占比20%：每次答辩50分。

2020

军事支出占GDP比重数据分析

思路

1.收集相关数据集 → 数据集上传

2.数据集数据处理 → 文本文件

3.具体的分析算法 → 最终分析文本

目录

CONTENTS

1 小组分工

2 采用数据集

3 数据集上传及处理

4 聚类分析处理数据

LOGO

小组分工

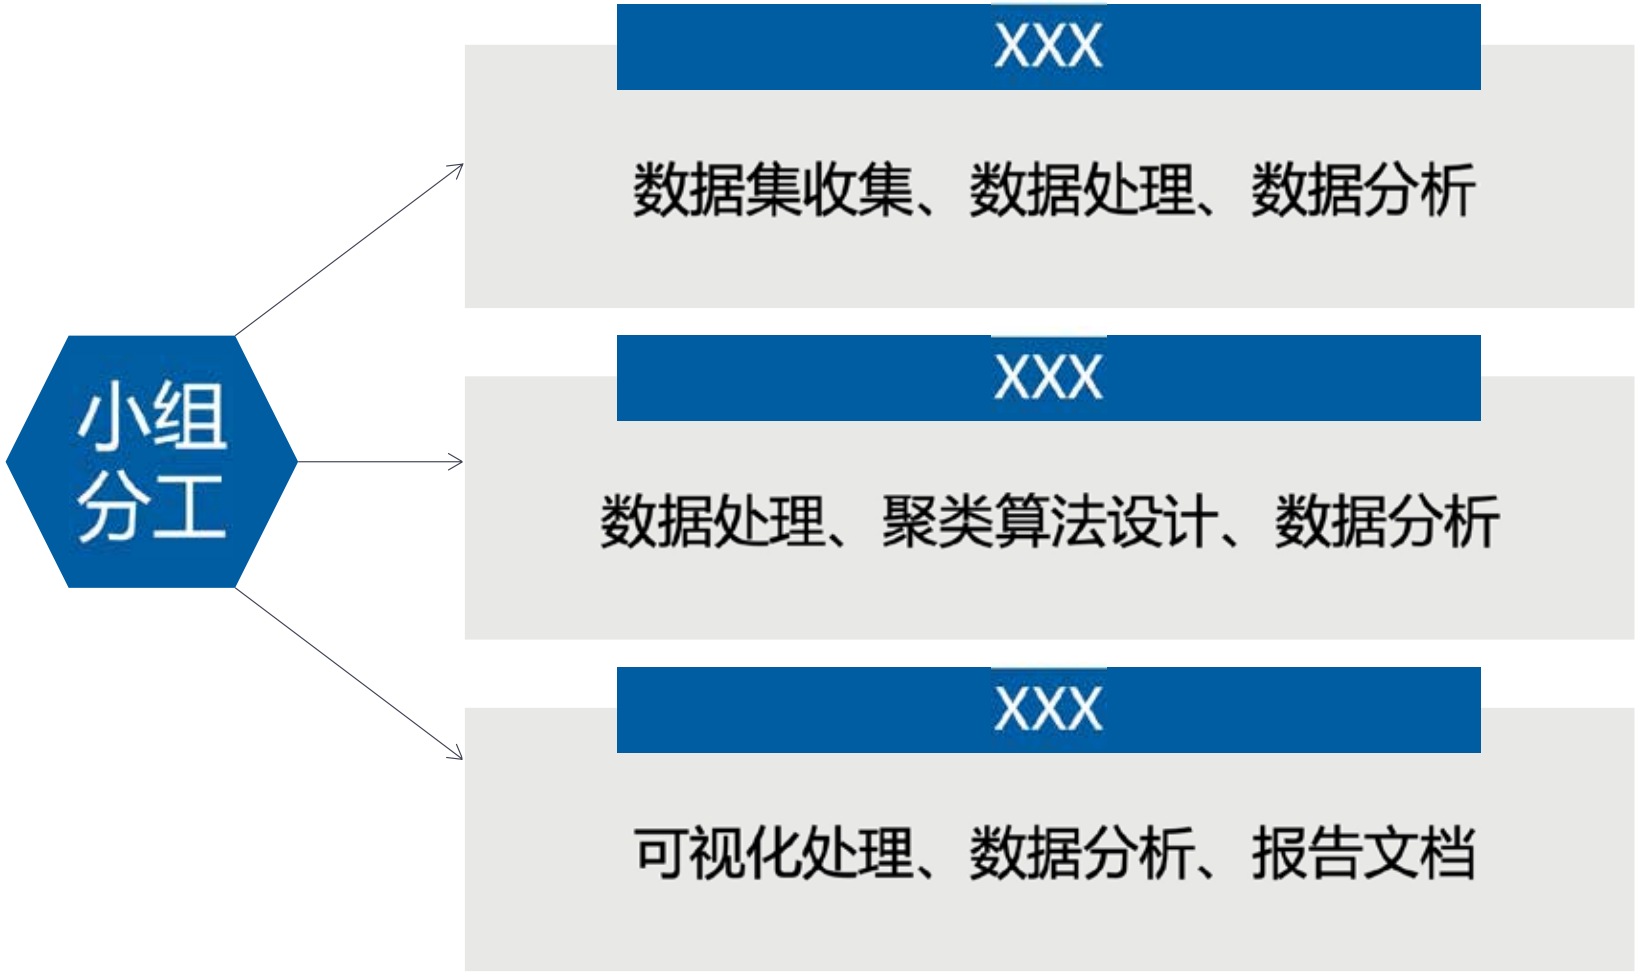
小组分工
XXX
数据集收集、数据处理、数据分析
XXX
数据处理、聚类算法设计、数据分析
XXX
可视化处理、数据分析、报告文档

目录

CONTENTS

1 小组分工

2 采用数据集

3 数据集上传及处理

4 聚类分析处理数据

Our World in Data

https://ourworldindata.org/military-spending

LOGO

采用数据集

military-expenditure-as-share-of-gdp

	A	B	C	D	E	F
1	Entity	Code	Year	Military expenditure (% of GDP)		
2	Afghanist	AFG	2004	2.431258		
3	Afghanist	AFG	2005	1.992068		
4	Afghanist	AFG	2006	1.896234		
5	Afghanist	AFG	2007	2.566268		
6	Afghanist	AFG	2008	2.335547		
7	Afghanist	AFG	2009	2.087413		
8	Afghanist	AFG	2010	1.945837		
9	Afghanist	AFG	2011	1.821346		
10	Afghanist	AFG	2012	1.175417		
11	Afghanist	AFG	2013	1.07695		
12	Afghanist	AFG	2014	1.298013		
13	Afghanist	AFG	2015	0.993455		
14	Afghanist	AFG	2016	0.955493		
15	Afghanist	AFG	2017	0.906857		
16	Albania	ALB	2004	1.381158		
17	Albania	ALB	2005	1.350005		
18	Albania	ALB	2006	1.567769		
19	Albania	ALB	2007	1.820765		
20	Albania	ALB	2008	1.984869		

9167	Zimbabwe	ZWE	2011	1.643824	
9168	Zimbabwe	ZWE	2012	2.263931	
9169	Zimbabwe	ZWE	2013	2.343084	
9170	Zimbabwe	ZWE	2014	2.324734	
9171	Zimbabwe	ZWE	2015	2.343629	
9172	Zimbabwe	ZWE	2016	2.198173	
9173	Zimbabwe	ZWE	2017	1.970583	
9174					

1960S-2017S

采用csv格式存储

目录

CONTENTS

1 小组分工

2 采用数据集

3 数据集上传及处理

4 聚类分析处理数据

LOGO

数据集上传

FileZilla Client

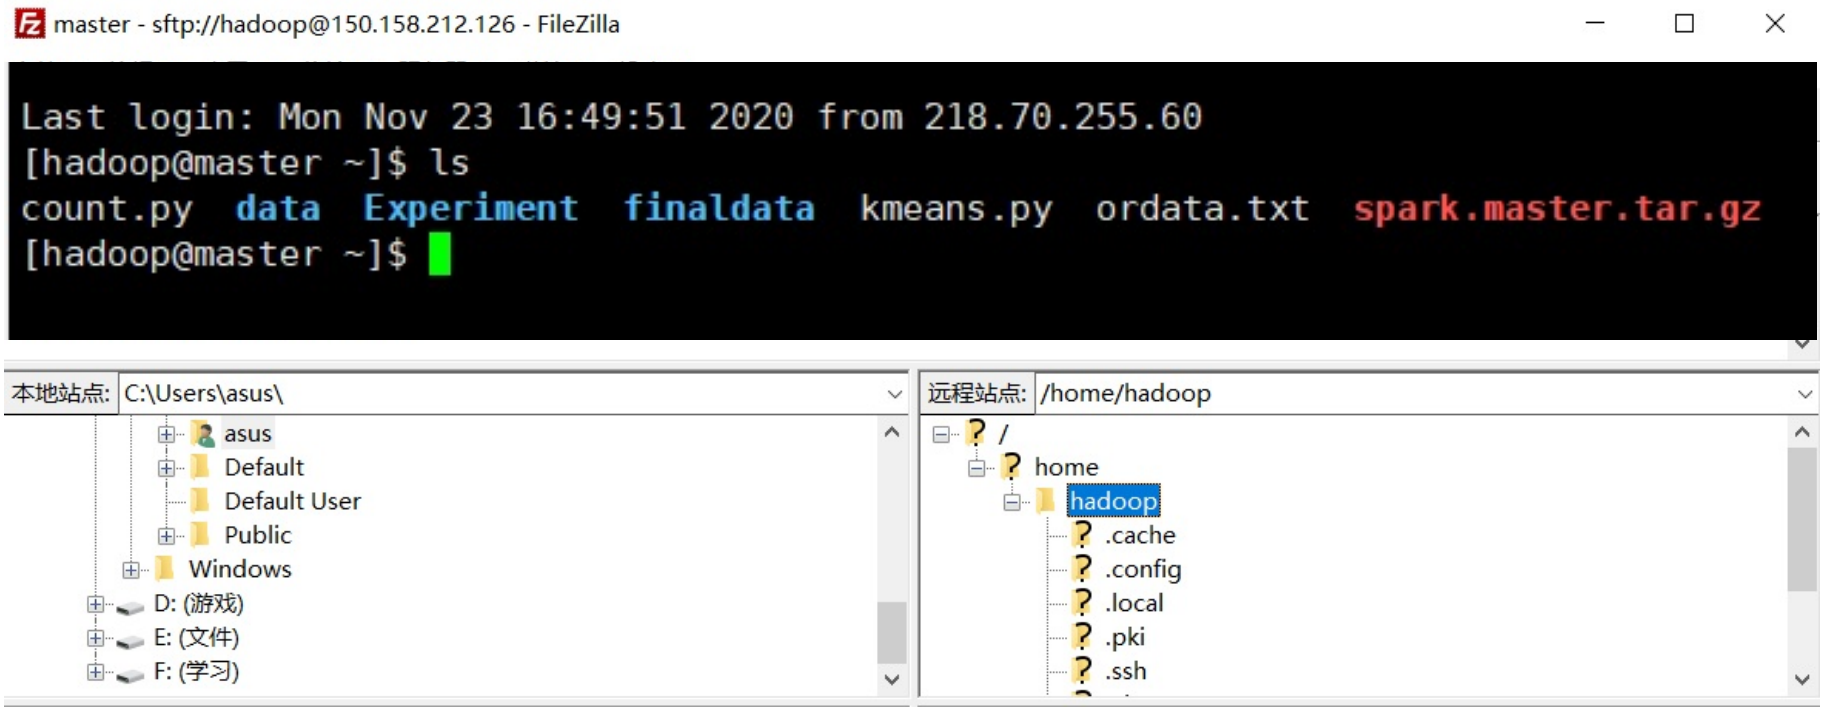

数据第一次筛选

采用2004S-2017S的数据

Hdfs： 数据第二次筛选

```
from
from
impor
conf = Spark(
sc = Sp
client
```

```
    lines = [(row.split(',')[0],float(row.split(',')[3]))for row in lines]
    data = sc.parallelize(lines)
    data_1 = data.groupByKey()
    data_2 = data_1.mapValues(lambda a:[i for i in a])
    data_2.saveAsTextFile("file:///home/hadoop/data")
```

```
08235108]), ('Angola', [3.471180187, 3.692240947, 3.761495305, 3.114054493, 3.57312
1984, 5.840526749, 6.389929368, 7.506153829, 6.202371753, 6.410466315]), ('Argentin
a', [0.883295359, 0.847154784, 0.788233877, 0.792548175, 0.762756475, 0.886508577,
0.814878105, 0.764287094, 0.784824721, 0.83773643, 0.878100919, 0.86472284, 0.82713
0106, 0.909662993]), ('Armenia', [2.741996705, 2.871931363, 2.947613156, 3.04257470
1, 3.395579363, 4.157049908, 4.265646056, 3.853946441, 3.583766499, 3.997244557, 3.
943378265, 4.239225803, 4.080226863, 3.968039367]), ('Australia', [1.827410769, 1.8
01853775, 1.821842846, 1.814599669, 1.797239012, 1.929179691, 1.862399774, 1.769389
864, 1.679917358, 1.649533076, 1.781294955, 1.958451254, 2.092849524, 1.989292632])
, ('Austria', [0.893480466, 0.853724571, 0.789783772, 0.90565864, 0.876168945, 0.83
8784296, 0.824768861, 0.794738036, 0.782234948, 0.754017344, 0.753954082, 0.7070986
42, 0.747000092, 0.729355232]), ('Azerbaijan', [2.629481138, 2.299069675, 3.4177593
```

目录

CONTENTS

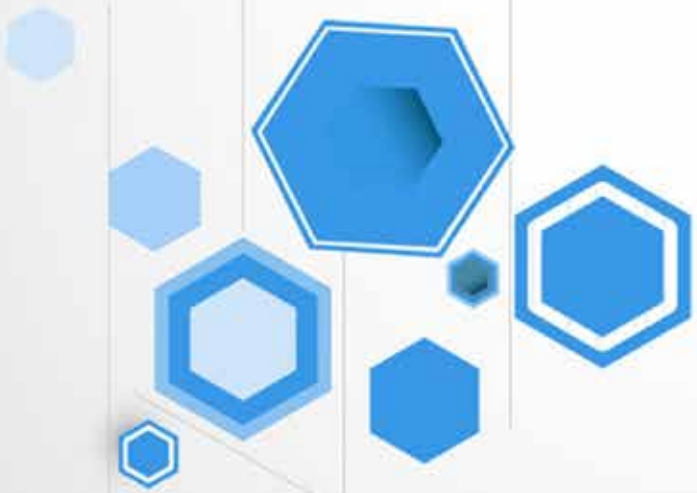

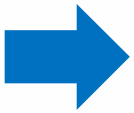

1 小组分工

2 采用数据集

3 数据集上传及处理

4 聚类分析处理数据

调用SPARK库 数据挖掘

```
    K = int(3)
    convergeDist = float(0.1)

    kPoints = data.takeSample(False, K, 1)
    tempDist = 2.0

    while tempDist > convergeDist:
        closest = data.map(
            lambda p: (closestPoint(p, kPoints), (p, 1)))
        pointStats = closest.reduceByKey(
            lambda p1_c1, p2_c2: ([i[0]+i[1] for i in zip(p1_c1[0],p2_c2[0])], p1_c
1[1] + p2_c2[1]))
        newPoints = pointStats.map(
            lambda st: (st[0], [i/st[1][1] for i in st[1][0]])).collect()
        tempDist = sum(np.sum([(i[0]-i[1])**2 for i in zip(kPoints[iK],p)]) for (iK
, p) in newPoints)
        for (iK, p) in newPoints:
            kPoints[iK] = p
    print("Final centers: " + str(kPoints))
    closest = lines.map(lambda p: (p[0],p[1],closestPoint(p[1], kPoints)))
    closest.saveAsTextFile("file:///home/hadoop/finaldata")
```

LOGO

数据集处理

fidatafbvalobratcess.pv

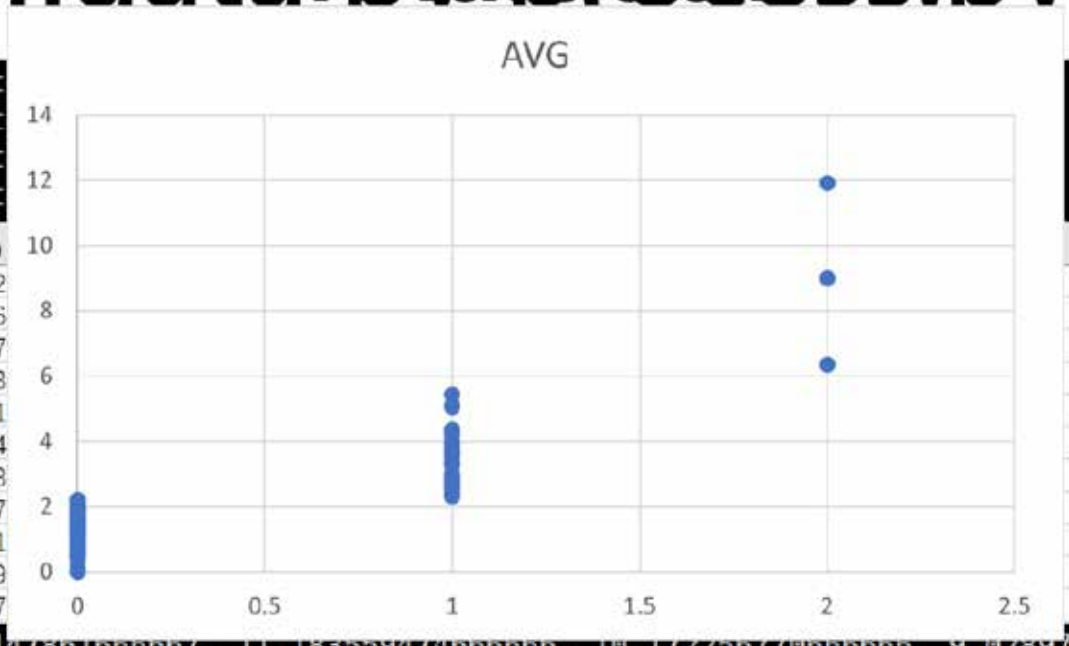


```
[hadoop@mast
[hadoop@mast
[hadoop@mast
[hadoop@mast
925, 10.0734478616666667, 11.1833594746666666, 10.1722567706666666, 9.028977891666667]
]
```

	A	B	C	D	N	O	P	Q
1	country	2004	2005	2	2016	2017	type	
2	Afghanista	2.431258	1.992068	1.896	0.955493	0.906857	0	
3	Albania	1.381158	1.350005	1.567	1.103347	1.244175	0	
4	Algeria	3.283885	2.834178	2.643	6.424474	5.708235	1	
5	Angola	3.47118	3.692241	3.761	2.641535	2.201338	1	
6	Arab Worl	5.133603	4.68989	4.434	6.202372	6.410466	1	
7	Argentina	0.883295	0.847155	0.788	0.82713	0.909663	0	
8	Armenia	2.741997	2.871931	2.947	4.080227	3.968039	1	
9	Australia	1.827411	1.801854	1.821	2.09285	1.989293	0	
10	Austria	0.89348	0.853725	0.789	0.747	0.729355	0	
11	Azerbaijar	2.629481	2.29907	3.417	3.690457	3.9374	1	

目录

CONTENTS

1 结果分析

2 课程项目总结

LOGO

结果分析

数据地图

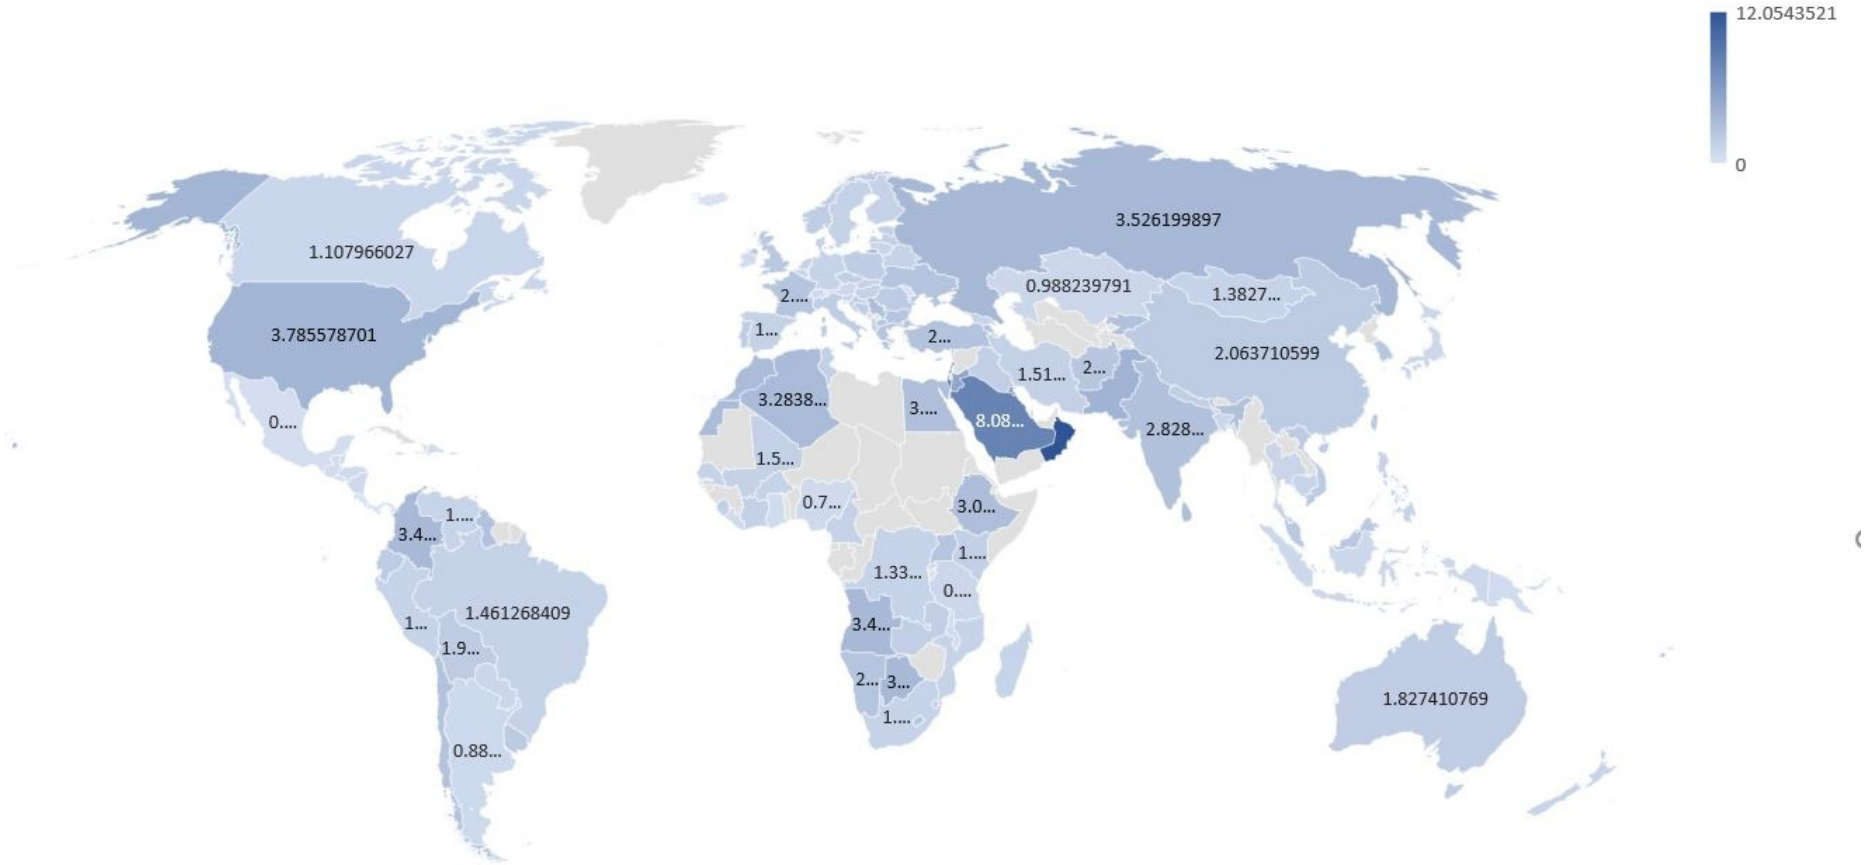

LOGO

结果分析

数据占比

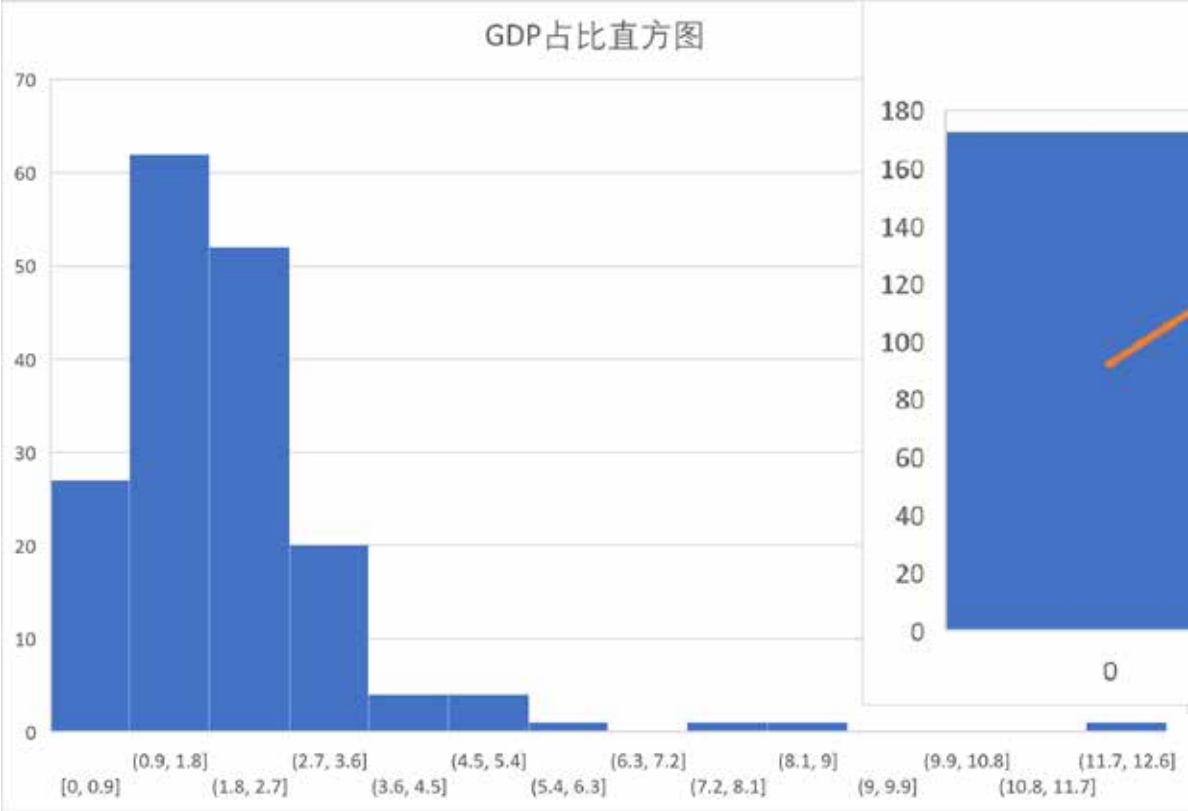

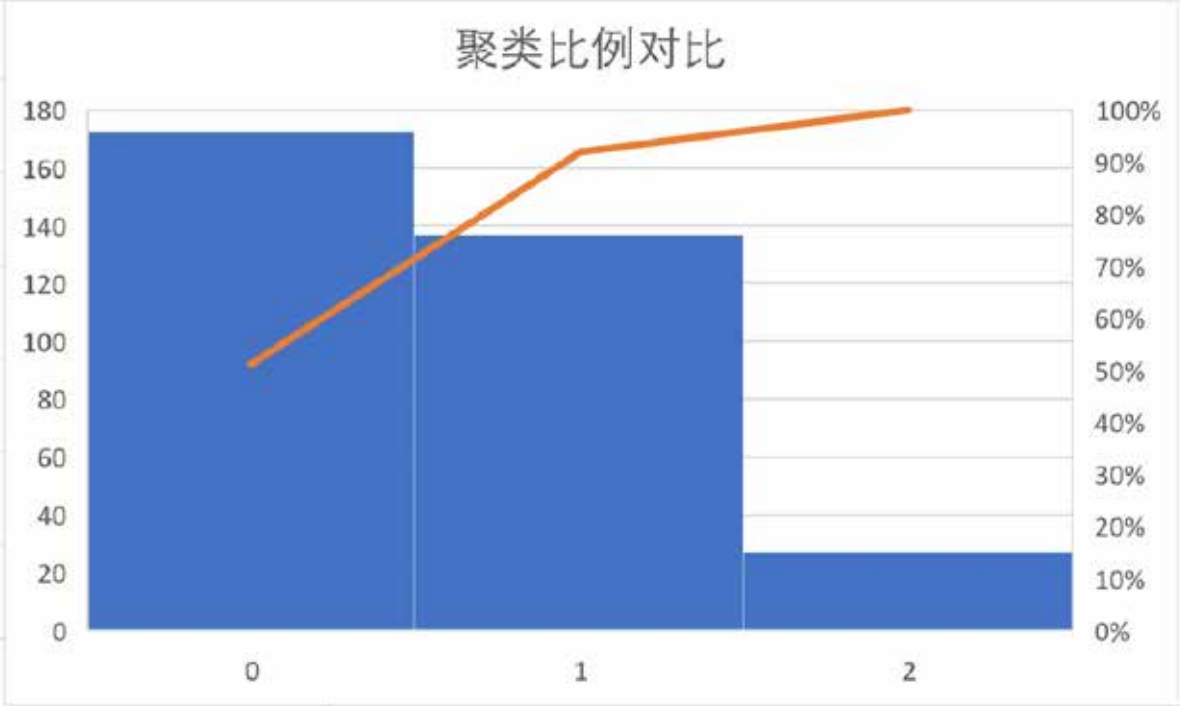

LOGO

结果分析

聚类散点图

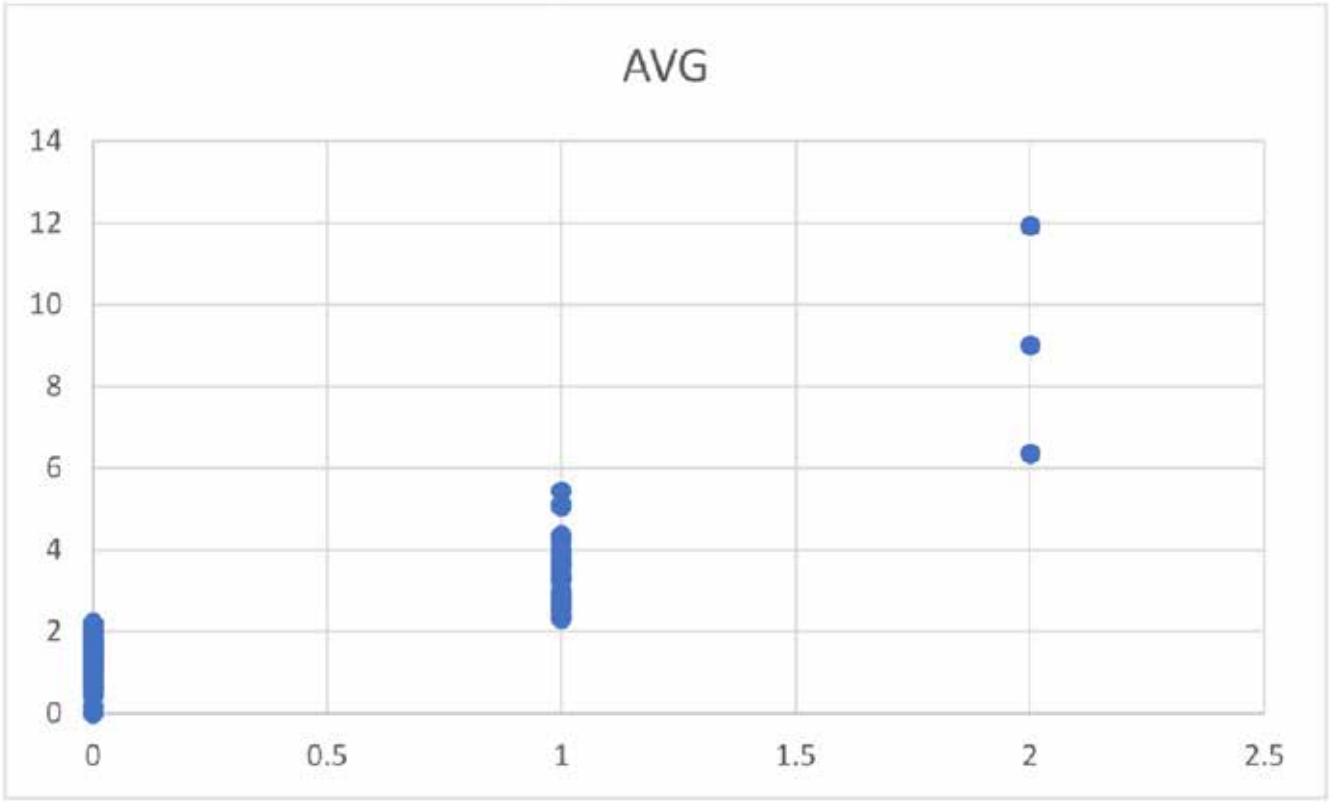

聚3类

LOGO

结果分析

第二类

78	Israel	8.185524	7.637096	7.4			.670257	4.654133	4.725543	2
126	Oman	12.05435	11.81698	10.8			14.3842	15.95615	12.07272	2
140	Saudi Arabia	8.08156	7.730601				13.49623	9.906483	10.28867	2

第一类

1	2
美国 3.902	伊朗 2.591
俄罗斯 3.937	巴基斯坦 3.394
	印度 2.582

第零类

1数量众多

2分布广泛

3以北欧、西欧、泛亚、南非国家为主

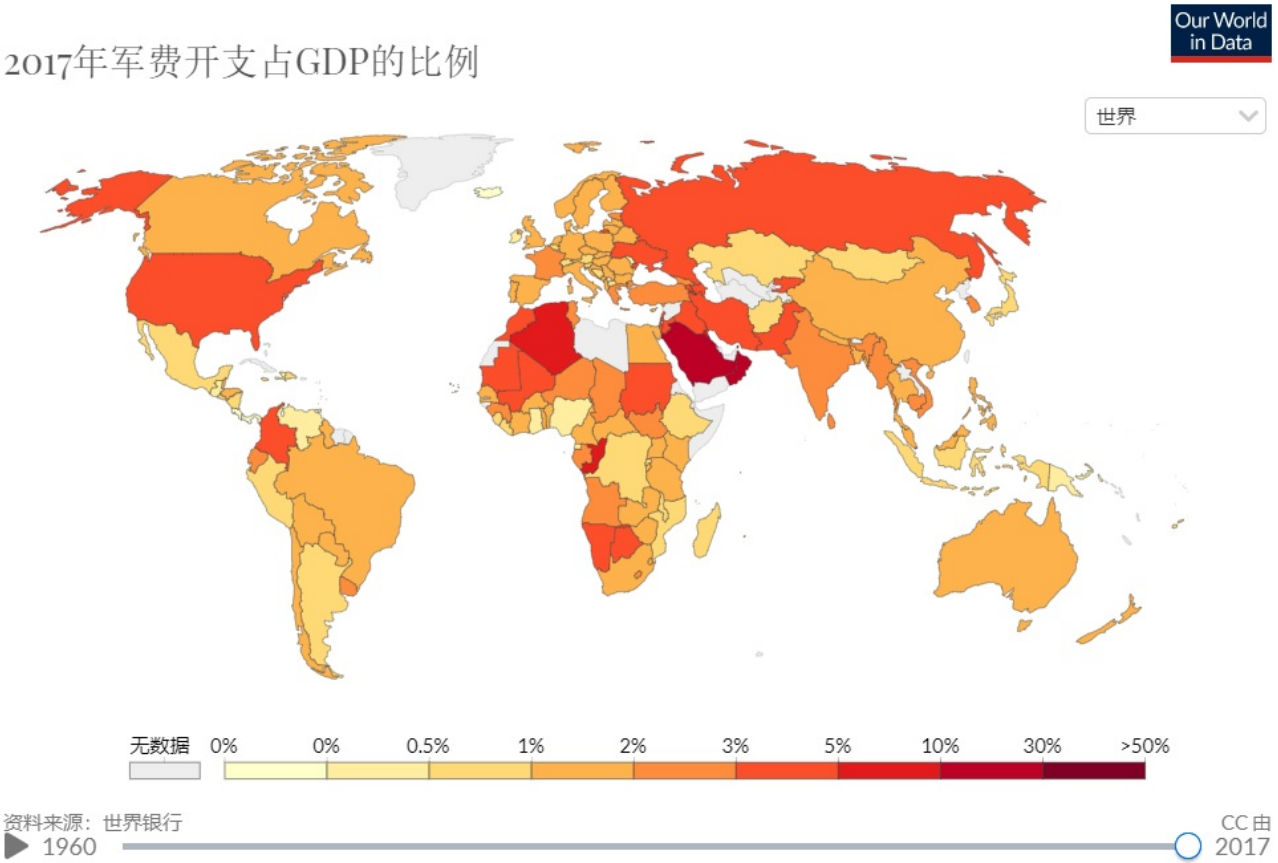

目录

CONTENTS

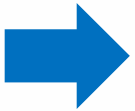

1 简单回顾

2 结果分析

3 课程项目总结

缺点

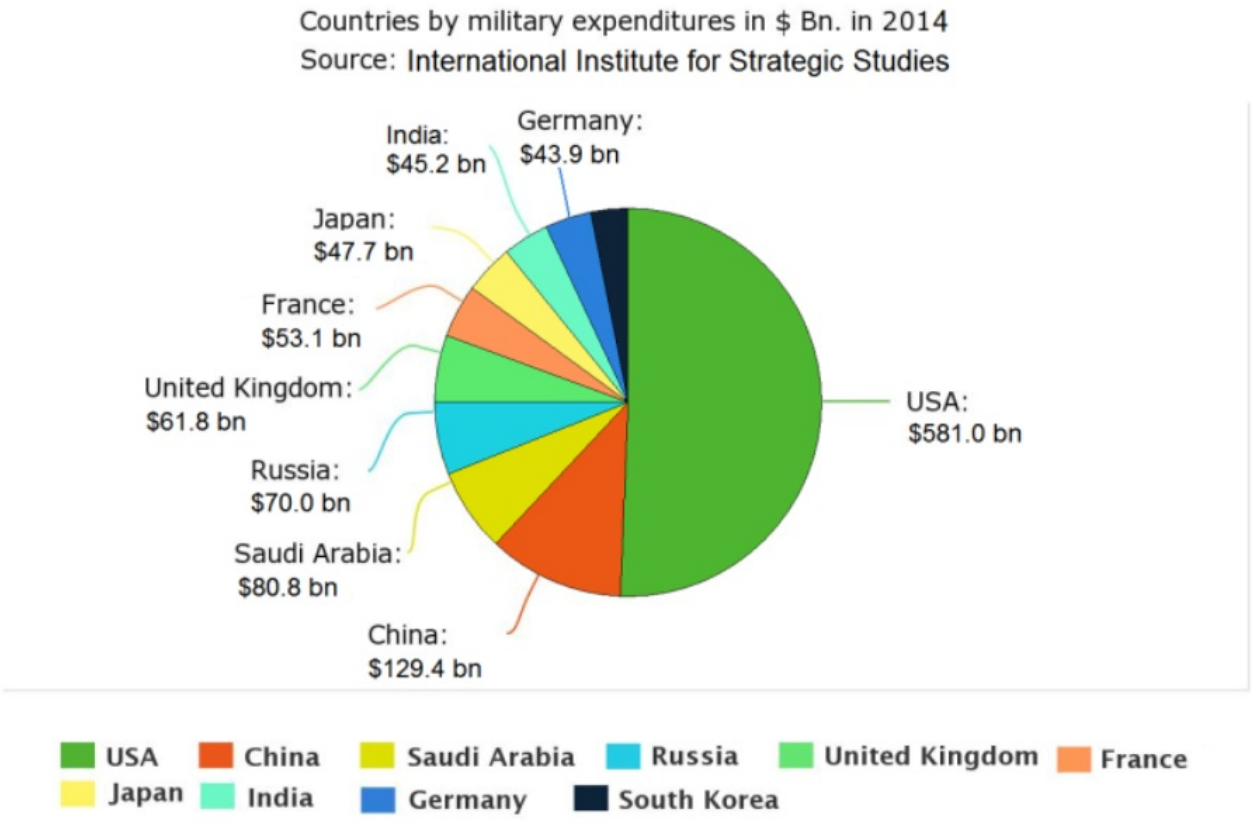
Countries by military expenditures in $ Bn. in 2014
Source: International Institute for Strategic Studies
India: $45.2 bn
Germany: $43.9 bn
Japan: $47.7 bn
France: $53.1 bn
United Kingdom: $61.8 bn
Russia: $70.0 bn
Saudi Arabia: $80.8 bn
China: $129.4 bn
USA: $581.0 bn
USA
China
Saudi Arabia
Russia
United Kingdom
France
Japan
India
Germany
South Korea

期末项目评价要求

Thank You!

大数据概述

CONTENTS

01 大数据概念与意义
Background

02 大数据的来源
Origin

03 大数据的应用
Application

04 大数据的处理方法
Processing data

数据的概念

1EB=1024PB；5EB 相当于至今全世界人类所讲过的话语

1ZB=1024EB；全世界海滩上的沙子数量总和

1.1.1 大数据发展历程

- 2008年9 月
  - 美国《自然》（Nature）杂志专刊——Big data: The next Google,第一次正式提出“大数据”概念
- 2011年2月1日
  - 《科学》（Science）杂志专刊——Dealing with data，通过社会调查的方式，第一次综合分析了大数据对人们生活造成的影响，详细描述了人类面临的“数据困境”
- 2011年5月
  - 麦肯锡研究院发布报告——Big data: The next frontier for innovation, competition, and productivity,第一次给大数据做出相对清晰的定义：“大数据是指其大小超出了常规数据库工具获取、储存、管理和分析能力的数据集。”

原文：“Big data” refers to datasets whose size is beyond the ability of typical database software tools to capture, store, manage, and analyze.

1.1.2 大数据“4V”特征

体量大（Volume）

从2013年至2020年，人类的数据规模将扩大50倍，每年产生的数据量将增长到44万亿GB，相当于美国国家图书馆数据量的数百万倍，且每18个月翻一番。

速度快（Velocity）

随着现代感测、互联网、计算机技术的发展，数据生成、储存、分析、处理的速度远远超出人们的想象力，这是大数据区别于传统数据或小数据的显著特征。

4 V 特征

种类多（Variety）

大数据数据来源广、维度多、类型杂，各种机器仪表在自动产生数据的同时，人自身的生活行为也在不断创造数据；不仅有企业组织内部的业务数据，还有海量相关的外部数据。

价值大密度低（Value）

大数据有巨大的潜在价值，但同其呈几何指数爆发式增长相比，某一对象或模块数据的价值密度较低，这无疑给我们开发海量数据增加了难度和成本。

5V

准确性(Veracity)

6V

动态性(Vitality)

7V

可视化(Visualization)

8V

合法化(Validity)

1.2 大数据的技术支撑

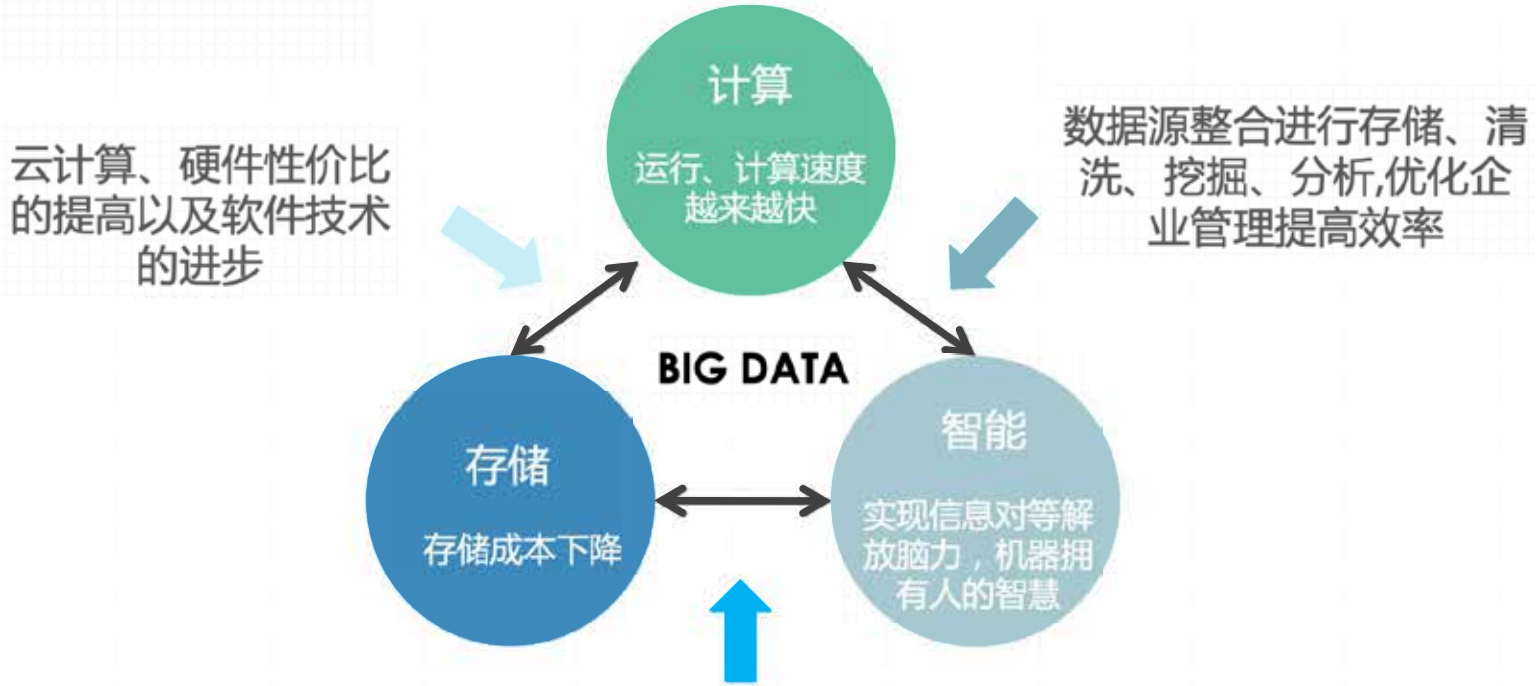
计算
运行、计算速度越来越快
云计算、硬件性价比的提高以及软件技术的进步
数据源整合进行存储、清洗、挖掘、分析,优化企业管理提高效率
BIG DATA
存储
存储成本下降
智能
实现信息对等解放脑力，机器拥有人的智慧
智能设备、传感器的普及，推动物联网、人工智能的发展

- **存储：存储成本的下降**

云计算出现之前	云计算出现之后
云计算出现之前，数据存储的成本高昂。 例如，公司要建设网站，需购置和部署服务器，安排人员维护，保证数据存储的安全性和数据传输畅通性，定期清理数据，腾出空间以便存储新的数据，机房整体的人力和管理成本都很高。	云计算出现后，数据中心的出现降低了公司计算和存储成本。 例如，公司现在要建设网站，不需要去购买服务器，不需要去雇用技术人员维护服务器，可以通过租用硬件设备的方式解决问题。

存储成本的下降，也改变了大家对数据的看法，更加愿意把1年、2年甚至更久远的历史数据保存下来，有了历史数据的沉淀，才可以通过对比，发现数据之间的关联和价值。正是由于存储成本的下降，才能为大数据搭建最好的基础设施。

- **计算：运算速度越来越快**

  - 海量数据从原始数据源到产生价值，期间会经过存储、清洗、挖掘、分析等多个环节，如果计算速度不够快，很多事情是无法实现的。
    - 分布式系统基础架构Hadoop的出现，为大数据带来了新的曙光
    - HDFS为海量的数据提供了存储
    - MapReduce则为海量的数据提供了并行计算，从而大大提高了计算效率
    - Spark、Storm、Impala等各种各样的技术进入人们的视野

- **智能：机器拥有理解数据的能力**

■ 大数据带来的最大价值就是“智慧”，大数据让机器变得有智慧，同时人工智能进一步提升了处理和理解数据的能力

1	谷歌AlphaGo大胜世界围棋冠军李世石
2	阿里云小Ai成功预测出《我是歌手》的总决赛歌王
3	iPhone上智能化语音机器人Siri
4	微信上与大家聊天的微软小冰

重庆大学 CHONGQING UNIVERSITY

1.3 大数据的意义

美国著名管理学家爱德华·戴明所言：“我们相信上帝。除了上帝，任何人都必须用数据来说话。”

“In God we Trust, all others bring data!”

（1）有数据可说

在大数据时代，“万物皆数”，“量化一切”，“一切都将被数据化”。人类生活在一个海量、动态、多样的数据世界中，数据无处不在、无时不有、无人不用，数据就像阳光、空气、水分一样常见，好比放大镜、望远镜、显微镜那般重要。

（2）说数据可靠

大数据中的“数据”真实可靠，它实质上是表征事物现象的一种符号语言和逻辑关系，其可靠性的数理哲学基础是世界同构原理。世界具有物质统一性，统一的世界中的一切事物都存在着时空一致性的同构关系。这意味着任何事物的属性和规律，只要通过适当编码，均可以通过统一的数字信号表达出来。

风马牛可相及

在大数据背景下，因海量无限、包罗万象的数据存在，让许多看似毫不相干的现象之间发生一定的关联，使人们能够更简捷、更清晰地认知事物和把握局势。大数据的巨大潜能与作用现在难以进行估量，但揭示事物的相关关系无疑是其真正的价值所在。

经典案例

（1）啤酒与尿布

（2）谷歌与流感

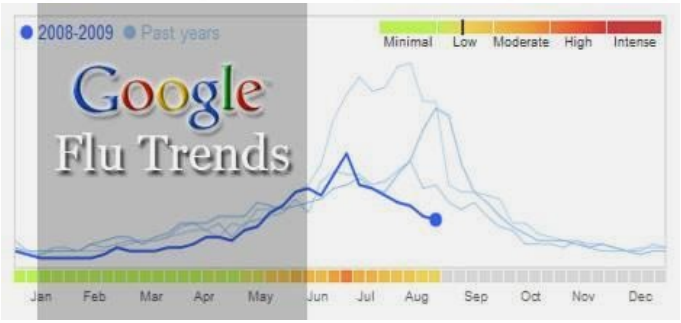

沃尔玛（WALMART ）啤酒与尿布

- 沃尔玛通过分析海量的购物小票数据发现，啤酒与尿布经常同时被购买。
- 背后的消费心理学：在美国很多有婴儿的家庭中，通常是母亲在家照顾婴儿，年轻的父亲下班后去超市买尿布。父亲在买尿布的同时，也会顺手为自己买些啤酒作为犒劳
- 沃尔玛如何应对？通过将啤酒与尿布并排摆放在一起使二者的销量双双增长

谷歌流感趋势监测系统(Google Flu Trends)

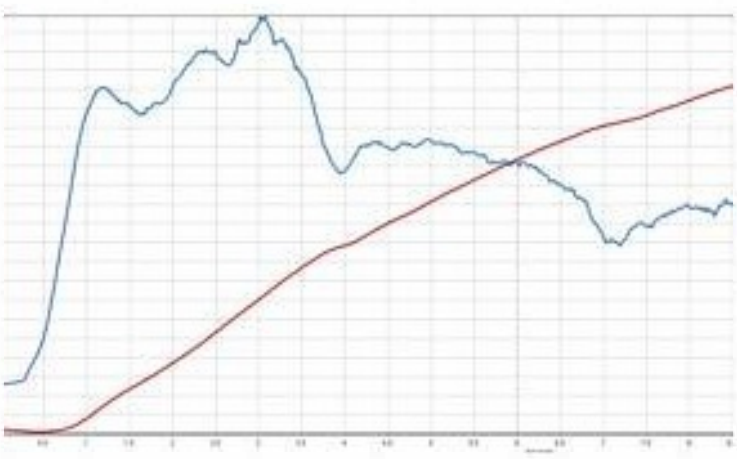

- 美国人在去医院前，喜欢在谷歌搜索类似“流感症状”的词汇
- 谷歌据此预测流感趋势，比美国疾病控制和预防中心(CDC)的流感通报提早一周到10天
- 政府由此可提前准备应对措施

重庆大学 CHONGQING UNIVERSITY

从大数据到大模型：技术融合演进

数据规模增长与算法创新相互驱动，共同推动从"大数据分析"到"大数据智能"的范式跃迁

重庆大学 CHONGQING UNIVERSITY

BD+AI=BDI：大数据智能的内涵

BD 大数据
海量数据资源
分布式存储与计算
数据采集与治理
相关性分析挖掘

+

AI 人工智能
机器学习/深度学习
大语言模型
知识表示与推理
自主决策与生成

=

BDI 大数据智能
数据驱动的智能系统
从感知到认知的跃迁
知识+数据双轮驱动
自主学习与持续进化

大数据智能的四大核心特征

数据驱动：以海量数据为燃料，模型性能随数据量增长而提升
端到端学习：从原始数据直接到决策输出，减少人工特征工程
知识增强：将领域知识与数据驱动方法结合，提升可解释性
持续进化：在线学习与反馈闭环，系统随数据积累不断优化

中国新一代人工智能发展战略明确将"大数据智能"列为五大方向之首，强调数据驱动与知识引导相结合的人工智能新方法。大模型的爆发正是BDI范式的最佳实践——13万亿token训练数据支撑起GPT-4的涌现能力。

大模型时代的数据处理新范式

传统大数据处理范式

数据采集 → ETL清洗 → 数据仓库 → BI报表
以结构化数据为主，批量处理为主
人工特征工程 + 统计分析
关注"发生了什么"（描述性分析）
价值密度低，需大量人工标注

大模型时代数据处理新范式

多模态数据 → 向量嵌入 → 向量数据库 → RAG生成
文本/图像/音频/视频统一处理
自监督预训练 + 指令微调 + RLHF
关注"将要发生什么/如何做"（预测+决策）
高质量数据成为核心竞争力

新范式下的三大关键转变

从"量"到"质"

数据规模不再是唯一指标
高质量、多样化、去重数据
数据质量决定模型上限
合成数据与真实数据融合

从"结构化"到"多模态"

文本、图像、音频、视频
统一向量表示空间
跨模态检索与生成
非结构化数据价值释放

从"分析"到"生成"

不仅洞察规律，更创造内容
RAG检索增强生成
Agent自主决策与执行
数据-模型-应用闭环

大数据概述

CONTENTS

01 大数据概念与意义
Background

02 大数据的来源
Origin

03 大数据的应用
Application

04 大数据的处理方法
Processing data

重庆大学 CHONGQING UNIVERSITY

2.1 摩尔定律

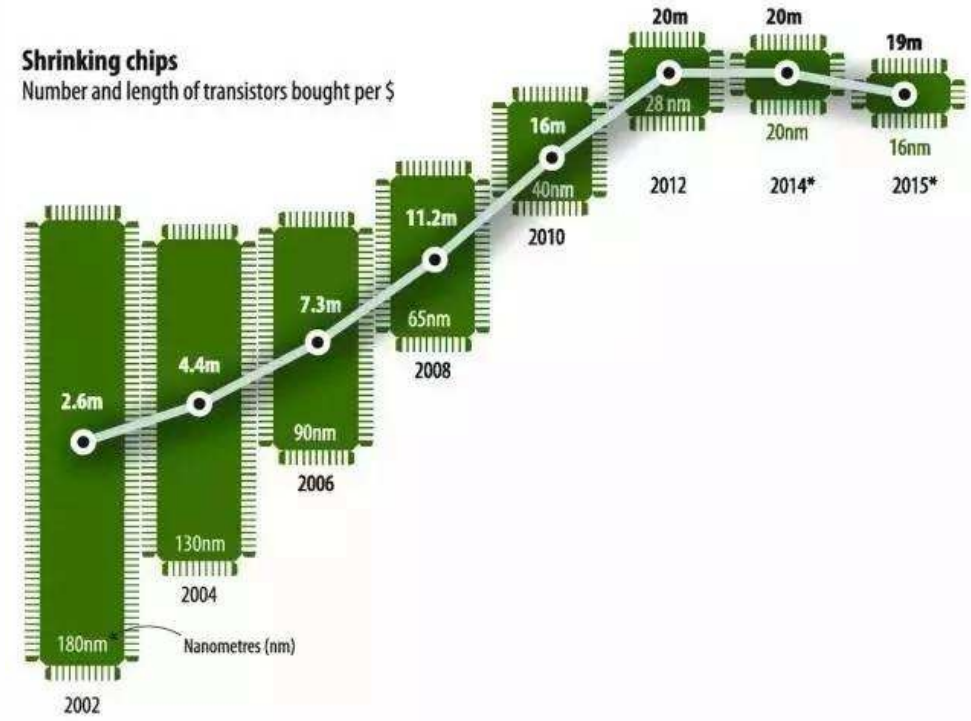

大数据到底有多大？

互联网每天产生的全部内容可以刻满6.4亿张DVD

全球每秒发送290万封电子邮件，一分钟读一篇的话，足够一个人昼夜不停地读5.5年

Google每天需要处理24PB的数据

每天会有2.88万个小时的视频上传到YouTube，足够一个人昼夜不停地观看3.3年

网民每天在Facebook上要花费234亿分钟，被移动互联网使用者发送和接收的数据高达44PB

Twitter上每天发布5000万条消息，假设10秒就浏览一条消息，足够一个人昼夜不停地浏览16年

数据存储量大、计算量大（Volume）

2020年，中国产生的数据总量8.5ZB，全球的数据总量预计40ZB。若以光盘存储，其总重量相当于424艘满载的尼米兹航空母舰。

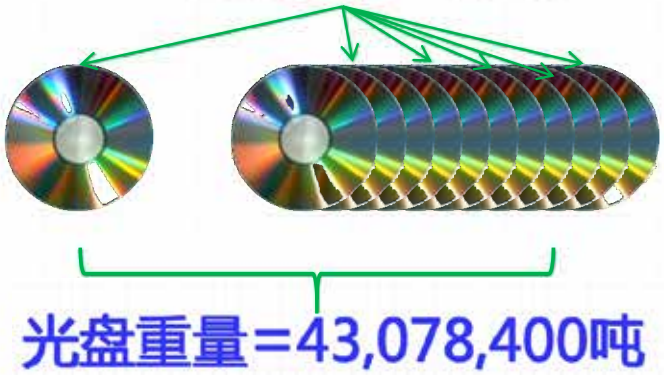

424艘尼米兹号航母重量

(101,600吨)

大数据的复杂性：结构化数据+非结构化数据，类型多+结构复杂

可视：结构化资料 15%

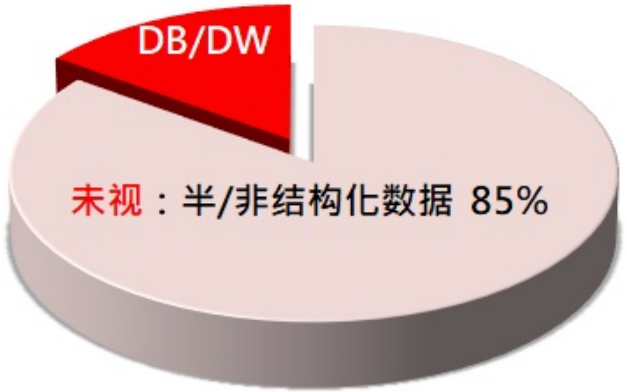

主管们看的战略数字仪表板，其实是残缺的…

非结构化数据更多没有被有效处理、分析和利用，只是被保存了、展示了、检索了

行业结构化大数据，TB级

政务大数据

电力大数据

电信大数据

税务大数据

银行大数据

沃尔玛大数据

…

电信营运商记录的数据

▪终端信息. 节点：DM DE	位置信息. 节点：LBS 系统等	互联网行为 节点：GGSN 等
▪终端品牌； 终端价格； 发布时间； OS 版本； 网络支持； 屏幕尺寸； GPS 功能； Wifi 支持； 摄像头； 等等	用户位置（工作时间）； 用户位置（工作时间之外；娱乐区中的用户频率位置； 不同地点的用户行为（与其它数据源合作）； 用户的社会身份（通过社区分析）	网上冲浪时间 网上冲浪技术（TD、GPRS、EDGE 等） 最喜爱的网站 网络行为（下载、视频、游戏） 社交网络的使用（QQ、微信、博客等） 数据量和时间分配 消费行为（淘宝、JD、VIP 等）

大数据应用：数据统计分析、数据挖掘

互联网大数据

重庆大学 CHONGQING UNIVERSITY

■行为分析

- 综合门户
- 新闻APP
- 社交APP
- 娱乐APP
- 音乐APP
- 体育APP
- 网购APP
- 旅行APP
- 招聘APP
- 游戏APP
- ……

交互信息
痕迹信息

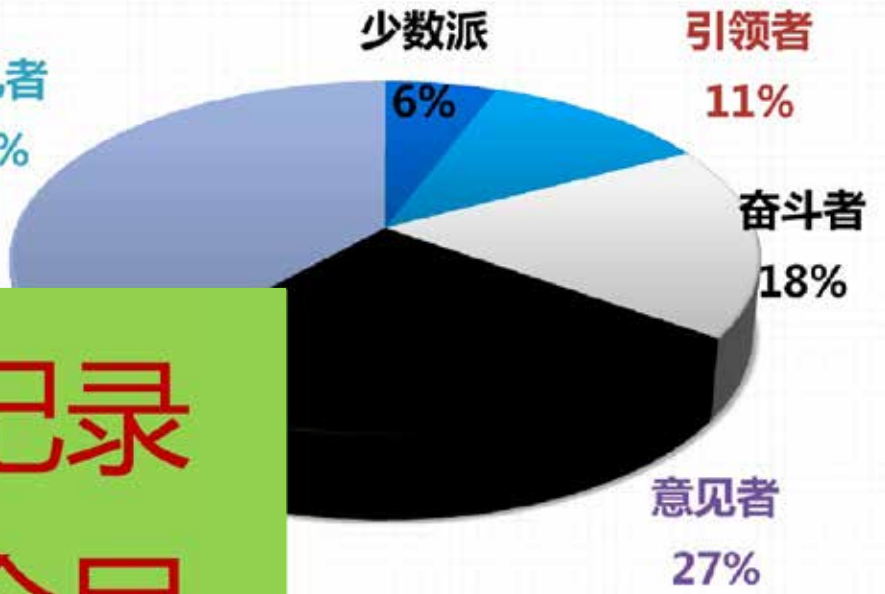

全民记录
记录全民

……

关注焦点　人群分类

网民喜好　生活习惯　人性分析

核心技术：自然语言处理　语义分析　机器学习　垂直搜索

科学大数据：上帝粒子寻找

欧洲强子对撞机：实验装置总长**26.7**公里，总耗资约**100亿**美金；

瞬间输出能量超全球电力千倍

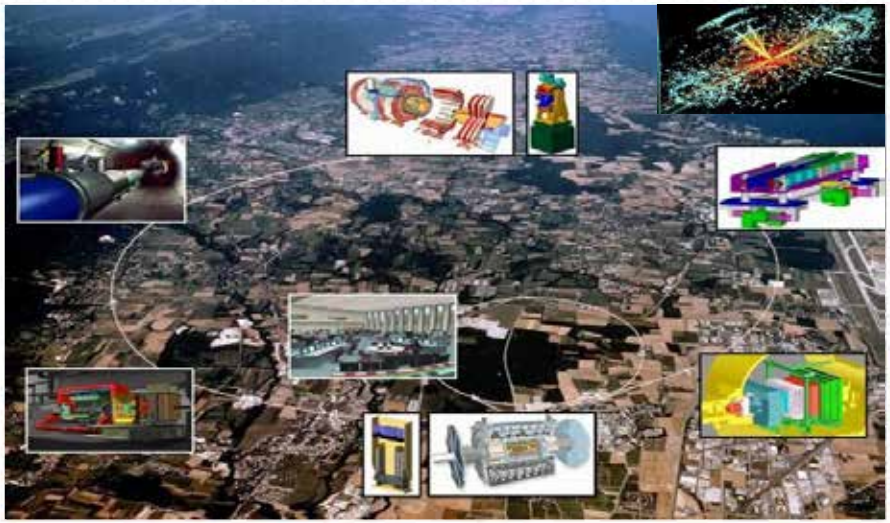

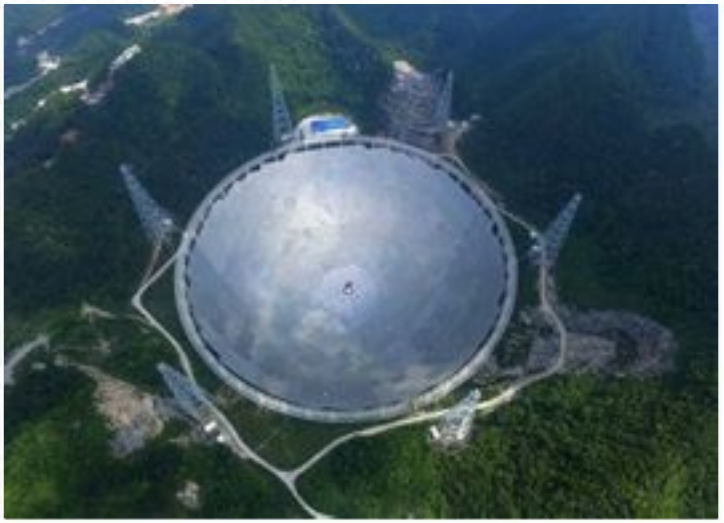

如何发现上帝粒子**希格斯玻色子**：

（1）记录碰撞产生的粒子参数：身份、能量、方向

每秒3~6GB数据，一年20PB

（2）从海量的实验数据中去找

（1）传输：近40G/秒，每年近90PB

（2）处理：处理后的数据量10-15PB

（3）计算：处理能力200万亿次/秒

（4）未来ZB级

实时大数据、流式大数据

城市交通流实时数据

飞机飞行监控实时数据

火箭卫星发射测控数据

（1）数据量大、计算需求量大

（2）有时效性，需要及时处理

（3）有时空关系

城市交通实时优化（单个数据价值小，时效性强）

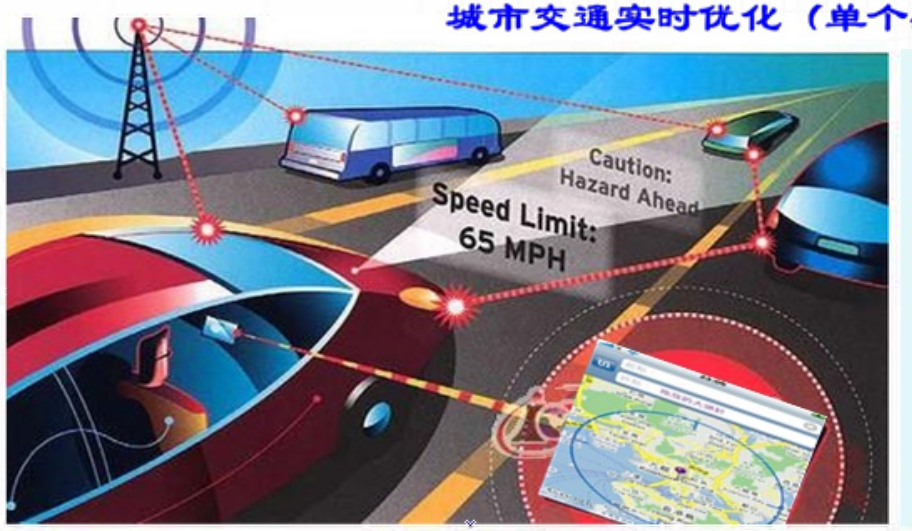

（1）实时路况计算

（2）实时信息通告

（2）实时导航

（4）实时调度

（5）实时红绿灯控制

2 大数据来源

智能终端拍照、拍视频

发微博、发微信

淘宝网 Taobao.com

其他互联网数据

来自“大人群”泛互联网数据

来自大量传感器的机器数据

科学研究及行业多结构专业数据

随着人类活动的进一步扩展，数据规模会急剧膨胀，包括金融、汽车、零售、餐饮、电信、能源、政务、医疗、体育、娱乐等在内的各行业累积的数据量越来越大，数据类型也越来越多、越来越复杂，已经超越了传统数据管理系统、处理模式的能力范围，于是“大数据”这样一个概念才会应运而生

2.2 大数据来源分类

01 按产生数据的主体划分

- **少量企业应用产生的数据**

  如关系型数据库中的数据和数据仓库中的数据等

- **大量人产生的数据**

  如推特、微博、通信软件、移动通信数据、电子商务在线交易日志数据、企业应用的相关评论数据等

- **巨量机器产生的数据**

  如应用服务器日志、各类传感器数据、图像和视频监控数据、二维码和条形码（条码）扫描数据等

2.2 大数据来源分类

02 按数据来源的行业划分

- **以 BAT 为代表的互联网公司**
  - 百度公司数据总量超过了千PB级别，阿里巴巴公司保存的数据量超过了百PB级别，腾讯公司总存储数据量经压缩处理仍超过了百PB级别，数据量月增加达到10%
- **电信、金融、保险、电力、石化系统**
  - 电信行业数据年度用户数据增长超过10%，金融每年产生的数据超过数十PB，保险系统的数据量也超过了PB级别，电力与石化方面，仅国家电网采集获得的数据总量就达到了数十PB，石油化工领域每年产生和保存下来的数据量也将近百PB级别

2.2 大数据来源分类

02 按数据来源的行业划分

- **气象、地理、政务等领域**
  - 中国气象局保存的数据将近10PB，每年约增数百TB；各种地图和地理位置信息每年约数十PB；政务数据则涵盖了旅游、教育、交通、医疗等多个门类，且多为结构化数据
- **制造业和其他传统行业**
  - 制造业的大数据类型以产品设计数据、企业生产环节的业务数据和生产监控数据为主。其中产品设计数据以文件为主，非结构化，共享要求较高，保存时间较长；企业生产环节的业务数据主要是数据库结构化数据，而生产监控数据则数据量非常大。

2.2 大数据来源分类

03 按数据存储的形式划分

- 大数据不仅仅体现在数据量大，还体现在数据类型多。仅有20%左右属于结构化的数据，80%的数据属于社交网络、电子商务等领域等非结构化数据

  - **结构化数据**：简单来说就是数据库，如企业ERP、财务系统、医疗HIS数据库、教育一卡通、政府行政审批、其他核心数据库等数据

  - **非结构化数据**：包括所有格式的办公文档、文本、图片、XML、HTML、各类报表、图像和音频、视频信息等数据

2.2 大数据来源分类

04 常用的大数据获取途径

■系统日志采集

- 使用海量数据采集工具，用于系统日志采集，如Hadoop的Chukwa、Cloudera等，采用分布式架构，能满足大数据的日志数据采集和传输需求

■互联网数据采集

- 通过爬虫等获取数据信息，可以数据从网页中抽取出来并存储。除网站中包含的内容之外，还可以使用DPI或DFI等带宽管理技术实现对数据的采集

■与数据服务机构进行合作

- 数据服务机构通常具备规范的数据共享和交易渠道，人们可以在平台上快速、明确地获取自己所需要的数据。

■APP移动端数据采集

- APP中的SDK插件可以将用户使用APP的信息汇总给指定服务器。单个APP用户规模有限，数据量有限；但数十万APP用户，获取的用户终端数据和部分行为数据也会达到数亿的量级

价值密度低(Value)

- 浪里淘沙又弥足珍贵。一部1小时的视频，在连续不间断的监控中，有用数据可能仅有一二秒。

- 如何通过强大的机器算法更迅速地完成数据的价值“提纯”成为目前大数据背景下亟待解决的难题。

交叉碰撞降低筛选数据成本

博学 笃志 切问 审慎 明辨 慎思 尚俭 戒奢 崇朴 黜华
勤学业 爱国家

大平台+简单算法提纯价值

利用各种大数据分析工具，比如Hadoop、SPSS和R，可从各种类型的数据中快速获得高价值的信息，这一点和传统的数据分析技术有着本质的区别。

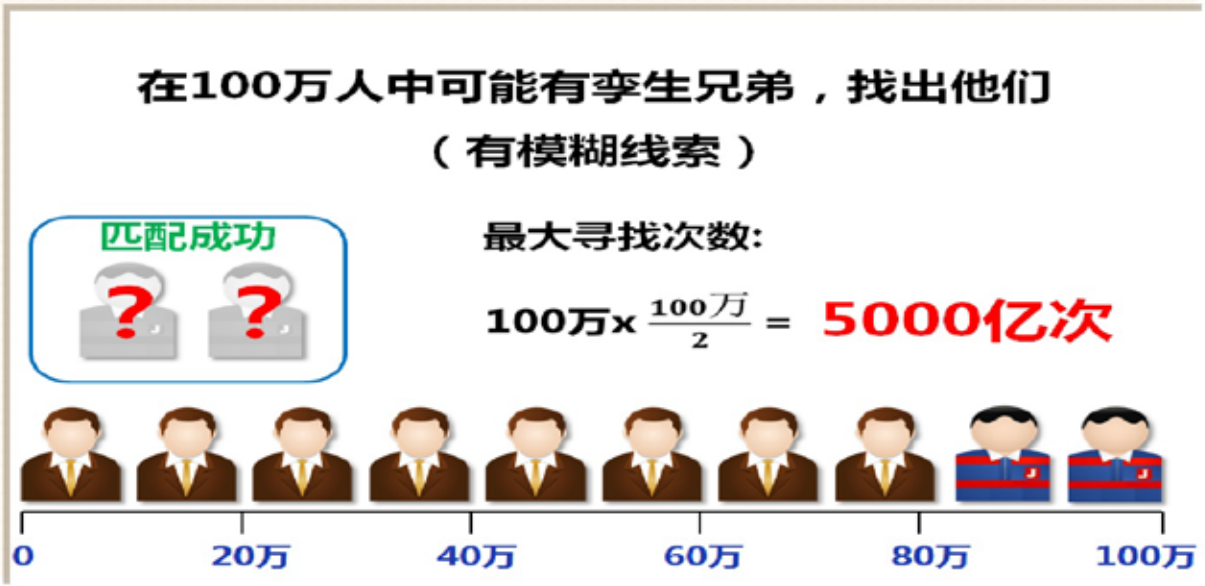

大数据概述

CONTENTS

01 大数据概念与意义
Background

02 大数据的来源
Origin

03 大数据的应用
Application

04 大数据的处理方法
Processing data

面向海量分子结构的分析成为当前新药研制的主要手段

其核心技术的对图模型描述的海量分子结构的模式分析

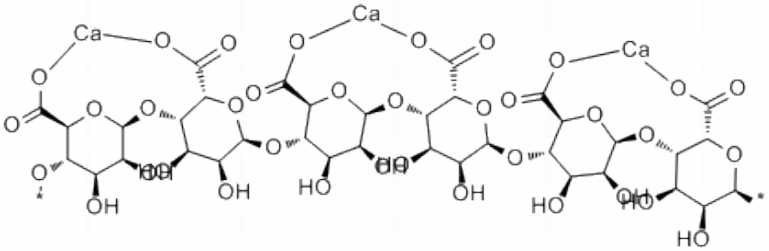

面向基因数据的挖掘是生物信息学的基础

生物信息数据的类型

基因序列、蛋白质相互作用网络、蛋白质三维结构、...

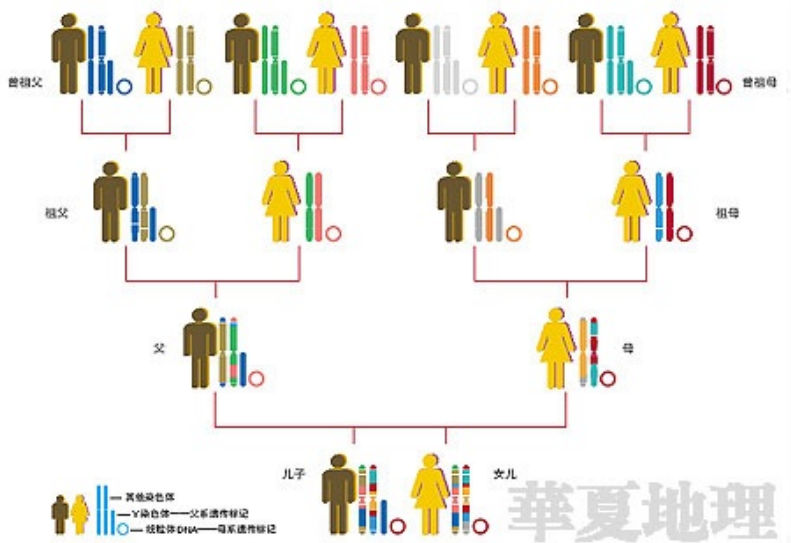

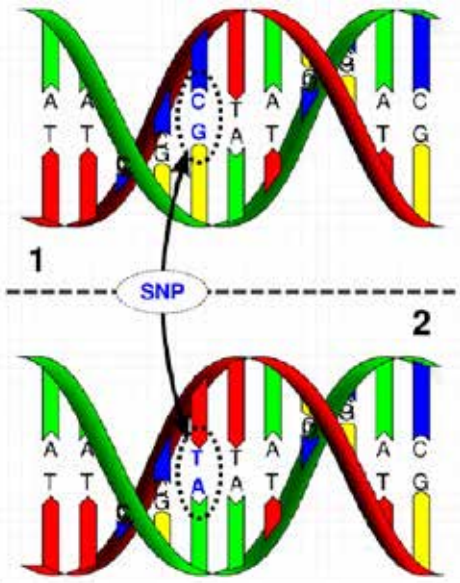

基因中能发现什么？转录结合变化？

面向网络用户行为的分析和网页内容的挖掘是WEB应用企业的核心技术

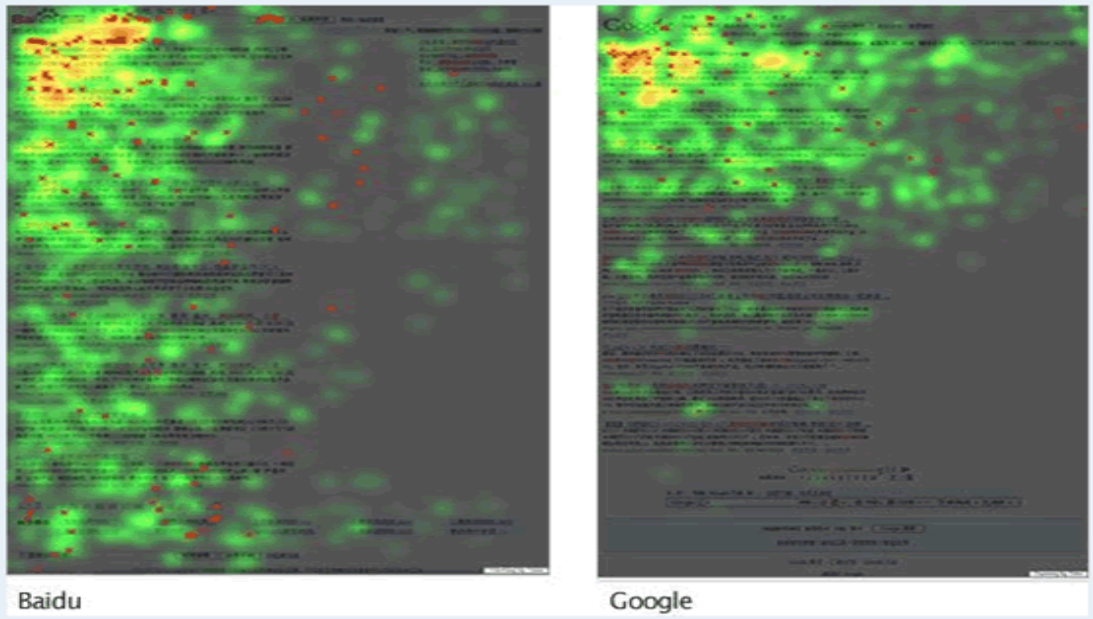

关注点分析

说明：鼠标点击越多的地方，亮度越高

城市管理

大数据技术可以了解经济发展情况、各产业发展情况、消费支出和产品销售情况等，依据分析结果，科学地制定宏观政策，平衡各产业发展，避免产能过剩，有效利用自然资源和社会资源，提高社会生产效率。

大数据技术也能帮助政府进行支出管理，透明合理的财政支出将有利于提高公信力和监督财政支出。

- 美国佛罗里达州，通过对高速口收费站数据（约为110万条）比对分析发现当地的3900辆警车在13个月的时间里共发生了5100多次的超速行驶记录。进一步的筛选分析发现，警车超速时间竟然大部分都发生在上下班时间

- 翔实的纪录与可信的分析结果引起了当地民众广泛关注，牵扯到超速案件的12个部门近800名警察受到处理，“警察开快车”事件被有效治理和纠正

智慧农业

重庆大学 CHONGQING UNIVERSITY

农业行业

借助于大数据提供的消费能力和趋势报告，政府可为农业生产进行合理引导，依据需求进行生产，避免产能过剩造成不必要的资源和社会财富浪费。

通过大数据的分析将会更精确地预测未来的天气，帮助农民做好自然灾害的预防工作，帮助政府实现农业的精细化管理和科学决策。

- 2013年孟山都以9.3亿美元收购了加州气候公司Climate Corporation。它通过分析气象、天气、降雨、地质土壤等海量数据，预测未来可能对农业生产造成破坏的各种情况，通过农业大数据信息帮助农民预测作物产量
- 农业大数据的有效利用，既节省了肥料资源，也避免了过量化肥的污染还可通过收集分析降水、温度、土壤种类和作物生长周期信息，帮助农民及时发现和解决农田存在问题

教育行业

信息技术已在教育领域有了越来越广泛的应用，教学、考试、师生互动、校园安全、家校关系等，只要技术达到的地方，各个环节都被数据包裹。

通过大数据的分析来优化教育机制，也可以作出更科学的决策，这将带来潜在的教育革命。

- 南京理工大学教育基金会通过大数据分析，每个月在食堂吃饭超过 60顿、一个月总消费不足420元的，被列为受资助对象。南京理工大学还采取直接将补贴款打入学生饭卡的方式，学生无需填表申请，不用审核

智慧环保——雄安新区天地一体化生态监测治理体系

重庆大学 CHONGQING UNIVERSITY

大气

噪声

辐射

水

土壤

生态监测系统

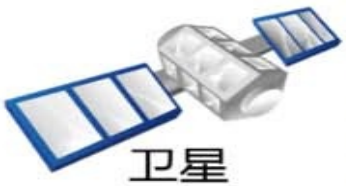

卫星

无人机

地面监测站

监测数据集成共享

生态环境监测大数据平台

国土资源

住房城乡建设

交通运输

水利

农业

卫生

林业

气象

海洋

……

生态环境监测信息发布

环境质量与风险监测预警

生态环境监管执法

耐劳苦 尚俭朴
勤学业 爱国家

2010年，美国西弗吉尼亚州发生死亡29人的矿难，由于该煤矿的监管记录保存完整，每条记录都包括检查的时间、结果、违反的法律条款、处理的意见、罚款的多少、已缴纳的金额、煤矿是否申诉等数据项。

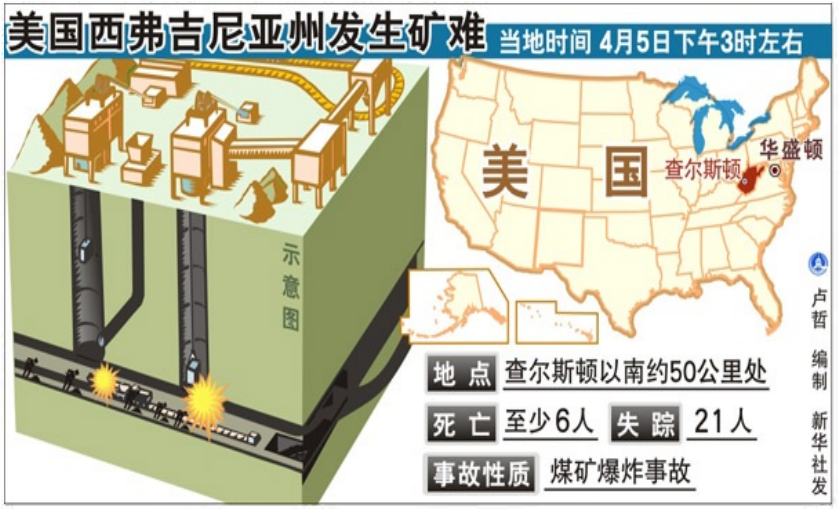

逾千条的监管记录为事故追责提供了重要证据，最终事故认定煤矿安全健康局无监管失职，出事煤矿所属公司应承担主要责任。

- 小松挖掘机上装有GPS卫星定位系统和工作状态无线传输系统
- 小松公司在后台能够看到每台挖掘机的位置、工作时间和挖掘量

智慧金融——传统银行

重庆大学 CHONGQING UNIVERSITY

金融行业

1）银行数据应用场景

利用数据挖掘来分析出一些交易数据背后的商业价值。

2）保险数据应用场景

用数据来提升保险产品的精算水平，提高利润水平和投资收益。

3）证券数据应用场景

对客户交易习惯和行为分析可以帮助证券公司获得更多的收益。

- 汇丰银行在防范信用卡和借记卡欺诈的基础上，利用SAS构建了一套全球业务网络的防欺诈管理系统，为多种业务线和渠道提供完善的欺诈防范
- 该系统通过收集和分析大数据，以更快的信息获取速度挖掘交易的不正当行为，并迅速启动紧急告警

互联网金融

- 利用掌握的大数据和大数据技术，为中小企业提供贷款服务
- 从提出申请，到商户收到贷款，整个过程最快只需三分钟
- 累计贷款总额260亿，单日利息收入100万，坏账率仅千份之三

智慧金融——蚂蚁智能风控

基于传统机器学习的风险控制精度效率不高，蚂蚁金服基于深度学习探索智能风控，提高模型精度和效率。

信用风险 | 骗保风险 | 套现风险 | 欺诈风险

深度图学习

算法
- Geniepath
- HeGNN
- IGNN
- …

框架
- 丰富深度图学习算子
- 支持多种图学习任务

规模
- 十亿节点图学习
- 毫秒响应

数据安全

弱监督学习

无监督学习

迁移学习

....

图深度学习架构

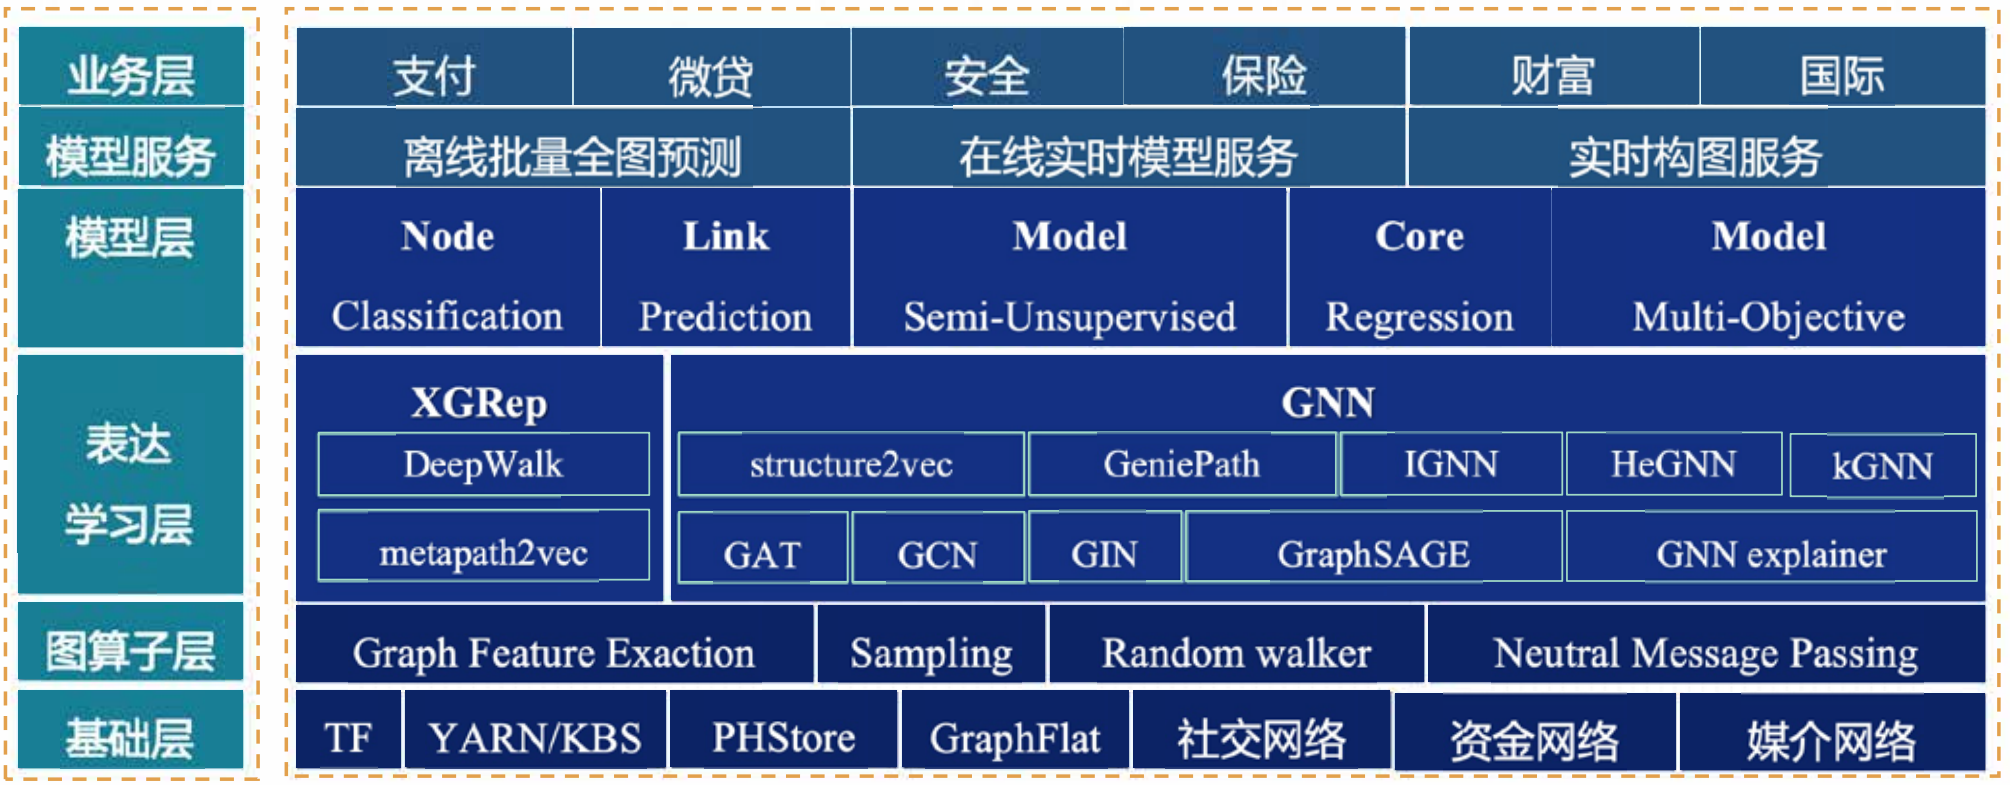
业务层
支付
微贷
安全
保险
财富
国际
模型服务
离线批量全图预测
在线实时模型服务
实时构图服务
模型层
Node
Classification
Link
Prediction
Model
Semi-Unsupervised
Core
Regression
Model
Multi-Objective
表达学习层
XGRep
DeepWalk
metapath2vec
GNN
structure2vec
GeniePath
IGNN
HeGNN
kGNN
GAT
GCN
GIN
GraphSAGE
GNN explainer
图算子层
Graph Feature Exaction
Sampling
Random walker
Neutral Message Passing
基础层
TF
YARN/KBS
PHStore
GraphFlat
社交网络
资金网络
媒介网络

智慧金融——蚂蚁智能风控

落地案例
8%+营销成本节省
2-hops GNN刻画商户 单调线性映射保证
金额度敏感度网络表达 金额敏感度单调性
新增数百亿授信
基于GraphML的企业风险模型体系
五福红包刮刮卡
核销率
4%+
营销活动精准定向
点击率
10%+
线下商户拉新
转化率
20%+
刷脸支付
线下首单
20%+
消费信贷风控
风险区分度
5%+
消费信贷风险画像
新增授信
数十亿+
欺诈商户识别
F1-值
3%+
新注册账户欺诈
资损覆盖
16%+

重庆大学 CHONGQING UNIVERSITY

AI审核：图像识别 & 知识图谱

深度学习图像识别 + 疾病知识图谱

上传材料

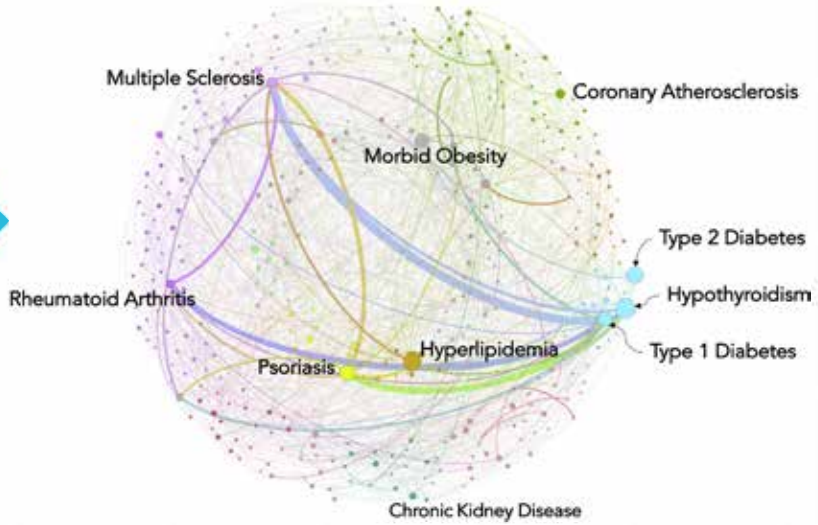

智能审核

相互宝：架构实现

流程

用户上报理赔信息 → 深度学习图像识别 → 知识图谱实体抽取 → 系统快速智能审核

技术支撑

图鹰 金融视觉平台

通用卡证 | 图像分类 | 图像检测

- 案件自动处理率 50%
- AI 自动核赔准备率 99%

蜘蛛 金融知识图谱平台

知识构建 | 知识融合 | 知识推理

- 健康知识图谱包含产品类型 12种
- 在线实时融合推理场景 10+ / 亿级边

赋能大模型

数据来源	说明
维基百科	在线百科,严谨
图书	经典为主的古登堡计划和自助出版平台Smashwords等
杂志期刊	论文：ArXiv等
链接	WebText,Reddit
Common Crawl	开源项目,爬取互联网所有数据
GitHub	程序员聚集地
合计	• 700 多GB,约有19万套四大名著的阅读量 • 5 000亿左右的token数量。（13万亿token:gpt4) • 100个标记大约等于75个英语单词

训练语料（gpt-3）

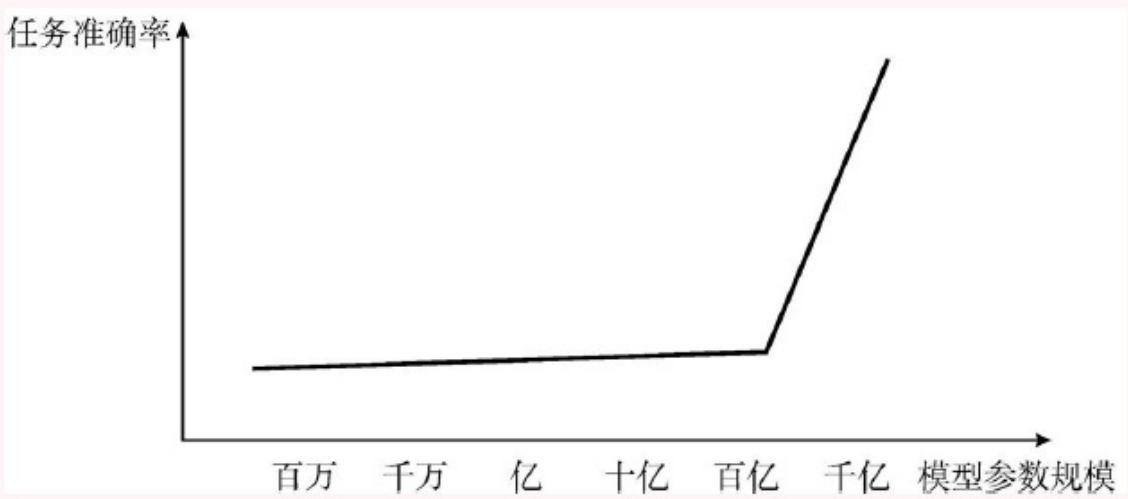

典型的新技能学习曲线：规模到达临界点之后才会迅速增长

模型参数：1.8万亿参数（GPT-4）

GPT-4o
上下文窗口大小：8192个token(标记)

大模型时代的数据需求：从4V到新维度

传统大数据4V特征

Volume 规模大

TB/PB/EB级数据
存储与计算挑战

Velocity 速度快

实时流处理
低延迟响应

Variety 类型多

结构化/半结构化
非结构化数据

Value 价值密度低

海量数据中淘金
相关性挖掘

→

大模型时代新增维度

Veracity 真实性

数据质量与可信度
去噪去重与事实校验

Vector 向量化

语义嵌入表示
向量检索与RAG

Vision 多模态

文本/图像/音频/视频
跨模态统一理解

Validation 合规性

数据隐私与版权
安全治理与审计

核心观点：数据质量取代数据规模成为大模型时代的核心竞争力

传统大数据时代，"存得下、算得快"是核心挑战；大模型时代，"数据质量决定模型上限"成为共识。研究表明，经过精细清洗的高质量数据（如FineWeb、DCLM）可以用1/10的数据量达到甚至超过海量原始数据的训练效果。

因此，数据治理、数据标注、数据合成和数据合规成为大模型产业链中价值密度最高的环节。

大模型训练数据规模与构成

主流大模型训练数据量对比（万亿 Token）

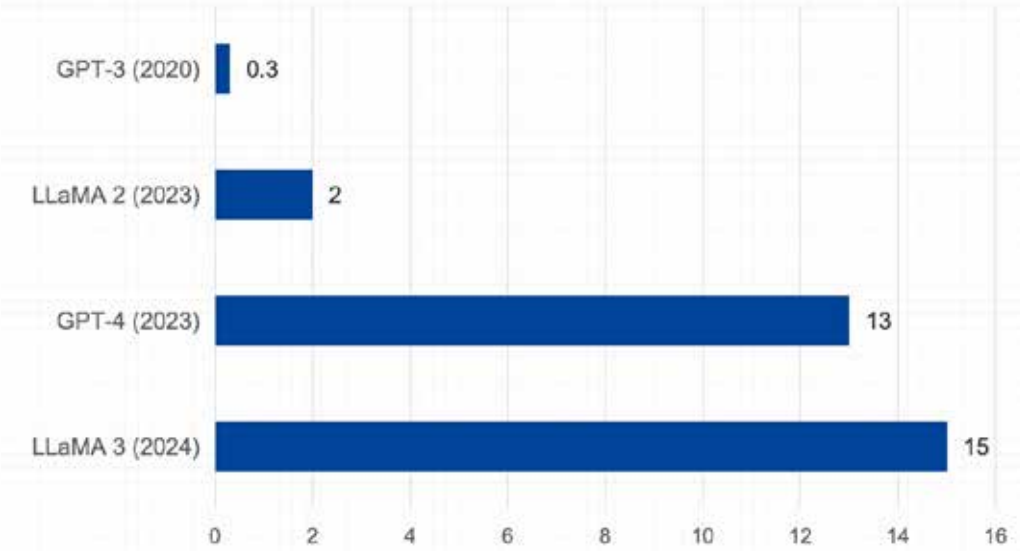

大模型训练数据构成（典型分布）

关键洞察：数据规模四年增长50倍，高质量数据成为稀缺资源

从GPT-3的3000亿Token到LLaMA 3的15万亿Token，训练数据规模四年增长约50倍。GPT-4约1.8万亿参数、13万亿Token训练量，估算训练成本超1亿美元。
数据构成上，网页文本占比最高但质量参差；书籍和学术论文虽占比小但知识密度高；代码数据对逻辑推理能力至关重要。当前行业共识：高质量公开数据即将耗尽，合成数据与私有数据将成为下一阶段竞争焦点。

大数据与大模型的双向赋能

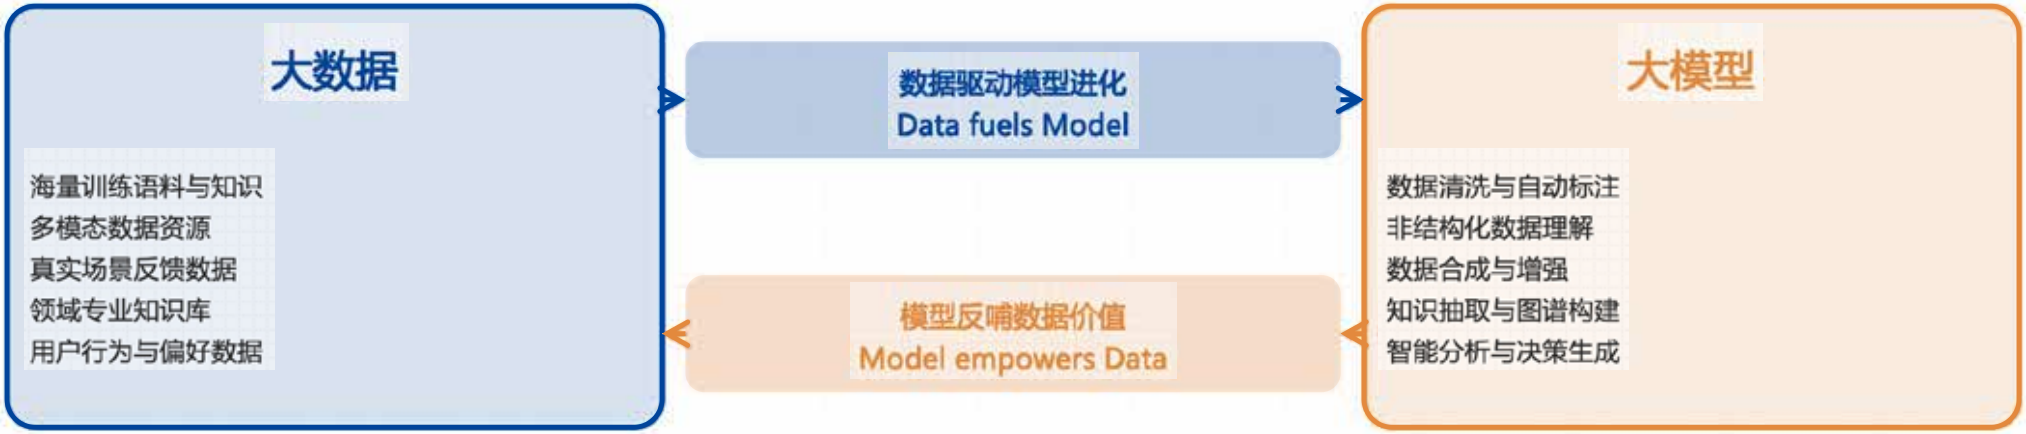

双向赋能的三大闭环

训练闭环
大数据预训练大模型，大模型生成合成数据反哺训练，形成数据-模型协同进化的飞轮效应。

应用闭环
RAG检索增强生成将企业私有数据与大模型结合，实现数据价值的即时释放与智能问答。

治理闭环
大模型自动完成数据分类、脱敏、质量检测，提升数据治理效率，保障数据安全合规。

案例：国内外大模型的数据基础

OpenAI / 国际大模型

GPT-4 数据基础

训练数据：约13万亿Token，覆盖网页、书籍、代码、论文
数据来源：Common Crawl、Books3、GitHub、ArXiv等
关键技术：RLHF人类反馈强化学习，百万级人类标注
多模态：图像数据来自互联网公开图片与授权数据集

LLaMA 3 数据基础

训练数据：15万亿Token，公开数据为主
特点：严格数据过滤与去重，注重高质量推理数据
开源策略：权重公开，推动全球大模型生态发展

国内大模型

百度文心一言 / 阿里通义千问

数据优势：中文语料丰富，搜索/电商/地图等场景数据
百度：搜索数据+知识图谱，中文理解能力突出
阿里：电商数据+通义实验室，多模态与代码能力强
合规要求：数据安全法、个人信息保护法严格约束

字节豆包 / 月之暗面Kimi

字节：抖音/头条海量内容数据，多模态与推荐优势
Kimi：长文本处理特色，支持200万字上下文输入
共同挑战：高质量中文数据稀缺，需加强数据治理

对比启示：数据主权与高质量中文语料是国产大模型的核心竞争力

国际大模型依托英语互联网的海量公开数据，在通用能力上领先；国内大模型在中文理解、本土场景和合规性上具有优势。当前制约国产大模型发展的关键瓶颈不是算力，而是高质量、多样化、合规的中文训练数据。建设中文高质量数据集、完善数据流通机制、加强数据要素市场化，是突破大模型技术瓶颈的战略路径。

大数据技术：采集、存储、管理、计算、分析、智能

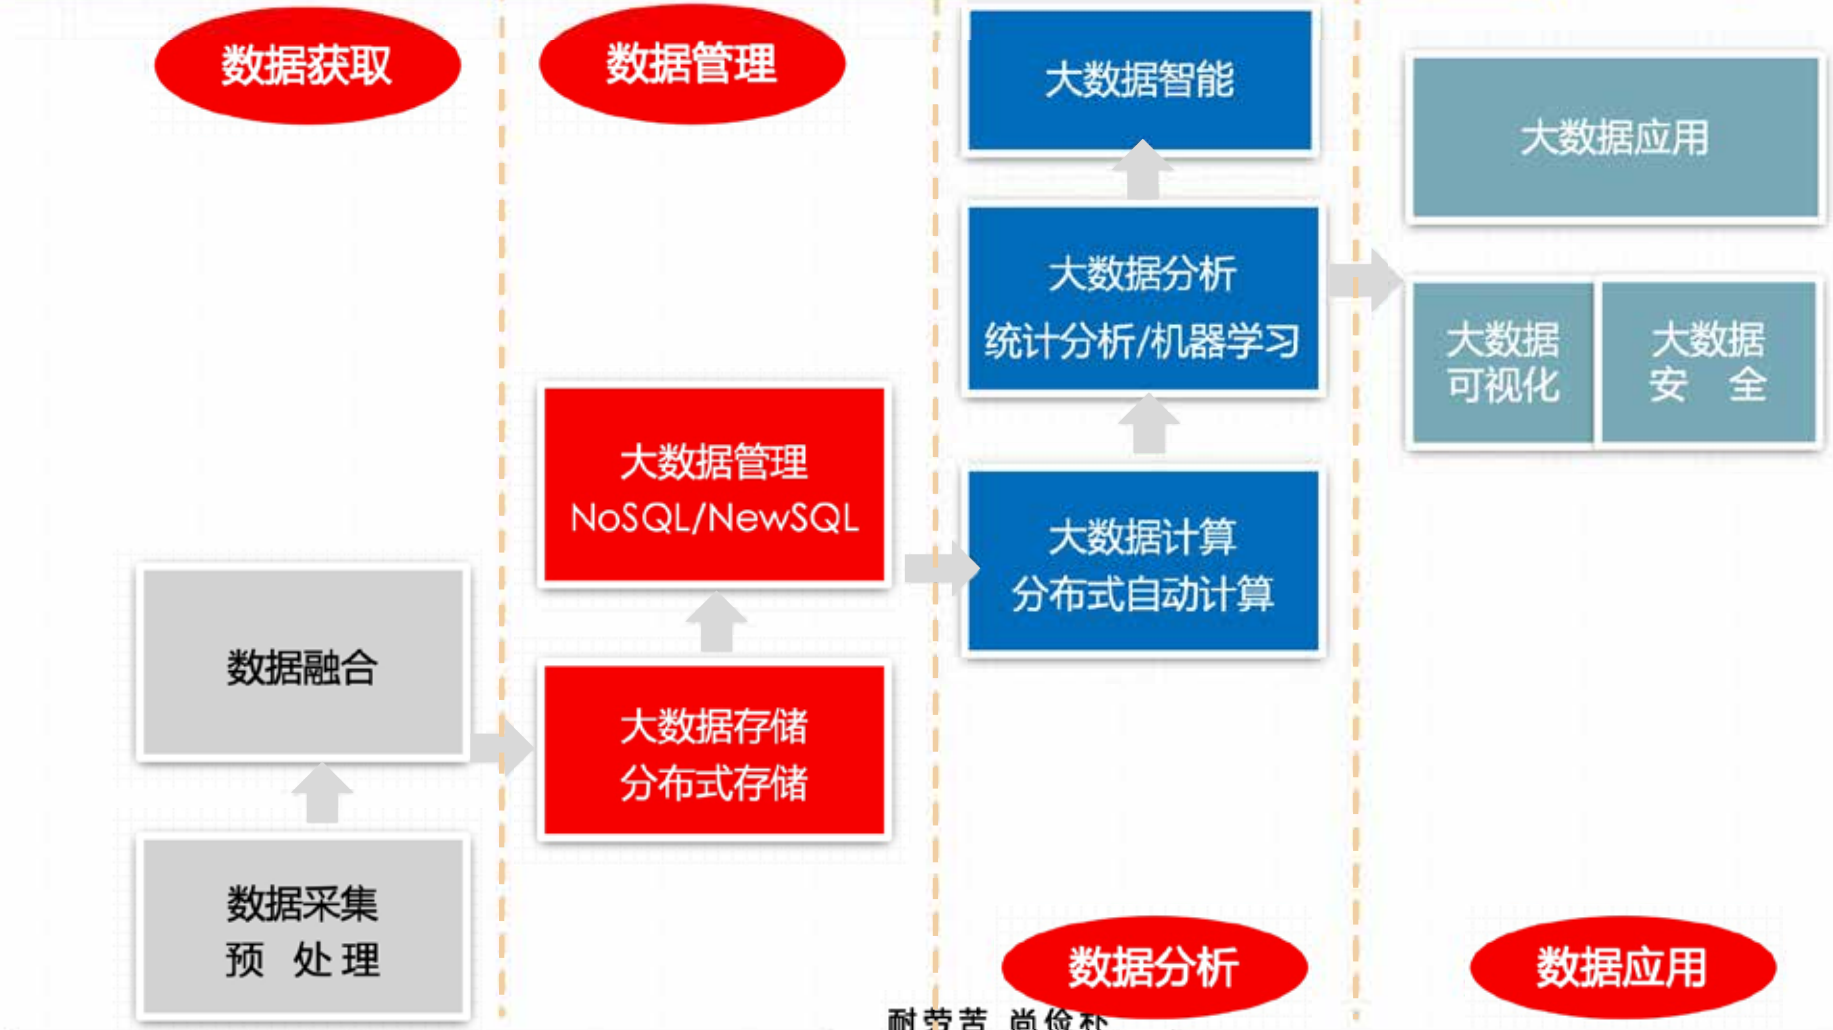

key-value数据库：分布式缓存，大型网络

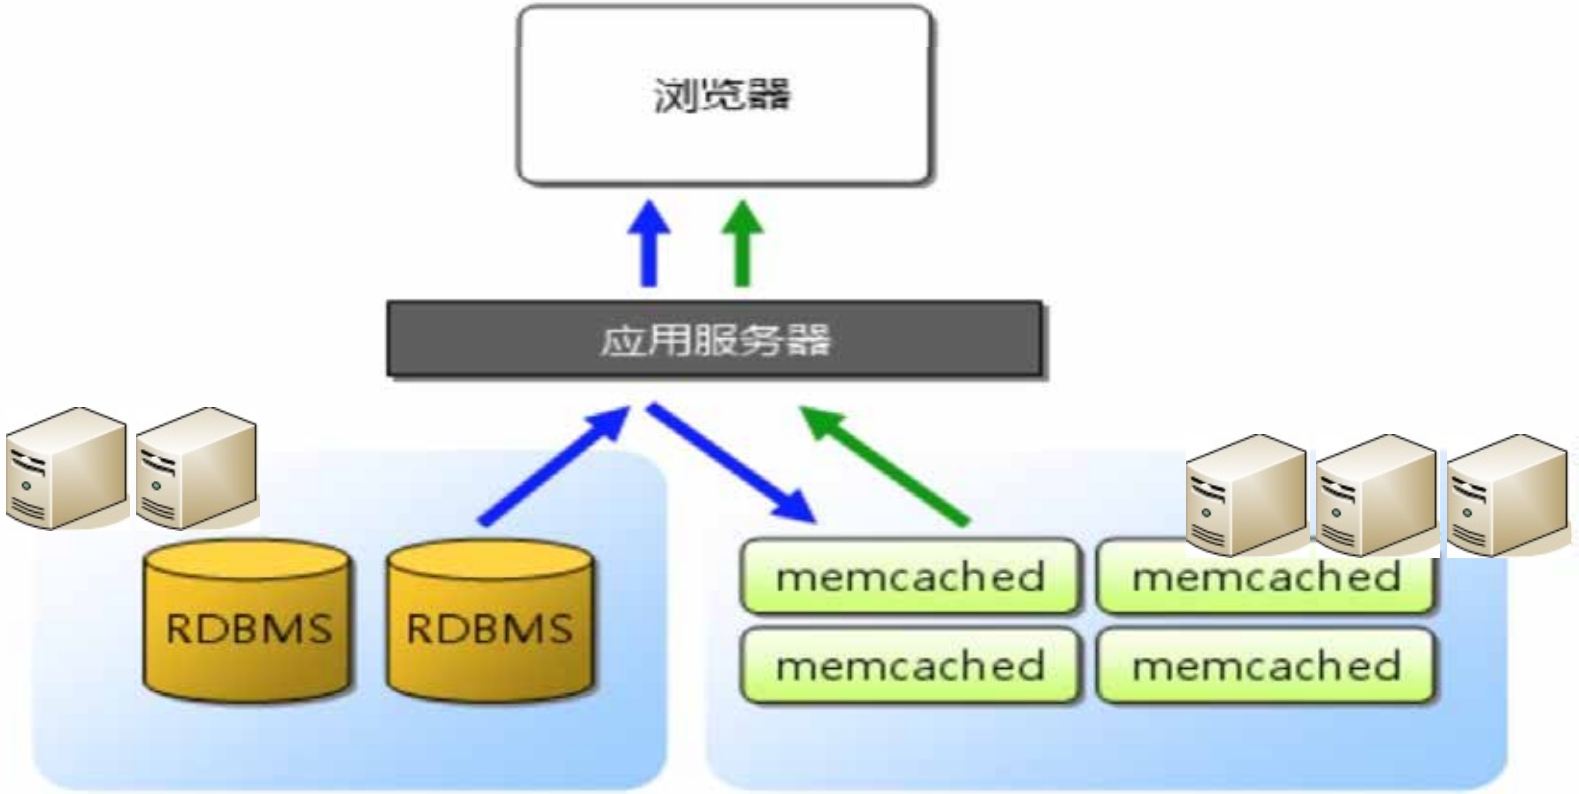

列簇数据库：无模式-自由模式数据库，电商/社交网站

传统SQL数据库
记录属性固定

固定模式：每条记录的属性（字段）是一样的
工资条：姓名，年月，基本工资，绩效工资，…

电商数据
不同商品，属性不同

书籍：书名，作者，出版商，ISBN号…
衣服：品牌，类别（男女童装），尺寸，颜色，…
大衣：
女装：

HBASE：非常流行的列簇数据库，每条记录的属性都可以不一样

图数据库：有关系的数据，社交数据，知识图谱

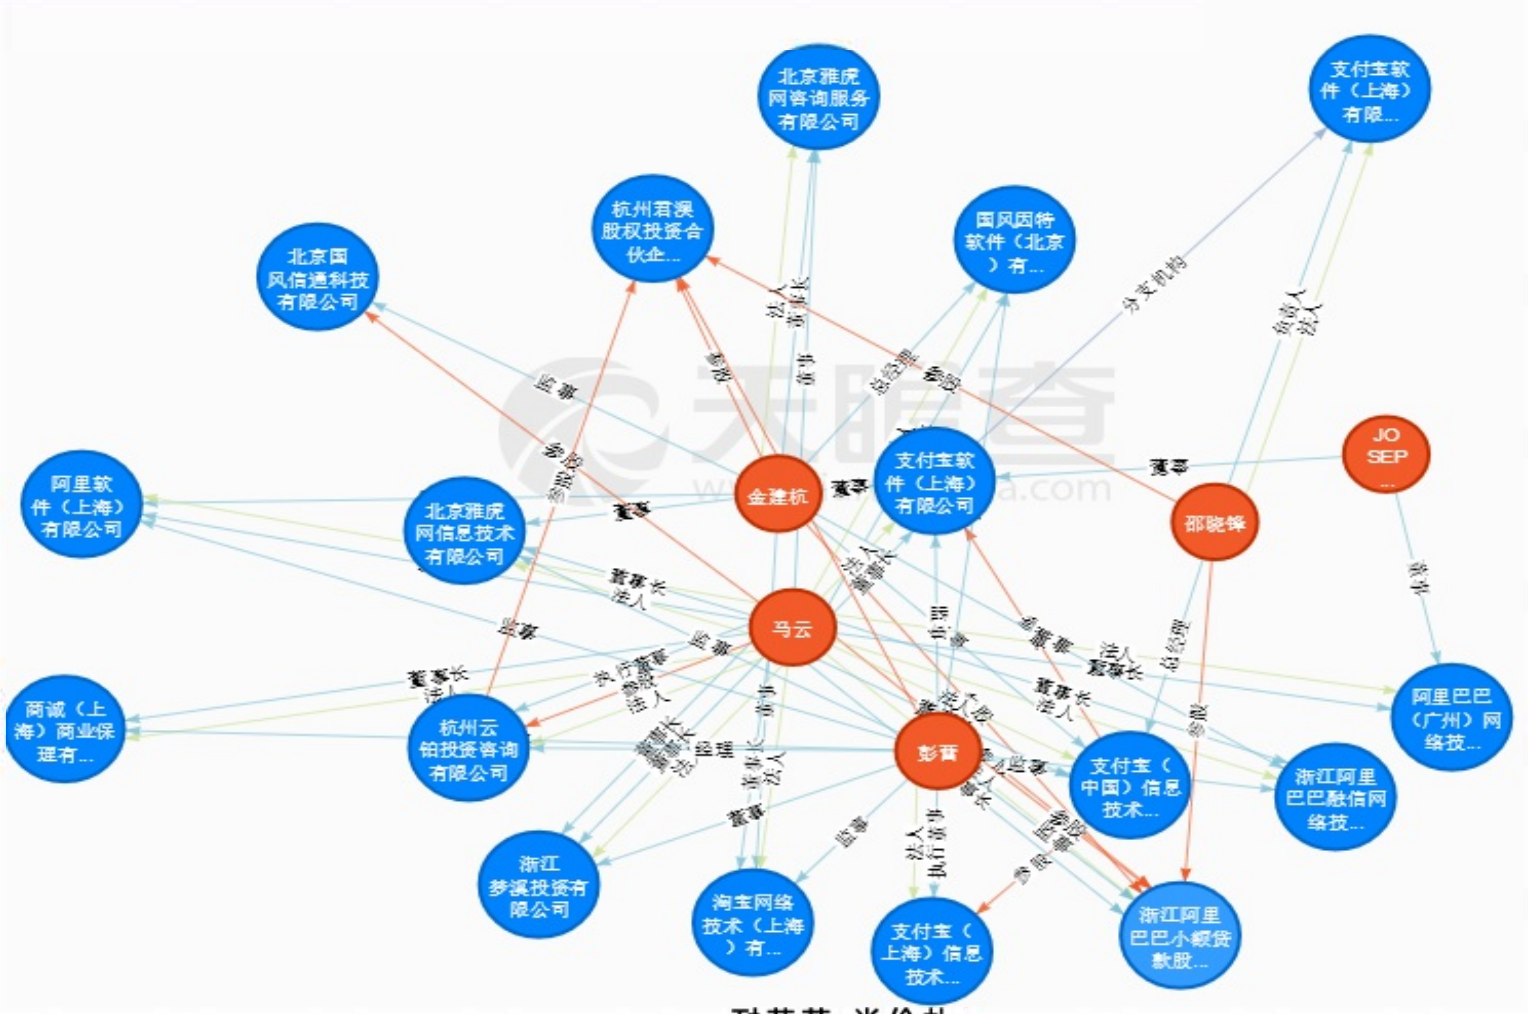

大数据可视化技术：多维数据可视化

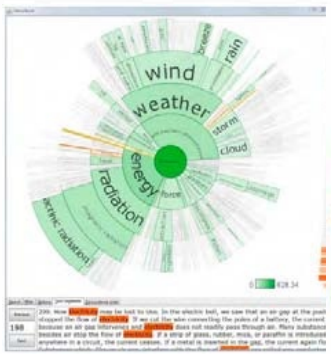

标签数据云

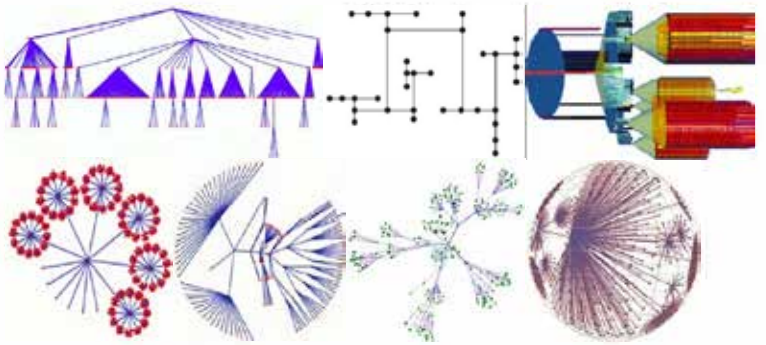

图关系数据可视化

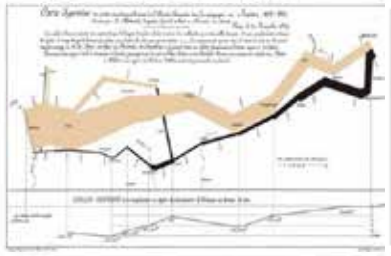

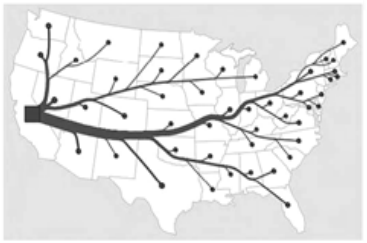

流式地图

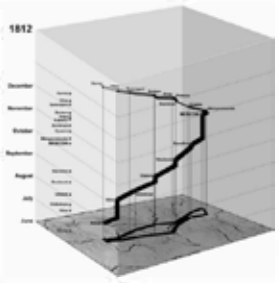

时空立方体

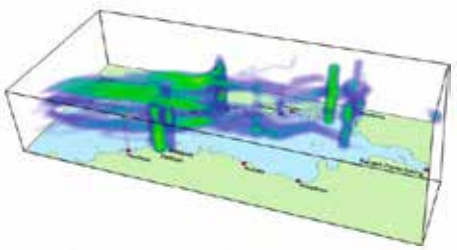

散点图+时空关系

大数据可视化技术：多维数据可视化，仪表盘

大数据思维

（1）大数据成为核心资产

（2）大数据需聚焦应用

（3）大数据融合价值更大

（4）大数据分析侧重相关性分析

（5）大数据最重要作用是预测

（6）大数据促进智慧型应用

（7）重视非结构化大数据

（8）不存在统一的大数据解决方案

（1）(大)数据成为核心资产

在大数据big data概念没有出现之前，（大）数据的价值并没有得到很好的认可

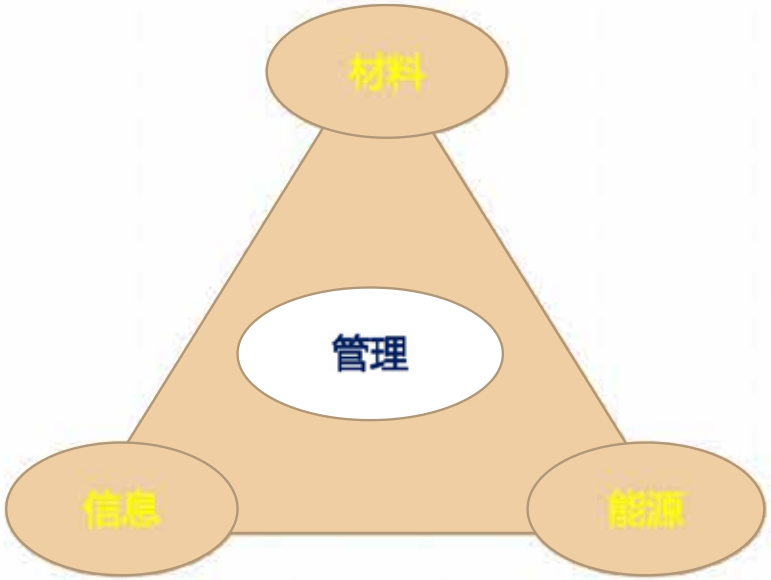

资源三角形的信息并没有真正落地

（1970年,哈佛大学提出）

从资产（资源）的高度认识大数据

2015年国务院发布《促进大数据发展行动纲要》才真正使学术界、产业界重视大数据

（2）大数据需要聚焦应用

重庆大学 CHONGQING UNIVERSITY

从计算角度：大数据是单个系统无法处理的数据
侧重技术

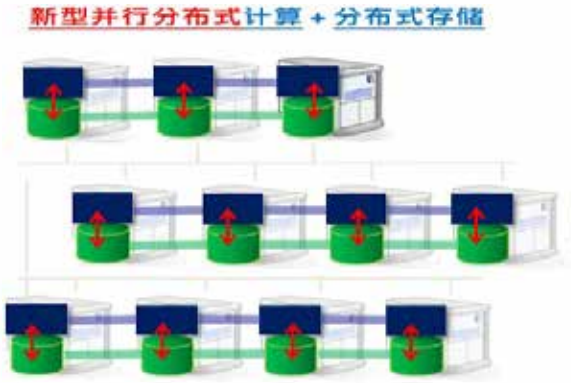

从应用来看：重要的是体现数据的作用和价值

（1）应用驱动、价值引领

（2）数据思维、定量思维

（3）数据融合价值更大

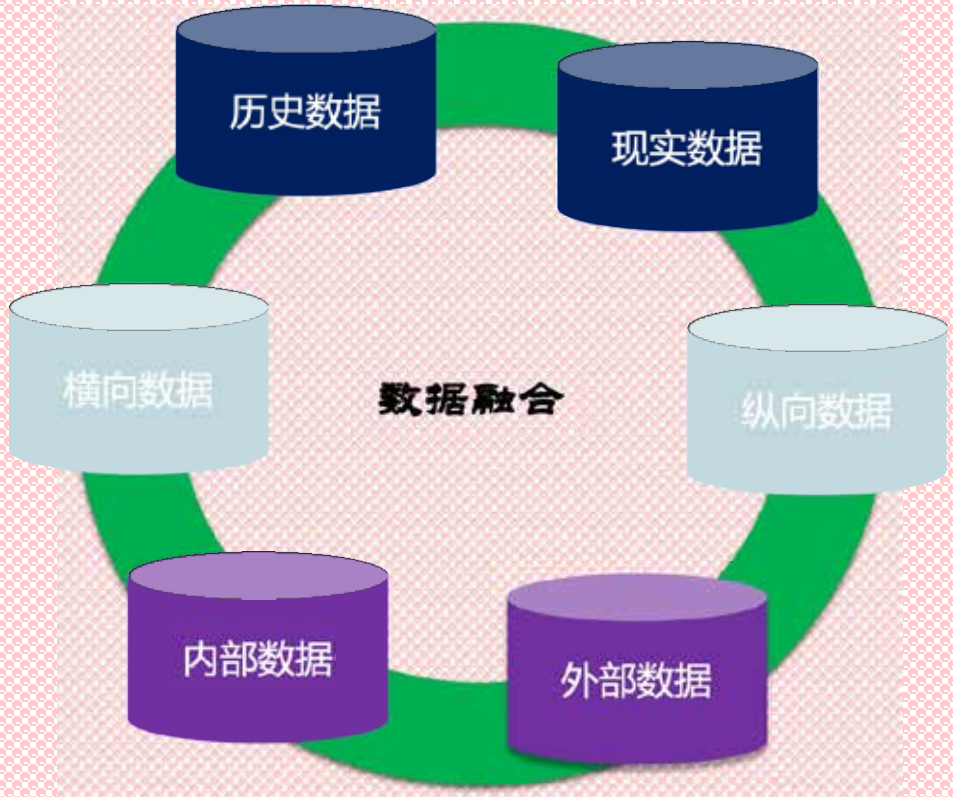

块数据

以区域为单位的数据集合

本质上就是融合数据

（4）大数据分析侧重相关性分析

大数据：全数据，不同于以往的统计分析，直接分析

大数据：因果分析 ⟹ 关联分析

典型例子：啤酒、尿布例子（源自沃尔玛某个商店）

The legend says that a study was done by a retail grocery store. The findings were that men between 30- 40 years in age, shopping between 5pm and 7pm on Fridays, who purchased diapers were most likely to also have beer in their carts. This motivated the grocery store to move the beer isle closer to the diaper isle and wiz-boom-bang, instant 35% increase in sales of both.

大数据：利用数据关系分析来进行主体间的网络关系分析

社交分析

人-机-物网 三元融合分析

（5）大数据最重要作用是预测----美国大选预测

2008年美国总统选举

For the Nate-haters, here's the 538 prediction and actual results side by side pic.twitter.com/jbny4pRX

4:58 AM - 07 Nov 12

- Past 30 years of Election Databases for all states
- Big data + simple algorithm（大数据、简单算法）

（6）大数据促进智慧型应用智能：大数据智能(深度学习)

2011年，Google：16000台电脑模拟了一个人工神经网络，向其输入1000万段随机从YouTube上选取的视频，看看它能学会什么．

运行了10天，涉及参数近十亿个，在完全没有外界干涉的条件下，它“认识了猫”，并从接下来输入的2万张图片中准确找出了猫的照片

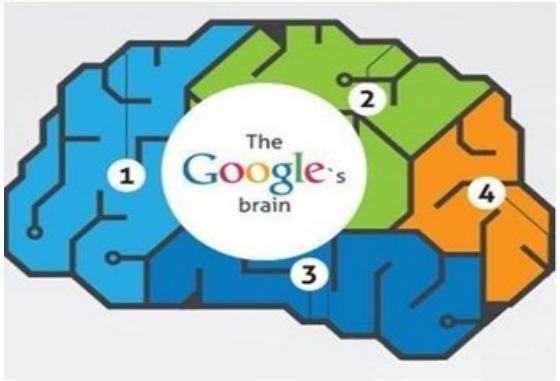

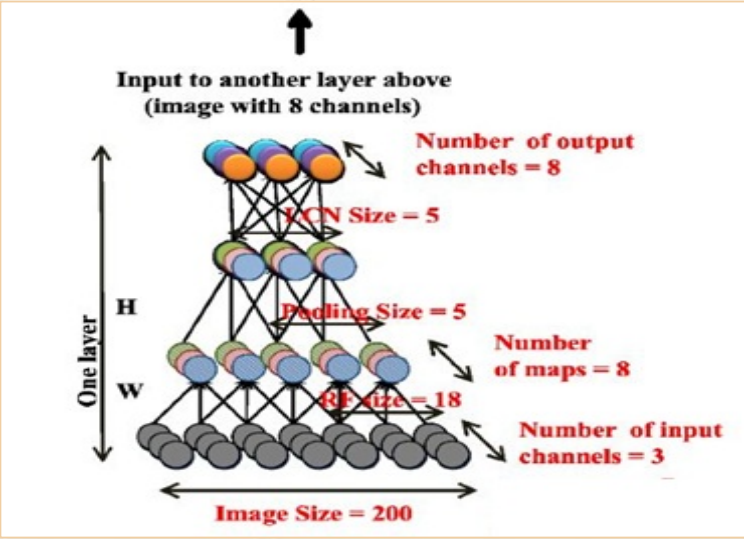

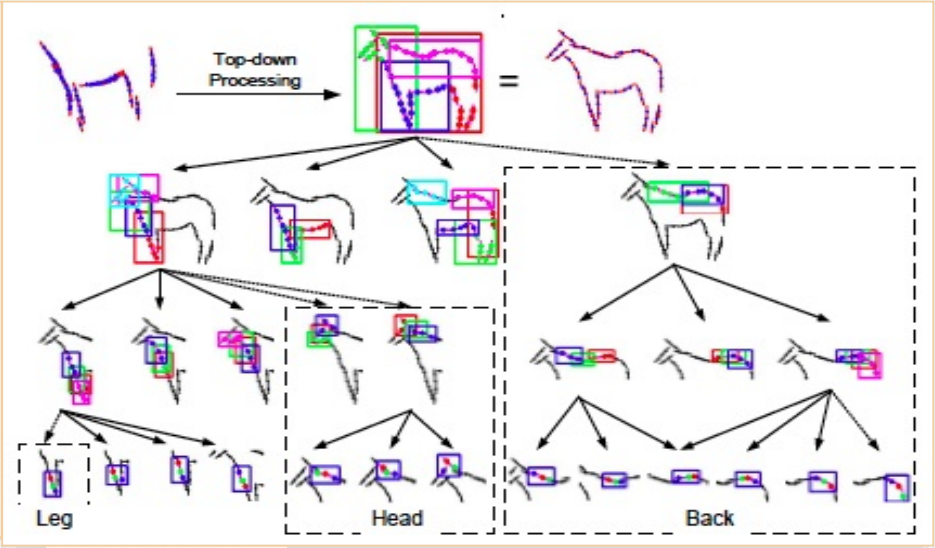

（7）重视非结构化数据应用

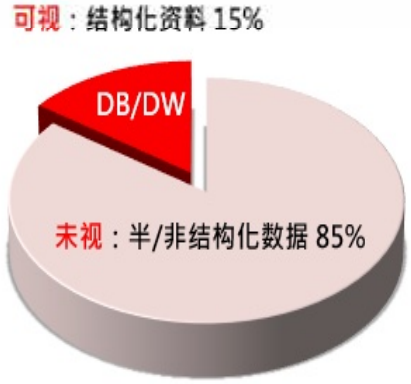

现有的行业数据、政务数据：结构化数据

非结构化数据：

（1）文件

（2）档案

（3）语音、视频、图像

（4）QQ数据、博客数据、新闻/消息/公告数据

（5）网络数据

…

典型例子：非结构化数据展示：www（万维网，互联网？）

非结构化数据检索：搜索引擎（谷歌，百度）

（8）大数据解决方案不是单一的

重庆大学 CHONGQING UNIVERSITY

方案1：Map/Reduce

方案2：Data Lake

方案3：内存计算

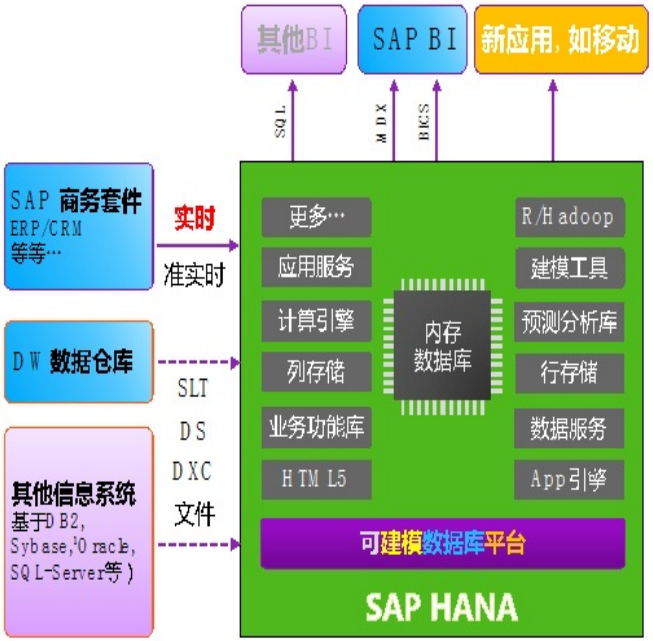

耐劳苦 尚俭朴
勤学业 爱国家

大数据智能Big Data Intelligence

重庆大学 CHONGQING UNIVERSITY

数据如何产生智能？（机器自动学习、数据挖掘）

数据库

编號	性別	年齡	婚姻	家庭人數	購買RV房車
A0001	Male	45	未婚	1	是
A0002	Male	52	已婚	7	是
A0003	Female	38	已婚	5	是
A0004	Male	25	已婚	5	否
A0005	Female	48	已婚	4	是
A0006	Male	32	未婚	3	是
A0007	Female	65	已婚	4	否
A0008	Male	33	已婚	3	是
A0009	Male	45	已婚	4	是
A0010	Female	52	未婚	1	是
A0011	Male	38	未婚	1	否
…	…	…	…	…	…
Z0099	Male	22	未婚	4	是

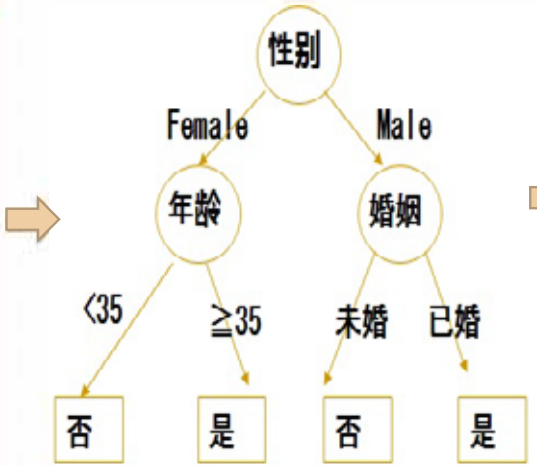

某人会买吗？

38岁，已婚男性？

机器答案：会买

大数据智能：三大必备条件

重庆大学 CHONGQING UNIVERSITY

计算：强大计算能力

PC 集群系统

数据：大数据

非结构化大数据
文本/音频/视频

结构化大数据
银行、税务....

模型：深度计算

数据挖掘
机器学习

深度学习
对抗生成
强化学习

耐劳苦 尚俭朴
勤学业 爱国家

计算能力：PC集群为主，其他如GPU集群、FPGA集群

超级计算机之争，中国力压美国
(2016年6月21日纽约时报新闻标题)

“神威·太湖之光”全景。体积相当于一个大仓库，用电量大致相当于1.5万户家庭

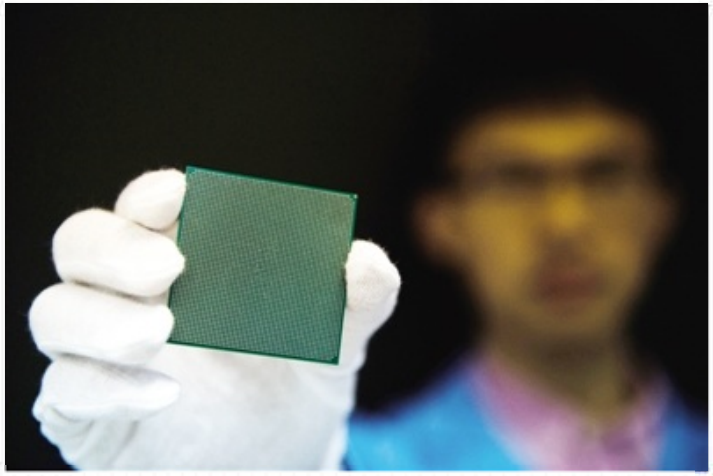

一名研发工程师展示“神威·太湖之光”所使用的“申威26010”众核处理器。该处理器采用64位自主申威指令系统，峰值性能3.168万亿次每秒，核心工作频率1.5GHz。“神威·太湖之光”里安装有40960个这样的处理器，1060万个处理器“核”，这些芯片单独运行时速度相对较慢，大约相当于苹果iPhone 6的处理器速度

“神威·太湖之光”超级计算机的交换机网线。“神威·太湖之光”采用大规模高流量复合网络体系结构，实现全系统高带宽、低延迟通信。

模型：深度学习(深度神经网络)模型为主

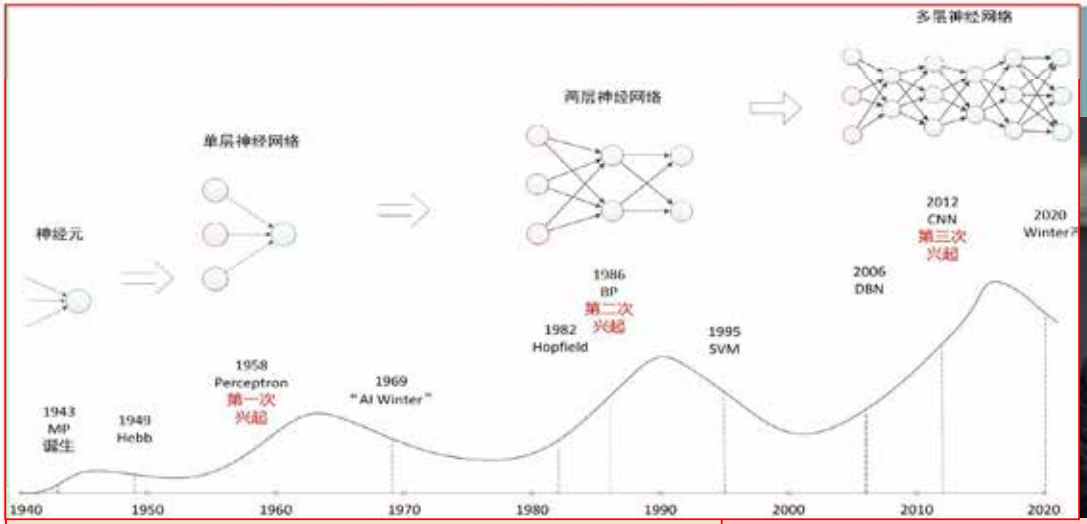

大数据智能BDI：新一代人工智能技术AI

重庆大学 CHONGQING UNIVERSITY

国务院关于印发

新一代人工智能发展规划的通知

国发〔2017〕35号

各省、自治区、直辖市人民政府，国务院各部委、各直属机构：

现将《新一代人工智能发展规划》印发给你们，请认真贯彻执行。

国务院

2017年7月8日

（此件公开发布）

新一代人工智能发展规划

人工智能的迅速发展将深刻改变人类社会生活、改变世界。为抢抓人工智能发展的重大战略机遇，构筑我国人工智能发展的先发优势，加快建设创新型国家和世界科技强国，按照党中央、国务院部署要求，制定本规划。

（一）构建开放协同的人工智能科技创新体系

建立新一代人工智能基础理论体系

（1）大数据智能理论
（2）跨媒体感知计算理论
（3）混合增强智能理论
（4）群体智能基础理论
（5）自主协同控制与优化决策理论
（6）高级机器学习理论
（7）类脑智能计算理论
（8）量子智能计算理论

专栏1　基础理论

1.大数据智能理论

研究数据驱动与知识引导相结合的人工智能新方法、以自然语言理解和图像图形为核心的认知计算理论和方法、综合深度推理与创意人工智能理论与方法、非完全信息下智能决策基础理论与框架、数据驱动的通用人工智能数学模型与理论等。

中国新一代人工智能战略

新一代人工智能发展规划布局示意图

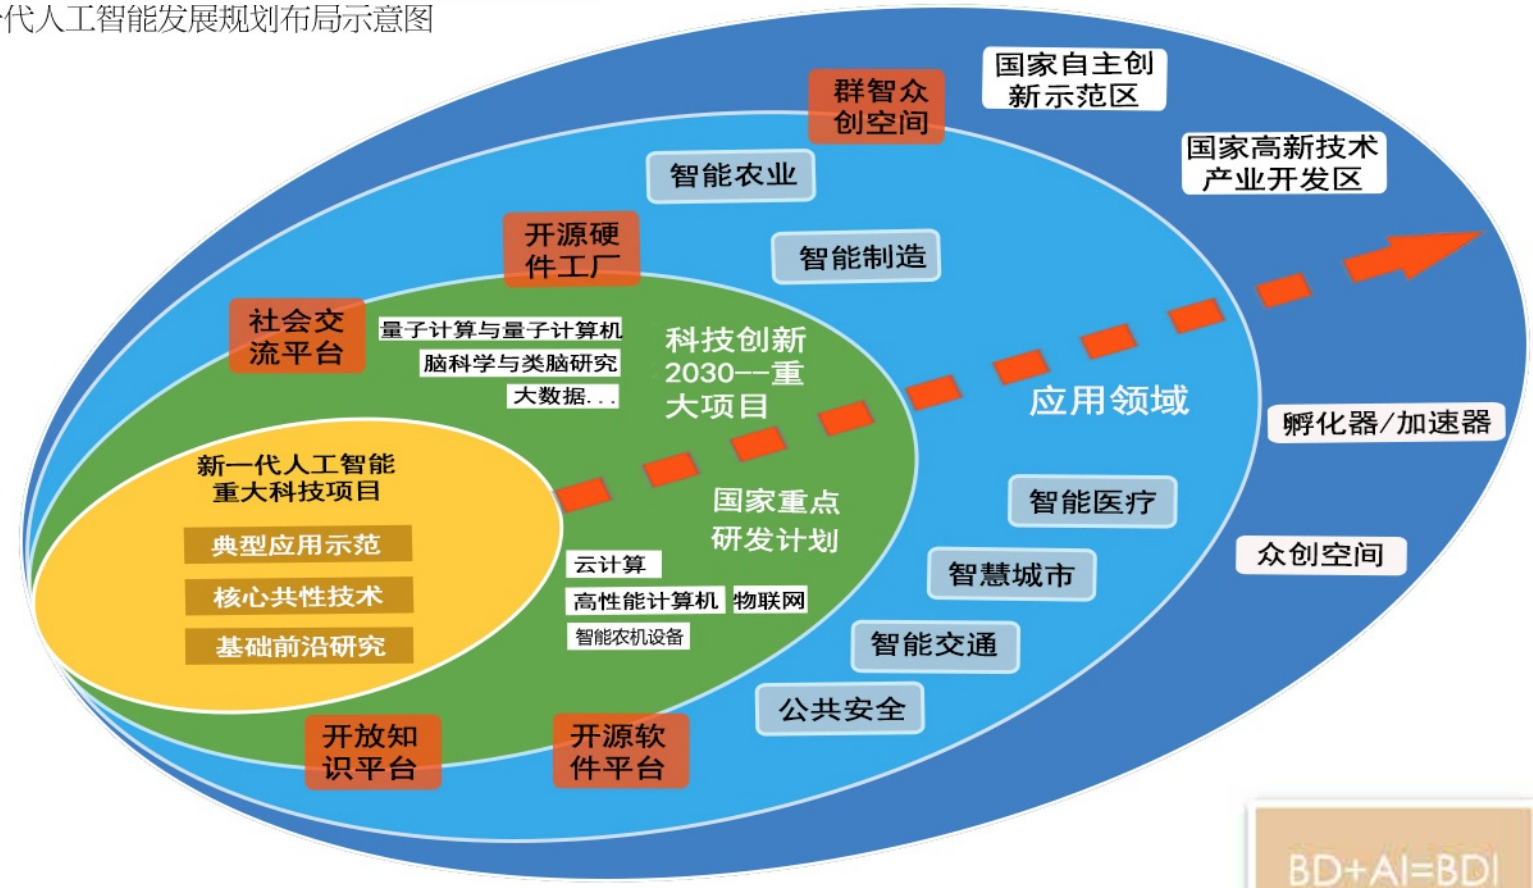

新一代人工智能规划

2016年1月，中国工程院启动了《中国人工智能2.0发展战略研究》重大咨询项目，这一项目被简称为AI2.0

2017年7月，国务院印发《新一代人工智能发展规划》，这是本世纪以来中国发布的第一个人工智能系统性战略规划，明确了我国新一代人工智能三步走的战略目标：

到2020年，人工智能总体技术和应用与世界先进水平同步，人工智能产业成为新的重要经济增长点；

到2025年，人工智能基础理论实现重大突破，部分技术与应用达到世界领先水平，人工智能成为我国产业升级和经济转型的主要动力；

到2030年，人工智能理论、技术与应用总体达到世界领先水平，成为世界人工智能创新中心之一。

新一代人工智能规划——大学-政府-产业的协同

重庆大学 CHONGQING UNIVERSITY

国家平台	任务	企业/地方政府
国家新一代人工智能开放创新平台（15个）	聚焦人工智能重点细分领域，充分发挥行业领军企业、研究机构的引领示范作用，整合技术资源、产业链资源和金融资源，持续输出人工智能核心研发能力和服务能力的重要创新载体。	自动驾驶（百度）、城市大脑（阿里云）、医疗影像（腾讯）、智能语音（科大讯飞公司）、智能视觉（商汤集团）、视觉计算（上海依图）、营销智能（明略科技）、基础软硬件（华为）、普惠金融（中国平安）、视频感知（海康威视）、智能供应链（京东），图像感知（旷视）、安全大脑（360）、智慧教育（好未来）、智能家居（小米）
国家新一代人工智能创新发展试验区（11个）	发挥地方主体作用，在体制机制、政策法规等方面先行先试，形成促进人工智能与经济社会发展深度融合的新路径，探索智能时代政府治理的新方式，推动新一代人工智能健康发展	北京、上海、合肥、杭州、深圳、天津、德清（2300多个县域中唯一一个）、重庆、成都、西安、济南
人工智能创新应用先导区	定位于攻破难点、痛点的“先锋队”，定位于探索新机制新方法的“试验田”，定位于培养产业发展的“主力军”。鼓励新技术新产品先行先试，着力夯实技术-产业系统迭代发展的基础	上海（浦东新区）、深圳、济南-青岛

大数据概述

CONTENTS

01 大数据概念与意义
Background

02 大数据的来源
Origin

03 大数据的应用
Application

04 大数据的处理方法
Processing data

4.1 大数据处理

- 大数据正带来一场信息社会的变革。大量的结构化数据和非结构化数据的广泛应用，致使人们需要重新思考已有的IT模式
- 与此同时，大数据将推动进行又一次基于信息革命的业务转型，使社会能够借助大数据获取更多的社会效益和发展机会
- 庞大的数据需要我们进行剥离、整理、归类、建模、分析等操作，通过这些动作后，我们开始建立数据分析的维度，通过对不同的维度数据进行分析，最终才能得到想到的数据和信息

因此，如何进行大数据的采集、导入/预处理、统计/分析和大数据挖掘，是“做”好大数据的关键基础

4.1.1 大数据采集

- 大数据的采集通常采用多个数据库来接收终端数据，包括智能硬件端、多种传感器端、网页端、移动APP应用端等，并使用数据库进行简单处理
- 常用的数据采集的方式主要包括以下几种：

01 数据抓取

02 数据导入

03 物联网传感设备自动信息采集

4.1.2 导入/预处理

- 采集端本身有很多数据库，如果要对这些海量数据进行有的分析，应该将这些数据导入到一个集中大型分布式数据库或者分布式存储集群中，同时，在导入的基础上完成数据清洗和预处理工作。
- 现实世界中数据大体上都是不完整、不一致的“脏”数据，无法直接进行数据挖掘，或挖掘结果差强人意，为了提高数据挖掘的质量，产生了数据预处理技术

数据清洗	主要是达到数据格式标准化、异常数据清除、数据错误纠正、重复数据的清除等目标。
数据集成	是将多个数据源中的数据结合起来并统一存储，建立数据仓库。
数据变换	通过平滑聚集、数据概化、规范化等方式将数据转换成适用于数据挖掘的形式。
数据归约	寻找依赖于发现目标的数据的有用特征，缩减数据规模，最大限度地精简数据量。

4.1.3 统计和分析

- 统计与分析主要是利用分布式数据库，或分布式计算集群来对存储于其内的海量数据进行普通的分析和分类汇总，以满足大多数常见的分析需求。

常见的统计分析方法

- 描述性统计：平均数、中位数、众数、方差、标准差、协方差等
- 假设检验：正态检验、t检验、卡方检验等
- 相关分析：单相关、复相关等
- 方差分析：单因素、多因素、协方差分析

4.1.4 大数据挖掘

分类

根据重要数据类的特征向量值及其他约束条件，构造分类函数或模型，目的是根据数据集的特点把未知类别的样本映射到给定类别中。

朴素贝叶斯算法　支持向量机SVM算法　AdaBoost算法　C4.5算法　CART算法

聚类

目的将数据集内具有相似特征属性的数据聚集在一起，同一个数据群中的数据特征要尽可能相似，不同的数据群中的数据特征要有明显的区别。

BIRCH算法　K-Means算法　期望最大化算法（EM算法）　K近邻算法

关联规则

找出所有能把一组事件或数据项与另一组事件或数据项联系起来的规则，以获得预先未知的和被隐藏的、不能通过逻辑操作或统计得出的信息。

Apriori算法　FP-Growth算法

预测模型

一种统计或数据挖掘的方法，包括可以在结构化与非结构化数据中使用以确定未来结果的算法和技术，可为预测、优化、预报和模拟等许多业务系统所使用。

序贯模式挖掘SPMGC算法

4.2 大数据挖掘工具---Spark MLlib

- 运行在Spark平台上专为在集群上并行运行而设计
- 内存中更快地实现多次迭代，适用于大规模数据集

Spark MLlib The Machine Learning Library

	离散型	连续型
有监督机器学习	分类 逻辑回归 支持向量机(SVM) 朴素贝叶斯 决策树 随机森林 梯度提升决策树 (GBT)	回归 线性回归 决策树 随机森林 梯度提升决策树 (GBT) 保序回归
无监督机器学习	聚类 k-means 高斯混合 快速迭代聚类(PIC) 隐含狄利克雷分布(LDA) 二分k-means 流k-means	协同过滤、降维 交替最小二乘(ALS) 奇异值分解(SVD) 主成分分析(PCA)

4.2.1 协同过滤

通过收集大量用户（协同）的喜好信息，以自动预测（过滤）用户感兴趣的商品。

◆ 基于ALS的矩阵分解算法

□ 算法介绍

- □ **基本思想**：是对稀疏矩阵进行模型分解，评估出缺失项的值，得到一个基本训练模型。然后依照此模型可以针对新的用户和物品数据进行评估。
- □ **缺失项**：ALS采用交替的最小二乘法计算缺失项，交替的最小二乘法是在最小二乘法的基础上发展而来的。

□ 算法流程

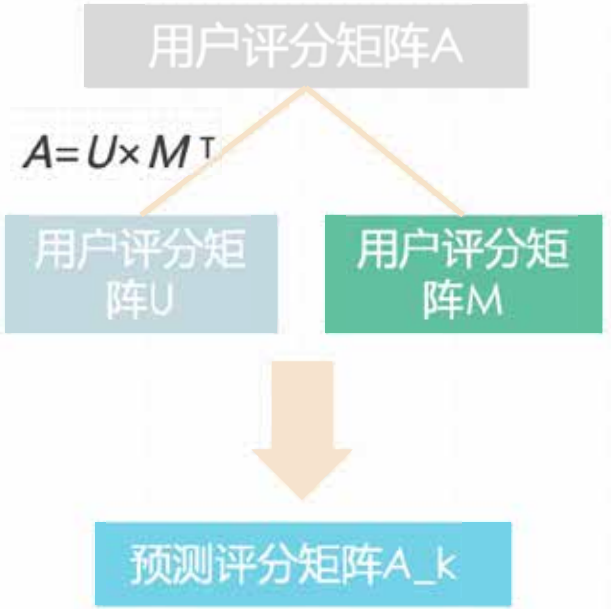

◆ 基于ALS的矩阵分解算法

□ 算法实例（1/3）

协同过滤的分类来说，ALS算法属于User-Item CF，也叫做混合CF，它同时考虑了User和Item两个方面。

Table1：听众对每首歌的评分矩阵（原始数据）

	痴心绝对	小酒窝	红豆	明天你好	浮夸
听众1	5			4	
听众2		6			3
听众3	3		7		
听众4				4	
听众5		4			6

◆ 基于ALS的矩阵分解算法

□ 算法实例（2/3）

ALS矩阵分解会把矩阵A分解成两个矩阵的相乘，分别是X矩阵和Y矩阵：

$$A = X * Y^T$$

x列&Y行表示：称为ALS中的因子

Table2：矩阵X

	性格	教育程度	兴趣爱好
听众1	X_{11}	X_{12}	X_{13}
听众2	X_{21}	X_{22}	X_{23}
听众3	X_{31}	X_{32}	X_{33}
听众4	X_{41}	X_{42}	X_{43}
听众5	X_{51}	X_{52}	X_{53}

Table3：矩阵Y

	痴心绝对	小酒窝	红豆	明天你好	浮夸
性格	Y_{11}	Y_{12}	Y_{13}	Y_{14}	Y_{15}
教育程度	Y_{21}	Y_{22}	Y_{23}	Y_{24}	Y_{25}
兴趣爱好	Y_{31}	Y_{32}	Y_{33}	Y_{34}	Y_{35}

◆ 基于ALS的矩阵分解算法

□ 算法实例（3/3）

音乐评分预测：如听众6，他从没听过“红豆“这首歌，拿到听众6在矩阵分解中X矩阵的向量M，把向量M和”红豆“在Y矩阵中的对应向量N**相乘**，预测出听众6对于”红豆“评分。

Table2：矩阵X

	性格	教育程度	兴趣爱好
听众1	X_{11}	X_{12}	X_{13}
听众2	X_{21}	X_{22}	X_{23}
听众3	X_{31}	X_{32}	X_{33}
听众4	X_{41}	X_{42}	X_{43}
听众5	X_{51}	X_{52}	X_{53}

Table3：矩阵Y

	痴心绝对	小酒窝	红豆	明天你好	浮夸
听众1	Y_{11}	Y_{12}	Y_{13}	Y_{14}	Y_{15}
听众2	Y_{21}	Y_{22}	Y_{23}	Y_{24}	Y_{25}
听众3	Y_{31}	Y_{32}	Y_{33}	Y_{34}	Y_{35}
听众4	Y_{41}	Y_{42}	Y_{43}	Y_{44}	Y_{45}
听众5	Y_{51}	Y_{52}	Y_{53}	Y_{54}	Y_{55}

◆ 基于物品协同过滤算法

□ 算法介绍

□ 基本思想

- UserCF思想：是根据用户行为数据，找到与目标用户有 相似兴趣的其他用户，给用户推荐其他用户喜欢的物品。
- ItemCF思想：是根据用户行为数据，计算物品间的相似度，基于用户以往的喜好记录，推荐给用户相似的物品。

◆ 基于物品协同过滤算法

□ 算法流程

1. 根据原始数据计算用户对物品的评分

用户对物品的评分						
	101	102	103	104	105	106
A	5	3	2.5	0	0	0
B	2	2.5	5	2	0	0
C	2	0	0	4	4.5	6
D	5	0	3	4.5	0	4
E	4	3	2	4	3.5	4

◆ 基于物品协同过滤算法

□ 算法流程

构建评分矩阵X

↓

构建物品相似度矩阵Y

↓

分值: $A = X * Y^T$

2.计算物品之间的相似度，可使用余弦相似度，如下：

$$w_{ij} = \frac{|N(i) \cap N(j)|}{\sqrt{|N(i)||N(j)|}}$$

其中，$N(i)$表示对物品i产生过行为的用户集合

物品与物品的相似度

	101	102	103	104	105	106
101	5	3	4	4	2	3
102	3	3	3	2	1	1
103	4	3	4	3	1	2
104	4	2	3	4	2	3
105	2	1	1	2	2	2
106	3	1	2	3	2	3

4.2.2 聚类算法

Scale 代码

```
import org.apache.spark.mllib.clustering.{KMeans,KMeansModel}
import org.apache.spark.mllib.linalg.Vectors

// Load and parse the data
val data = sc.textFile("data/mllib/points.txt")
val parsedData = data.map(s =>
Vectors.dense(s.split("\\s+").map(_.toDouble))).cache()

// Cluster the data into three classes using KMeans
val k = 3
val numIterations = 20
val clusters = KMeans.train(parsedData, k, numIterations)

for(c <- clusters.clusterCenters){ println(c) }
clusters.predict(Vectors.dense(10,10))

// Evaluate clustering by computing Within Set Sum of Squared Errors
val WSSSE = clusters.computeCost(parsedData)
println("Within Set Sum of Squared Errors = " + WSSSE)
```

输出结果

```
[1.5,10.5]
[10.5,1.5]
[10.5,10.5]
2
Within Set Sum of Squared Errors =
6.000000000000057
```

◆ 基于物品协同过滤算法

□ 算法流程

3.用户对物品的评分矩阵 × 物品相似矩阵 = 推荐列表

$$A = X * Y^T$$

	A	B	C	D	E
101	5	2	2	5	4
102	3	2.5	0	0	3
103	2.5	5	0	3	2
104	0	2	4	4.5	4
105	0	0	4.5	0	3.5
106	0	0	6	4	4

4.2.3 回归算法

回归算法和分类算法都是有监督的学习，分类算法预测的结果是离散的类别，而回归算法预测的结果是连续的数值。

- 线性回归——最常用的算法之一，使用输入值的线性组合来预测输出值
- 类LinearRegressionWithSGD——MLlib实现线性回归算法的常用类之一，基于随机梯度下降实现线性回归

输入数据

```
-0.801696864,-1.497953299 -0.263601072
0.407654716,0.796247055 0.047655941
-0.979828061,-1.622338485 -0.843294092
-0.403657629,-0.990720665 0.458513517
-0.183790121,-0.171901282 -0.489197399
-0.92193133,-1.607582523 -0.59070034
0.100333967,0.366273919 -0.414014963
-0.312807305,-0.710307385 0.211731938
-0.364812555,-0.262791728 -1.167083456
0.331381491,0.899043117 -0.59070034
-0.236406401,-0.903451691 1.07659722
-0.307844837,-0.06333379 -1.380889709
-0.769339565,-1.1539379 -0.961853075
0.044169664,0.062020372 0.065797389
-0.96409108,-0.757310278 -2.927179705
0.769104799,1.112269933 1.064849162
```

输入函数

y=0.5*x1+0.2*x2

输出结果

weights:
[0.5000000000539042,0.19999999999
89402], intercept:0.0

training Mean Squared Error =
9.576567731363342E-20

4.2.4 分类算法

输入数据

lable	x1	x2	x3
0	1	0	0
0	2	0	0
0	3	0	0
0	4	0	0
1	0	1	0
1	0	2	0
1	0	3	0
1	0	4	0
2	0	0	1
2	0	0	2
2	0	0	3
2	0	0	4

Scale代码

加载训练数据文件

解析每行数据

训练模型

预测分类

测试案例

Vector(0 0 9) 's label is 2.0

Accuracy: 1.0

国家战略定位

数据基础设施是**新型基础设施的核心组成部分**，是数字经济时代的"水电气"，是支撑经济社会数字化转型的关键底座。

2026年政府工作报告首次将"算电协同"写入，明确提出：

- 打造智能经济新形态
- 实施超大规模智算集群、算电协同等新基建工程
- 加快建设国家数据基础设施体系

国家战略层级

国家数据基础设施
新型基础设施
数字中国建设
中国式现代化

数据基础设施对数字经济增长的贡献率已达38.7%

数据基础设施是数据要素价值释放的基石

数据基础设施解决了数据要素价值释放的三大核心问题：

- **"数据孤岛"问题**：实现跨层级、跨区域、跨部门数据互联互通
- **"安全可信"问题**：通过隐私计算等技术实现数据"可用不可见"
- **"价值计量"问题**：建立数据资产确权、定价、交易的完整体系

2026年被国家数据局明确为"数据价值释放年"，重点推进数据要素市场化配置改革。

数据要素价值释放全流程

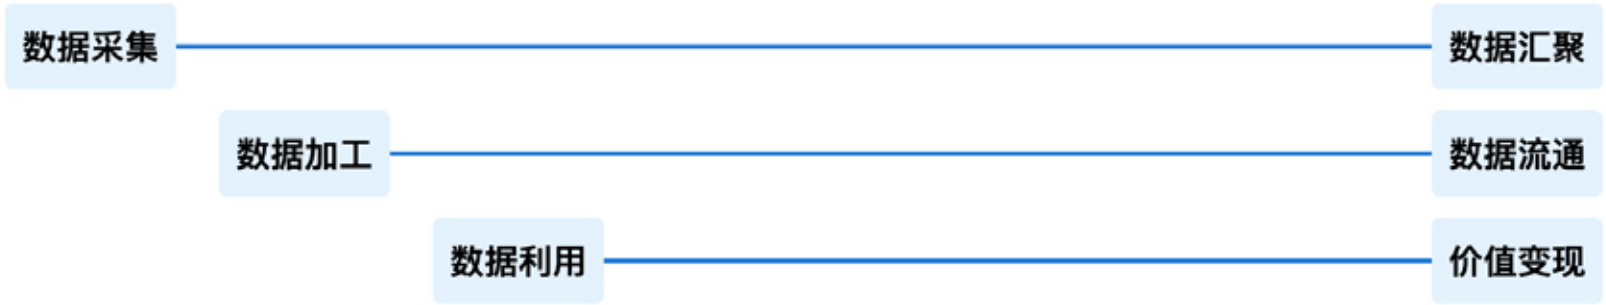

数据基础设施贯穿数据全生命周期，是实现数据从"资源"到"资产"再到"资本"转化的关键支撑

官方定义

重庆大学 CHONGQING UNIVERSITY

数据基础设施

2024年12月国家发改委、国家数据局、工信部联合发布的《国家数据基础设施建设指引》首次从国家政策层面明确：

数据基础设施是从数据要素价值释放的角度出发，面向社会提供 数据采集、汇聚、传输、加工、流通、利用、运营、安全服务 的一类新型基础设施，是集成硬件、软件、模型算法、标准规范、机制设计等在内的有机整体。

这一定义标志着我国数据基础设施建设从"技术驱动"转向"价值驱动"，从"分散建设"转向"系统布局"。

与数字基础设施的区别

重庆大学 CHONGQING UNIVERSITY

对比维度	数字基础设施	数据基础设施
核心目标	为数字化转型提供通用技术支撑	实现数据要素价值最大化释放
关注焦点	技术能力和网络覆盖	数据流通和价值转化
组成部分	5G、物联网、大数据、人工智能、卫星互联网等	数据流通设施、网络与算力设施、安全保障设施
系统属性	技术系统	技术+规则+市场+治理的社会技术系统
建设主体	以运营商和云厂商为主	政府引导、多方参与、市场化运营

数据基础设施是数字基础设施的**核心子集和高级形态**，
是数字基础设施发展到一定阶段的必然产物。

核心组成部分

重庆大学 CHONGQING UNIVERSITY

数据流通设施

核心板块

- 可信数据空间
- 数据场
- 数联网
- 隐私计算平台
- 区块链网络

网络与算力设施

基础支撑

- 高速网络
- 数据中心
- 智算中心
- 超算中心
- 边缘计算节点

安全保障设施

底线保障

- 安全监测系统
- 应急响应体系
- 数据脱敏系统
- 身份认证系统
- 审计追溯系统

数据全生命周期管理

重庆大学 CHONGQING UNIVERSITY

采集 — 汇聚 — 加工 — 流通 — 利用 — 销毁

采集阶段

物联网、传感器、互联网、政务系统等多源数据采集

汇聚阶段

数据清洗、去重、标准化、分类分级管理

加工阶段

数据标注、特征提取、模型训练、知识图谱构建

流通阶段

数据交易、共享、开放、跨境流动

利用阶段

数据分析、决策支持、智能应用、价值变现

销毁阶段

数据归档、删除、销毁，确保数据安全

12个关键概念与内涵

数据基础设施

Data Infrastructure — 支撑数据采集、传输、存储、处理、分析、流通、治理和销毁全生命周期的基础设施体系。涵盖硬件设施（数据中心、网络）、软件平台（数据库、数据中台）、制度规范（标准、法规）三大维度，是数字经济的"底座工程"。

数据要素

Data Factor / Data Element — 与土地、劳动力、资本、技术并列的**第五大生产要素**。2020年4月中央首次将数据列为生产要素。数据要素具有非排他性、可复制性、边际成本趋零等独特属性，可被多方同时使用而不减损价值。

数据仓库

Data Warehouse, DW — 面向主题的、集成的、稳定的、随时间变化的数据集合。如同"精加工仓库"，数据经过清洗、转换后按主题组织存储，适用于结构化的商业智能分析，强调数据质量与查询性能。

数据湖仓

Data Lakehouse — 融合数据湖的灵活性与数据仓库的管理能力的新型架构。在数据湖上增加事务支持（ACID）、数据治理、索引优化等能力，实现"一份存储、多种用法"，代表产品有 Delta Lake、Apache Iceberg、Apache Hudi。

12个关键概念与内涵

数据湖

Data Lake — 以原始格式存储大量结构化和非结构化数据的存储系统。如同一个"自然湖"汇入各种源头的水，数据湖保留了数据的原始形态，待需要时再进行加工分析，强调"先存后用"、灵活性与扩展性。

数据编织

Data Fabric — 跨不同端点的数据集成和管理架构，利用元数据和AI主动管理数据流。如同"编织"一张覆盖全域的数据网络，实现跨云、跨地域、跨系统的数据自动发现、连接和治理，强调自动化与智能化。

数据网格

Data Mesh — 去中心化的数据架构范式，核心思想是将数据视为"产品"，由各业务域团队自主管理其数据产品的全生命周期，而非集中到统一平台。四大原则：领域所有权、数据即产品、自助数据平台、联邦计算治理。

数据治理

Data Governance — 对数据资产进行管理和控制的组织框架与制度体系。涵盖数据质量管理、元数据管理（Metadata Management）、数据血缘（Data Lineage）、数据安全合规、主数据管理等方面，确保数据"可信、可用、可管、可溯"。

12个关键概念与内涵

重庆大学 CHONGQING UNIVERSITY

隐私计算

Privacy-Preserving Computation, PPC — 在保护数据隐私的前提下实现数据计算与流通的技术体系。核心技术包括：联邦学习（Federated Learning, FL）、多方安全计算（Secure Multi-Party Computation, MPC）、可信执行环境（Trusted Execution Environment, TEE）、同态加密（Homomorphic Encryption, HE）。实现"数据可用不可见"。

数据流通与交易

Data Circulation and Trading — 数据作为要素在市场中进行确权、定价、交易和流转的过程。包括数据交易所/交易中心、数据确权登记、数据资产评估、数据经纪等环节。目前全国已设立约**50家**数据交易机构。

向量数据库

Vector Database — 专门存储和检索向量嵌入（Vector Embedding）的数据库系统。AI大模型时代的关键基础设施，将文本、图像等非结构化数据转化为高维向量，支持相似性搜索（ANN），为RAG（Retrieval-Augmented Generation，检索增强生成）提供底座支撑。

数据空间

Data Space — 基于共享规则和信任机制的数据共享生态。以国际数据空间（International Data Spaces, IDS）为代表，强调数据主权——数据提供方始终控制其数据的访问权限和使用条件，实现"数据不动程序动"的安全流通。

重要术语

重庆大学 CHONGQING UNIVERSITY

PUE（电源使用效率）

英文全称：Power Usage Effectiveness

定义：数据中心总能耗与IT设备能耗的比值

计算公式：PUE = 数据中心总能耗 / IT设备能耗

意义：衡量数据中心能源利用效率的核心指标，越接近1越节能

当前水平：我国新建大型数据中心PUE普遍低于1.3，先进水平可达1.1以下

PFLOPS（千万亿次浮点运算每秒）

英文全称：Peta Floating-point Operations Per Second

定义：每秒能完成1千万亿次浮点运算

换算关系：1PFLOPS = 1000TFLOPS

意义：衡量算力的基本单位

应用：AI大模型训练、科学计算、气象预报等

EFLOPS（百亿亿次浮点运算每秒）

英文全称：Exa Floating-point Operations Per Second

定义：每秒能完成1百亿亿次浮点运算

换算关系：1EFLOPS = 1000PFLOPS

意义：代表当前算力的最高水平

现状：全球已有多台E级超算，我国"天河三号"、"神威·太湖之光"升级版均为E级超算

DPU（数据处理单元）

英文全称：Data Processing Unit

定义：专门处理网络、存储和安全任务的芯片

作用：释放CPU算力专注于业务应用和AI计算

优势：实现数据中心内部"无损网络"，大幅提升数据传输效率

现状：已成为现代数据中心的标配组件

产业前沿动态

重庆大学 CHONGQING UNIVERSITY

2025年全球数据量	2023年中国数据产量	中国算力总规模	数据中心机架	东数西算投资
175	32	230	810	4000
ZB（泽字节）	ZB	EFLOPS	万标准机架	亿元+

全球数据量增长趋势

数据来源：IDC Global DataSphere Forecast 2024

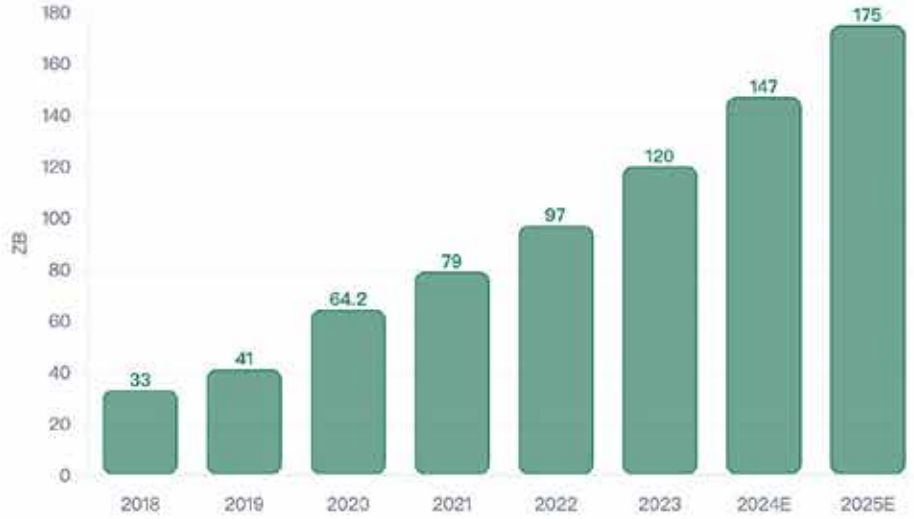

中国算力规模增长

数据来源：工信部、信通院 | EFLOPS=每秒百亿亿次浮点运算

产业前沿动态

重庆大学 CHONGQING UNIVERSITY

全球数据中心能耗占比

数据来源：IEA 2024

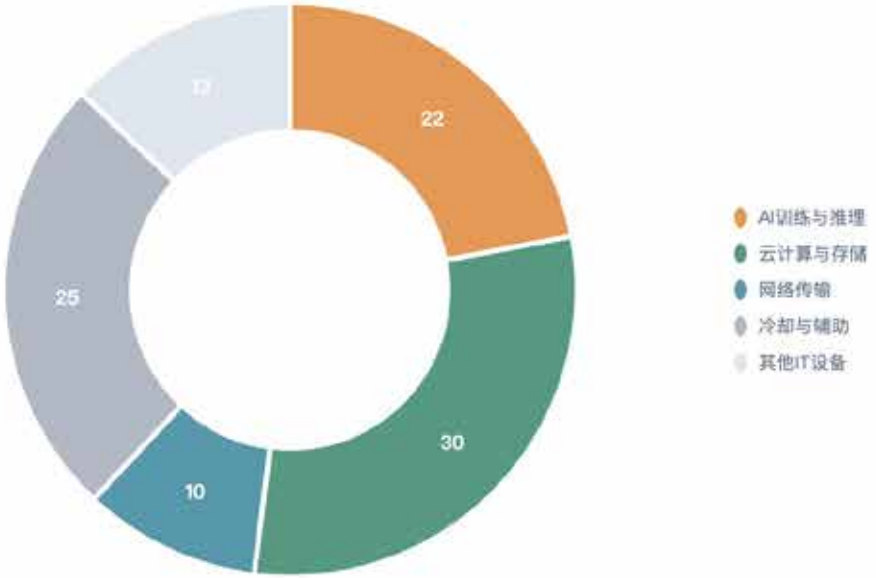

中国数据要素市场交易规模

数据来源：国家数据局、信通院 | 单位：亿元

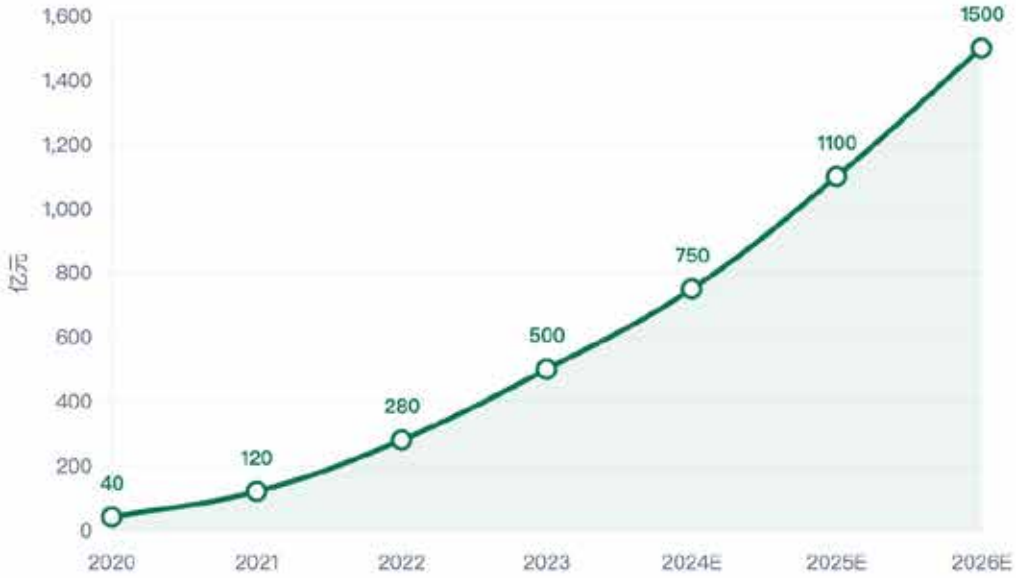

产业前沿动态

重庆大学 CHONGQING UNIVERSITY

全球数据中心年耗电 460 TWh (2023)	中国智能算力占比 30%+ 超过通用算力	全国数据交易机构 ~50 家	GPT-4训练数据量 13T Tokens
向量数据库市场增速 30%+ CAGR	中国平均PUE 1.48 越接近1越节能	一体化算力网 8+10 枢纽+集群	2025算力目标 300 EFLOPS

指标解读

EFLOPS：每秒百亿亿次浮点运算，衡量算力规模

ZB：泽字节=10^21字节，衡量数据规模

PUE：电能利用效率=总耗电/IT设备耗电

TWh：太瓦时=10亿千瓦时，衡量耗电量

重大政策与事件（上）

重庆大学 CHONGQING UNIVERSITY

- **2020年4月**
  数据列为第五大生产要素
  《关于构建更加完善的要素市场化配置体制机制的意见》
- **2021年9月**
  《数据安全法》正式施行
  确立数据安全保护管理制度
- **2022年2月**
  "东数西算"工程全面启动
  8枢纽10集群，投资超4000亿元
- **2022年12月**
  "数据二十条"发布
  数据产权、流通交易、收益分配、安全治理四项制度

从"要素确认"到"制度体系"

3年时间完成数据要素从理论到制度的跨越

重大政策与事件（下）

重庆大学 CHONGQING UNIVERSITY

2023年10月

国家数据局正式挂牌

统筹数字中国、数字经济、数字社会规划与建设

2023年12月

《"数据要素×"三年行动计划》

选择12个行业推动数据要素乘数效应

2024年1月

《关于加强数据资产管理的指导意见》

财政部发文，数据资产入表，公共数据授权运营加速

2024年7月

二十届三中全会：加快建立数据产权归属认定制度

培育全国一体化技术和数据市场

从"制度框架"到"落地实施"

国家数据局统筹推进数据要素市场加速成型

数据基础设施的六层架构模型总览

重庆大学 CHONGQING UNIVERSITY

L6	**应用服务层** — BI分析、AI推理、RAG、数字孪生、智能推荐
L5	**数据治理与安全层** — 数据质量、元数据、血缘、隐私计算、合规审计
L4	**数据加工与编排层** — ETL/ELT、流批一体、Spark、Flink、Airflow
L3	**数据存储与组织层** — 数据湖仓、向量数据库、对象存储、HDFS、图数据库
L2	**算力与网络层** — GPU/NPU、RDMA、CXL、DPU、InfiniBand
L1	**物理设施层** — 数据中心、液冷、PUE、绿电、储能

数据基础设施的六层架构模型（上）

重庆大学 CHONGQING UNIVERSITY

L2 算力与网络层

算力：通用算力（CPU）、智能算力（GPU/NPU，Graphics Processing Unit / Neural Processing Unit）、超算（HPC，High Performance Computing）。网络：**RDMA**（Remote Direct Memory Access，远程直接内存访问）延迟低于10μs；**CXL**（Compute Express Link，计算快速链接）缓存一致性互联；**DPU**（Data Processing Unit，数据处理单元）卸载专用处理。

GPU/NPU | RDMA | CXL | DPU | RoCE | InfiniBand

L1 物理设施层

数据中心、机房、电力、散热等物理基础设施。核心指标：PUE（Power Usage Effectiveness，电能利用效率）=总耗电/IT设备耗电，越接近1越节能。绿色数据中心目标PUE低于1.25。液冷技术可将PUE降至1.1以下。2023年全国平均PUE约1.48。

数据中心 | 液冷 | PUE | 绿电 | 储能

数据基础设施的六层架构模型（中）

重庆大学 CHONGQING UNIVERSITY

L4 数据加工与编排层

核心模式包括ETL（Extract-Transform-Load，抽取-转换-加载）、ELT（Extract-Load-Transform，抽取-加载-转换）、流批一体（Stream-Batch Unified Processing）处理。关键计算框架：Apache Spark、Apache Flink。数据编排：Apache Airflow、Dagster。

Apache Spark | Apache Flink | Apache Airflow | 流批一体 | ETL/ELT

L3 数据存储与组织层

关系型数据库（MySQL、PostgreSQL）、分布式文件系统（HDFS，Hadoop Distributed File System）、对象存储（S3/OSS）、**数据湖仓**（Delta Lake、Apache Iceberg、Apache Hudi）、**向量数据库**（Milvus、Pinecone）、图数据库（Neo4j）。

数据湖仓 | 向量数据库 | 对象存储 | 图数据库 | HDFS

数据基础设施的六层架构模型（下）

重庆大学 CHONGQING UNIVERSITY

L6 应用服务层

面向终端用户和业务场景的数据服务，包括BI（Business Intelligence，商业智能）分析、AI大模型推理、RAG（Retrieval-Augmented Generation，检索增强生成）、智能推荐、数字孪生等。

BI分析 | AI推理 | RAG | 数字孪生 | 智能推荐

L5 数据治理与安全层

确保数据"可信、可用、可管、可溯"的制度与技术体系。包括数据质量管理、元数据管理（Metadata Management）、数据血缘（Data Lineage）、隐私计算（PPC）、数据脱敏、访问控制、合规审计等。

数据质量 | 元数据 | 数据血缘 | 隐私计算 | 脱敏 | 合规审计

三种数据架构范式对比

维度	数据湖 Data Lake	数据仓库 Data Warehouse	数据湖仓 Data Lakehouse
核心理念	先存后用，保留原始	先处理后用，质量优先	两者融合，一份存储多种用法
数据类型	结构化+非结构化	结构化	结构化+非结构化
数据质量	原始数据，可能"脏"	高质量，已清洗	支持治理，质量可控
事务支持	无ACID	完整ACID	ACID支持（表级）
存储成本	低（对象存储）	高（专用存储）	低（对象存储）
查询性能	较慢	快（索引优化）	较快（支持索引）
代表产品	AWS S3 + HDFS	Snowflake, Redshift	Delta Lake, Iceberg, Hudi
适用场景	数据探索、ML训练	BI报表、经营分析	全场景统一

主要产品与厂商

重庆大学 CHONGQING UNIVERSITY

存储层产品

分布式存储： Ceph, MinIO, GlusterFS

对象存储： AWS S3, 阿里云OSS, 华为OBS

数据湖仓： Delta Lake (Databricks), Apache Iceberg, Apache Hudi

向量数据库： Milvus (Zilliz), Pinecone, Weaviate, Qdrant

计算层产品

GPU/AI芯片： NVIDIA A100/H100, 华为昇腾910B, 寒武纪思元, 海光DCU

DPU： NVIDIA BlueField, 中科驭数

计算框架： Apache Spark, Apache Flink, Ray

智算平台： NVIDIA DGX Cloud, 华为ModelArts, 百度百舸

数据管理平台

一体化平台： Databricks, Snowflake, 星环科技TDH

数据中台： 阿里数据中台, 网易数帆, 数澜科技

数据集成： Fivetran, Informatica, DataX, SeaTunnel

数据编排： Apache Airflow, Dagster, Prefect

数据治理与安全

元数据/血缘： Apache Atlas, DataHub, OpenLineage

数据质量： Great Expectations, dbt, Soda

隐私计算： 蚂蚁摩斯, 华控清交, 星云Clustar, 矩阵元

联邦学习： 微众银行FATE, 谷歌TFF, PySyft

数据流通与交易

数据交易所： 上海数交所, 北京国际大数据交易所, 深圳数交所, 广州数交所

数据确权： 各地数据登记中心

数据资产评估： 中评协数据资产评估指引

公共数据授权运营： 各地试点推进

基础设施服务商

云服务商： 阿里云, 华为云, 腾讯云, AWS中国, 电信天翼云

数据中心： 万国数据, 秦淮数据, 数据港, 奥飞数据

网络互联： 中国电信, 中国移动, 中国联通

液冷散热： 曙光, 浪潮, 维谛技术

国内外数据基础设施领域的主要产品格局，覆盖存储、计算、管理、流通全环节。

代表案例--国家级标杆："东数西算"工程

"东数西算"工程全面实施，取得显著成效（截止2025年12月）：

- 全国已建成70条算力大通道
- 形成"集群内1ms、枢纽间20ms"时延圈
- 八大国家枢纽节点算力占比超过80%
- 西部数据中心上架率提升至65%以上
- 累计带动投资超过8000亿元

"东数西算"有效解决了"东部有需求没电，西部有电没需求"的矛盾，实现了算力与电力的优化配置。

八大国家算力枢纽节点分布

代表案例--政务领域：上海数据交易所

重庆大学 CHONGQING UNIVERSITY

政务领域

项目概况

2021年11月挂牌成立，率先探索数据产品挂牌交易模式。涵盖金融、交通、通信等10余个行业，首创**"数商"生态体系**，推动数据从"资源"变"资产"。

核心成果

- 累计挂牌数据产品超 **1,500个**
- 交易金额超 **10亿元**
- 构建数商生态，培育数据经纪、评估等专业服务
- 探索数据资产入表，推进数据资产化路径

挂牌数据产品
1500+

交易金额
10亿+

覆盖行业
10+

代表案例--能源领域：华为云贵安数据中心

重庆大学 CHONGQING UNIVERSITY

能源领域

项目概况

位于"东数西算"**贵安枢纽节点**，采用间接蒸发冷却+液冷技术，是中国绿色数据中心的标杆项目。

核心成果

- PUE低至 **1.12**，行业领先水平
- 100%使用绿色电力
- 年均节电数亿度
- 间接蒸发冷却+液冷双技术路线

远低于全国平均1.48
绿色数据中心标杆

代表案例--交通领域：杭州城市大脑

重庆大学 CHONGQING UNIVERSITY

交通领域

项目概况

阿里云为底座构建的城市数据中台，汇聚交通、城管、医疗等领域数据，是**数据驱动城市治理的典范**。

核心成果

- 实时分析 **50万+** 路监控视频
- 主干道通行时间缩短 **15.3%**
- 应急救援响应时间缩短 50%+
- 覆盖交通、医疗、城管等多领域

视频分析路数
50万+

通行时间缩短
15.3%

应急响应提速
50%+

代表案例--金融领域：微众银行FATE联邦学习平台

重庆大学 CHONGQING UNIVERSITY

金融领域

项目概况

全球首个工业级联邦学习开源框架（Federated AI Technology Enabler），实现多方数据**"可用不可见"**。

核心成果

- 合作机构超 **200家**
- 开源社区Star数超 5,000
- 应用于信贷风控、反欺诈、保险定价
- 支持FL/MPC/TEE多种隐私计算技术

核心技术路线

数据不动模型动
只共享模型参数
不共享原始数据

未来发展趋势

重庆大学 CHONGQING UNIVERSITY

01

AI原生数据基础设施

数据基础设施从"为人服务"转向"为人+AI双服务"。向量数据库成为标配，RAG架构深度集成，数据管道面向AI训练和推理优化。Gartner预测到2028年超过**70%**的新数据平台将内置AI能力。

02

数据要素市场加速成熟

数据确权、定价、交易制度逐步完善。公共数据授权运营全面铺开，数据资产入表（会计准则已实施），数据信托、数据银行等新模式涌现。预计2026年中国数据要素市场规模超**1500亿元**。

03

绿色低碳数据中心

AI算力需求爆发与双碳目标构成双重压力。液冷技术从"可选"变"必选"，绿电直供、储能系统成为标配。新建PUE低于**1.25**，枢纽节点低于1.2。2025年枢纽节点绿电占比超**80%**。

04

数据空间与可信流通

借鉴欧洲数据空间（Gaia-X等）经验，构建跨组织、跨行业、跨国的可信数据流通体系。隐私计算从"技术验证"走向"规模商用"，MPC/FL/TEE融合使用成为趋势。数据主权与跨境流动规则持续演化。

05

多模态数据融合处理

文本、图像、视频、音频、3D点云、传感器时序等多模态数据统一存储与融合处理能力成为关键。多模态大模型驱动数据基础设施向"一库多模态"演进，向量化与语义检索成为基础能力。

06

自主可控与国产替代

GPU（华为昇腾、寒武纪）、数据库（OceanBase、达梦）、分布式存储、数据管理平台等环节国产替代加速推进。信创从党政走向行业，金融、电信等关键行业国产化率目标**50%+**。

重庆大学 CHONGQING UNIVERSITY

数据基础设施发展路线图

2024

夯实基础

东数西算初步建成
数据交易所探索运营
隐私计算试点验证

2025

规模扩展

算力300EFLOPS目标
数据资产入表推开
AI原生平台普及

2026

深度融合

数据要素市场成熟
多模态数据统一处理
国产替代过半

2030

智能自主

数据空间全面互联
绿色算力碳中和
自主可控体系成型

5.1 数据要素市场化：从资源到资产

2019年：要素地位确立

党的十九届四中全会首次将数据与土地、劳动力、资本、技术并列为第五大生产要素。
数据从"副产品"上升为"核心资产"，要素地位正式确立。

2022年：数据二十条

中共中央、国务院印发《关于构建数据基础制度更好发挥数据要素作用的意见》。
创造性提出"三权分置"：数据资源持有权、加工使用权、产品经营权。

2024年：数据资产入表

财政部《企业数据资源相关会计处理暂行规定》正式施行。企业数据资源可计入无形资产或存货，数据资产正式进入财务报表。

数据要素市场化的核心制度框架

产权制度：三权分置破解确权难题
流通交易：数据交易所、数据经纪人、合规审查
收益分配：兼顾效率与公平，按贡献分配

安全治理：数据安全法、个人信息保护法
数据要素×：三年行动计划（2024-2026），12大行业
国家数据局：统筹推进数据基础制度建设

5.2 湖仓一体：数据架构的范式演进

第一代：数据仓库

特点：结构化数据、ETL、BI报表
代表：Oracle、Teradata、Greenplum
优势：事务一致性、查询性能高
局限：扩展性差、成本高、无法处理非结构化数据
时代：1990s-2010s

第二代：数据湖

特点：原始数据、多格式、弹性扩展
代表：Hadoop HDFS、S3、Hive
优势：存储成本低、支持非结构化数据
局限：缺乏ACID、数据沼泽、治理困难
时代：2010s-2020s

第三代：湖仓一体

特点：开放格式、统一存储、ACID事务
代表：Iceberg、Delta Lake、Hudi
优势：兼具湖的灵活与仓的性能
新增：时间旅行、Schema演进、流批一体
时代：2020s-至今

湖仓一体的核心技术与代表产品

开放表格式：Apache Iceberg、Delta Lake、Apache Hudi三大开放格式，提供ACID事务、Schema演进、时间旅行等数据仓库核心能力
查询引擎：StarRocks、Trino、Spark、Snowflake、Databricks SQL，支持实时分析与BI查询
AI原生能力：向量检索、文本检索、半结构化数据分析，直接支撑RAG和大模型应用，实现"Lakehouse is all you need"

5.3 Data+AI一体化与向量数据库

Data+AI一体化架构

应用层：AI Agent / RAG / 智能问答 / 数据分析

模型层：大模型 / 微调 / 特征工程 / 向量嵌入

存储层：湖仓一体 + 向量数据库 + 特征存储

数据层：多模态数据 / 实时流 / 批量数据

向量数据库：大模型的"记忆系统"

核心原理

将文本、图像等非结构化数据通过Embedding模型转化为高维向量，基于语义相似度进行快速检索。

主流产品

专用：Milvus、Pinecone、Weaviate、Chroma
融合：StarRocks、PostgreSQL(pgvector)、Elasticsearch

关键技术

HNSW、IVF-PQ等近似最近邻索引，支持亿级向量毫秒级检索。

核心观点：Data+AI一体化打破了"数据平台"与"AI平台"的壁垒，向量数据库成为连接结构化数据与非结构化语义的关键基础设施。Databricks提出"Lakehouse is all you need"，Snowflake推出Snowpark ML，云厂商纷纷将AI能力内嵌到数据平台中。

5.4 RAG：大数据与大模型的桥梁

RAG（Retrieval-Augmented Generation，检索增强生成）：让大模型"开卷考试"，实时检索外部知识来增强回答准确性

RAG的核心价值与应用场景

解决三大痛点

知识过时：实时检索最新数据，无需重新训练模型
幻觉问题：基于真实文档生成，答案可溯源可验证
私有数据：企业内部知识库无需泄露给模型训练

典型应用场景

企业智能客服与知识库问答
法律/医疗/金融专业领域助手
代码生成与文档检索（GitHub Copilot）
多模态RAG：图文混合检索与生成

5.5 实时计算与隐私计算新进展

实时大数据：流批一体成为主流

技术演进

第一代：Lambda架构（批处理+流处理两套系统）
第二代：Kappa架构（流处理为核心）
第三代：流批一体（Flink、Spark Structured Streaming）

核心技术栈

消息队列：Apache Kafka、Pulsar
流计算：Apache Flink、Spark Streaming
实时数仓：ClickHouse、Apache Doris、StarRocks

典型场景

实时风控、实时推荐、实时监控、实时数仓BI

隐私计算：数据可用不可见

三大技术路径

联邦学习：多方数据不出域，协同建模
差分隐私：添加噪声保护个体隐私
安全多方计算：加密态下联合计算
可信执行环境：TEE硬件级隔离保护

政策驱动

《数据安全法》《个人信息保护法》实施
数据要素流通需要隐私计算破局

大模型时代的新挑战

训练数据隐私泄露、模型记忆攻击、数据合规审计

趋势总结：实时计算从"奢侈品"变为"标配"，流批一体降低实时数据应用门槛；隐私计算从"学术概念"走向"产业落地"，成为数据要素流通的关键基础设施。二者共同支撑大模型时代的实时、安全、可信数据应用。

Thank You!