大数据预处理与质控

BIG DATA



教材



大数据应用案例		场景化众智案例	
大数据可视化技术		基于像素、几何投影、基于图符、层次可视化、可视化复杂对象与关系、ECharts	
大数据计算与分析		MapReduce、SparkRDD、Flink、数据挖掘、机器学习、深度学习	
大数据存储与管理		HDFS、Yarn、HBase、MongoDB、数据库	
大数据预处理与质控		数据认知、数据清洗、数据集成、数据归约、数据变换与离散化、数据降维	
大数据获取与采集		分布式爬虫、日志采集、物联网数据采集	
大数据操作系统		操作系统	
大数据硬件环境		计算平台	

0 概述

什么是数据预处理与质控

数据预处理（Data Preprocessing）：在数据挖掘或机器学习之前，对原始数据进行清洗、集成、归约、变换和降维等一系列操作，将"脏数据"转化为高质量、适合分析的格式。

数据质控（Data Quality Control）：在数据全生命周期中，通过质量评估、规则校验、监控告警等手段，确保数据满足准确性、完整性、一致性、时效性、唯一性和规范性六大质量维度。

为什么预处理至关重要

Garbage In, Garbage Out（垃圾进，垃圾出）：原始数据质量直接决定分析结果的可靠性。

现实问题：真实世界数据通常存在缺失、噪声、异常、不一致、重复、维度灾难等问题。

行业统计：数据科学家约60%-80%的时间用于数据清洗和预处理，仅20%-40%用于建模分析。

质控目标：从源头保障数据质量，降低后续分析的不确定性。

数据预处理完整流程（Knowledge Discovery in Databases, KDD 过程）

数据采集
Data Collection
爬虫/日志/IoT/API

→

数据预处理
Preprocessing
清洗/集成/归约
变换/降维

→

数据挖掘
Data Mining
分类/聚类/关联
预测/异常检测

→

模式评估
Pattern Evaluation
兴趣度度量
可视化验证

→

知识呈现
Knowledge
决策支持
业务应用

数据预处理五大核心任务

数据清洗
Data Cleaning
去噪/补缺/去重
异常值处理

数据集成
Data Integration
多源合并/实体匹配
冗余消除

数据归约
Data Reduction
维度/数值归约
特征选择

数据变换
Data Transformation
规范化/离散化
属性构造

数据降维
Dimensionality Reduction
PCA/t-SNE/UMAP
高维可视化



大数据预处理与质控

CONTENTS

01 数据对象与属性类型
Data Objects and Attribute Types

02 数据的基本统计描述
Basic Statistical Description of Data

03 度量数据的相似性和相异性
Measuring Data Similarity and Dissimilarity

04 数据清洗
Data Cleaning

05 数据归约
Data Reduction

06 数据变换与离散化
Data Transformation and Discretization

07 数据降维
Dimensionality Reduction

重庆大学 CHONGQING UNIVERSITY

1.1 数据对象与属性的基本概念

核心概念定义

数据集 Dataset
数据对象的集合，是数据挖掘的输入。通常表示为数据矩阵或关系表。

数据对象 Data Object
描述实体的基本单位，又称样本、实例、记录、元组。如一个学生、一笔交易。

属性 Attribute
描述数据对象的性质或特征，又称维度、特征、字段。如年龄、性别、成绩。

属性值 Attribute Value
属性在特定对象上的具体取值。如年龄=20，性别=男，成绩=85。

数据矩阵示例（学生信息表）

学号	姓名	性别	年龄	成绩
2024001	张三	男	20	85
2024002	李四	女	19	92
2024003	王五	男	21	78
2024004	赵六	女	20	88
2024005	孙七	男	22	95

5个数据对象（行）x 5个属性（列），属性值为单元格内容

数据对象的两种表示形式

特征向量表示（Feature Vector）：
每个数据对象表示为一个d维向量，d为属性个数。
例：学生张三 = (2024001, 张三, 男, 20, 85)
适用于数值型属性，可直接进行向量运算（距离、相似度计算）。

关系表表示（Relational Table）：
数据集表示为二维表，行=数据对象，列=属性，单元格=属性值。
例：学生信息表（如上方表格所示）
适用于结构化数据，是关系型数据库和数据仓库的标准表示。



大数据预处理与质控

CONTENTS

01 数据对象与属性类型
Data Objects and Attribute Types

02 数据的基本统计描述
Basic Statistical Description of Data

03 度量数据的相似性和相异性
Measuring Data Similarity and Dissimilarity

04 数据清洗
Data Cleaning

05 数据归约
Data Reduction

06 数据变换与离散化
Data Transformation and Discretization

07 数据降维
Dimensionality Reduction

1.2 属性类型分类与数据集类型

属性的四种基本类型（按测量尺度 Scale of Measurement 分类）

类型	英文全称	定义与特点	例子	可执行运算
标称	Nominal	仅作为名称或标签，无顺序关系，值之间不可比较大小	性别、颜色、职业、学号	=、!=、众数、熵
序数	Ordinal	值之间有顺序/等级关系，但差值无意义	成绩等级(优/良/中)、职称、满意度	>、<、中位数、百分位
区间	Interval	值之间可比较大小且差值有意义，但无真正零点（0不代表不存在）	摄氏温度、年份、IQ智商	+、-、均值、标准差
比率	Ratio	具有真正零点，差值和比值均有意义，是最高测量尺度	身高、体重、年龄、收入、成绩分数	全部算术运算、几何平均

离散属性 vs 连续属性

离散属性 Discrete
取值为有限或可数无限个集合
例：性别、职业、家庭人口数
通常用整数表示，标称/序数多为离散

连续属性 Continuous
取值为实数区间，理论上无限不可数
例：温度、身高、体重、收入
通常用浮点数表示，区间/比率多为连续

常见数据集类型

记录式数据 Record Data
数据对象为固定属性集合的记录
例：关系表、CSV文件、数据矩阵

基于图的数据 Graph Data
对象为节点，关系为边的图结构
例：社交网络、知识图谱、分子结构

有序数据 Ordered Data
数据对象之间存在时间或空间顺序
例：时序数据、空间数据、序列数据

事务数据 Transaction Data
每条记录包含一组无序的项（商品）
例：购物篮分析、推荐系统输入

重庆大学 CHONGQING UNIVERSITY

2.1 中心趋势度量（Measures of Central Tendency）

均值 Mean

算术均值（Arithmetic Mean）：所有值之和除以个数

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

加权均值（Weighted Mean）：各值乘以权重后求和

$$\bar{x} = \frac{\sum_{i=1}^{n} w_i x_i}{\sum_{i=1}^{n} w_i}$$

其中 n=数据个数，x_i=第i个数据值，w_i=第i个权重

中位数 Median

将数据**升序排列**后位于中间位置的值

n为奇数：取中间那个值

$median = x_{(n+1)/2}$

n为偶数：取中间两个值的平均

$$median = \frac{x_{n/2} + x_{n/2+1}}{2}$$

优点：对异常值不敏感（稳健统计量）

众数与中列数

众数（Mode）：出现频率最高的值

单峰(Unimodal)/双峰(Bimodal)/多峰(Multimodal)

适用于标称、序数、数值型所有属性

中列数（Midrange）：最大值与最小值的平均

$$midrange = \frac{max(x) + min(x)}{2}$$

计算简单，但对极端值非常敏感

计算示例：某班10名学生数学成绩（分）

原始数据：65, 72, 78, 80, 82, 85, 88, 90, 92, 98（已升序排列，n=10）

均值 = (65+72+78+80+82+85+88+90+92+98)/10 = 830/10 = **83.0**

中位数 = (x_5 + x_6)/2 = (82+85)/2 = **83.5**　**众数** = 无（每个值仅出现一次）　**中列数** = (65+98)/2 = 81.5

偏态分布中三者的位置关系

对称分布	均值 = 中位数 = 众数（三者重合）
正偏(右偏)	众数 < 中位数 < 均值（长尾在右）
负偏(左偏)	均值 < 中位数 < 众数（长尾在左）

正偏例：收入分布（少数高收入拉高均值）

负偏例：考试成绩偏难（多数低分拉低均值）

2.2 数据散布度量与分布可视化

数据散布度量（Measures of Dispersion）

极差 Range
最大值与最小值之差
$R = max(x) - min(x)$
计算简单，但仅用两个极端值，易受异常值影响

四分位数 Quartiles
Q1=第25百分位，Q2=中位数(第50)，Q3=第75百分位
四分位距 IQR = Q3 - Q1
对异常值稳健，是箱线图的核心组件

方差 Variance 与 标准差 Standard Deviation（最常用的散布度量）

总体方差（Population Variance，N为总体个数）：$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2$

样本方差（Sample Variance，n为样本个数，分母n-1为贝塞尔校正）：

$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$

标准差 = 方差的平方根，与原始数据同单位：$s = \sqrt{s^2}$　其中 μ=总体均值，x̄=样本均值

数据分布可视化方法

箱线图 Boxplot
五数概括：最小值、Q1、中位数、Q3、最大值
箱体=IQR范围，须线=1.5×IQR范围，超出为异常值
适合比较多组数据分布和识别异常值

直方图 Histogram
将数据划分为等宽区间（bin），统计每区间频数
横轴=数据值区间，纵轴=频数/频率
直观展示数据分布形态（对称/偏态/峰度）

散点图 Scatter Plot 与 分位数图 Quantile Plot
散点图：每个点(x_i, y_i)表示两个属性的取值对，用于观察两变量间的相关关系和聚类趋势
分位数图（Quantile-Quantile Plot, Q-Q图）：横轴=理论分位数，纵轴=样本分位数，点越接近对角线说明越符合该理论分布（如正态分布）
散点图矩阵（Scatter Plot Matrix）可同时展示多对变量间的关系

计算示例：10名学生成绩（65, 72, 78, 80, 82, 85, 88, 90, 92, 98），均值x̄=83

极差 R = 98 - 65 = 33　　**四分位数**：Q1=78（第25%位置），Q2=中位数=83.5，Q3=90（第75%位置），**IQR** = 90-78 = 12

样本方差 s^2 = [(65-83)²+(72-83)²+(78-83)²+(80-83)²+(82-83)²+(85-83)²+(88-83)²+(90-83)²+(92-83)²+(98-83)²]/(10-1)

= [324+121+25+9+1+4+25+49+81+225]/9 = 864/9 = 96.0　　**样本标准差** s = √96 ≈ 9.80 分

解读：标准差约9.8分，说明学生成绩在均值83分附近波动，成绩分布较为集中；IQR=12分，中间50%学生的成绩落在78-90分之间。



大数据预处理与质控

CONTENTS

01 数据对象与属性类型
Data Objects and Attribute Types

02 数据的基本统计描述
Basic Statistical Description of Data

03 度量数据的相似性和相异性
Measuring Data Similarity and Dissimilarity

04 数据清洗
Data Cleaning

05 数据归约
Data Reduction

06 数据变换与离散化
Data Transformation and Discretization

07 数据降维
Dimensionality Reduction

3.1 数据矩阵与相异性矩阵

数据矩阵（Data Matrix）

n个数据对象、d个属性构成的**n×d二维矩阵**，行=对象，列=属性

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix}$$

其中 n=数据对象个数（行数），d=属性个数（列数），x_ij=第i个对象在第j个属性上的取值

相异性矩阵（Dissimilarity Matrix）

存储n个对象两两之间相异性的**n×n对称矩阵**，对角线为0（自身距离为0）

$$D = \begin{bmatrix} 0 & & & \\ d(2,1) & 0 & & \\ d(3,1) & d(3,2) & 0 & \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

其中 d(i,j)=对象i与对象j之间的相异性（距离），满足 d(i,j)=d(j,i)（对称性），d(i,i)=0

示例：3名学生的成绩数据矩阵

学生	数学	英语	计算机
张三	85	78	92
李四	90	85	88
王五	75	92	80

对应的相异性矩阵（欧氏距离）

	张三	李四	王五
张三	0	9.95	18.22
李四	9.95	0	19.16
王五	18.22	19.16	0

相似性与相异性的关系及应用场景

相似性 Similarity sim(i,j)：衡量两个对象的相似程度，值越大越相似，范围[0,1]
相异性 Dissimilarity d(i,j)：衡量两个对象的差异程度，值越大越不相似，范围[0,∞)
转换关系：当d归一化到[0,1]时，sim(i,j) = 1 - d(i,j)

应用场景：
聚类分析：相似对象归为同一簇（K-Means、层次聚类）
推荐系统：基于用户/物品相似度进行协同过滤推荐
异常检测：与大多数对象相异性大的点视为异常值

3.2 标称属性相似性度量

二元属性的四种匹配情况（列联表）

	对象B = 1	对象B = 0
对象A = 1	f_{11} = a	f_{10} = b
对象A = 0	f_{01} = c	f_{00} = d

a=f_{11}：两者都为1的属性数（共同拥有） b=f_{10}：A有B无
c=f_{01}：A无B有 d=f_{00}：两者都为0的属性数（共同不拥有）
总属性数 p = a + b + c + d

简单匹配系数（Simple Matching Coefficient, SMC）

两个对象取值**相同**的属性数占总属性数的比例

$$SMC = \frac{f_{11} + f_{00}}{f_{11} + f_{10} + f_{01} + f_{00}} = \frac{a + d}{a + b + c + d} = \frac{a + d}{p}$$

特点：同时考虑"共同拥有"(a)和"共同不拥有"(d)，适用于对称二元属性（0和1同等重要）
适用场景：医学检查结果（阳性/阴性同等重要）、考试对错判断

Jaccard系数（Jaccard Coefficient / Jaccard Similarity）

只考虑"共同拥有"的属性，**忽略"共同不拥有"**的属性

$$J = \frac{f_{11}}{f_{11} + f_{10} + f_{01}} = \frac{a}{a + b + c}$$

特点：非对称二元属性（1比0更重要），d不参与计算
适用场景：购物篮分析（共同购买的商品）、文档词频（共同出现的词）、基因表达（共同表达的基因）

计算示例：两位顾客的购物记录（1=购买，0=未购买，共6种商品）

顾客A：[1, 1, 0, 1, 0, 1] 顾客B：[1, 0, 0, 1, 1, 1] （商品顺序：牛奶, 面包, 鸡蛋, 苹果, 香蕉, 可乐）
列联表：a=f_{11}=3（牛奶、苹果、可乐共同购买），b=f_{10}=1（A买面包B没买），c=f_{01}=1（B买香蕉A没买），d=f_{00}=1（鸡蛋都没买），p=6
SMC = (a+d)/p = (3+1)/6 = 0.667 （考虑共同不购买鸡蛋）
Jaccard系数 = a/(a+b+c) = 3/(3+1+1) = 0.600 （忽略共同不购买鸡蛋，更适合购物篮场景）

3.3 数值属性距离与余弦相似度

欧氏距离 Euclidean Distance

两点间直线距离（勾股定理推广到d维）

$$d(x,y)=\sqrt{\sum_{i=1}^{d}(x_i-y_i)^2}$$

其中 d=属性维度数，x_i/y_i=对象x/y在第i维的取值
最常用距离，K-Means聚类默认使用

曼哈顿距离 Manhattan Distance

各维度差值绝对值之和（城市街区行走距离）

$$d(x,y)=\sum_{i=1}^{d}|x_i-y_i|$$

又称L1距离、城市街区距离（City Block Distance）
对异常值比欧氏距离更稳健

闵可夫斯基距离 Minkowski Distance

欧氏和曼哈顿距离的统一推广形式

$$d(x,y)=\left(\sum_{i=1}^{d}|x_i-y_i|^r\right)^{1/r}$$

r=1→曼哈顿距离，r=2→欧氏距离，r→∞→切比雪夫距离
r为距离阶数参数，控制对大差值的敏感度

余弦相似度（Cosine Similarity）

衡量两个向量**方向的一致性**，不关心向量长度（幅值）

$$cos(x,y)=\frac{x\cdot y}{\|x\|\|y\|}=\frac{\sum_{i=1}^{d}x_i\,y_i}{\sqrt{\sum x_i^2}\sqrt{\sum y_i^2}}$$

其中 x·y=向量点积（内积），‖x‖=向量x的模长（L2范数），取值范围[-1,1]，1=完全同向，0=正交，-1=完全反向
适用场景：文本相似度（TF-IDF向量）、推荐系统（用户评分向量）、图像特征比对

皮尔逊相关系数（Pearson Correlation Coefficient）

衡量两个变量**线性相关程度**，先去均值再计算余弦相似度

$$r(x,y)=\frac{\sum_{i=1}^{d}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\sum(x_i-\bar{x})^2}\sqrt{\sum(y_i-\bar{y})^2}}$$

其中 x̄=x的均值，ȳ=y的均值，取值范围[-1,1]，1=完全正相关，0=无线性相关，-1=完全负相关
适用场景：协同过滤推荐（用户评分相关性）、特征选择（特征与目标相关性）

计算示例：两个二维点 x=(3,4)，y=(6,8)

欧氏距离 = √[(3-6)²+(4-8)²] = √(9+16) = √25 = **5.0**　　**曼哈顿距离** = |3-6|+|4-8| = 3+4 = **7.0**

闵可夫斯基距离(r=3) = (|3-6|³+|4-8|³)^(1/3) = (27+64)^(1/3) = 91^(1/3) ≈ **4.50**

余弦相似度 = (3×6+4×8)/(√(9+16)×√(36+64)) = (18+32)/(5×10) = 50/50 = **1.0**（两向量方向完全相同，y是x的2倍）

关键区别：欧氏距离=5反映了两点间的实际空间距离；余弦相似度=1反映了两向量方向完全一致（y=2x），长度差异不影响余弦值。文本相似度用余弦而非欧氏，因为文档长度不同但主题可能相同。



大数据预处理与质控

CONTENTS

01 数据对象与属性类型
Data Objects and Attribute Types

02 数据的基本统计描述
Basic Statistical Description of Data

03 度量数据的相似性和相异性
Measuring Data Similarity and Dissimilarity

04 数据清洗
Data Cleaning

05 数据归约
Data Reduction

06 数据变换与离散化
Data Transformation and Discretization

07 数据降维
Dimensionality Reduction

4.1 数据质量问题概述

数据质量的六个维度（Data Quality Dimensions）

准确性 Accuracy
数据是否正确反映真实世界
例：年龄记录为200岁→不准确

完整性 Completeness
是否存在缺失值或缺失记录
例：某学生成绩为空→不完整

一致性 Consistency
同一数据在不同来源是否一致
例：A表年龄20，B表年龄25

时效性 Timeliness
数据是否及时更新、是否过时
例：用2010年人口数据做2026分析

可信性 Believability
数据来源是否可靠、可被信任
例：权威机构vs匿名网络数据

可解释性 Interpretability
数据格式和含义是否易于理解
例：编码"001"无注释→难解释

脏数据的常见类型（Dirty Data Types）

问题类型	定义	示例
缺失值	Missing Value：某些属性值为空或未记录	患者表中"血压"字段为空
噪声	Noise：被随机错误或方差污染的数据	传感器读数受电磁干扰偏移
异常值	Outlier：与其他数据显著不同的观测值	人群收入中出现亿万富翁
重复数据	Duplicate：同一实体被多次记录	同一客户在系统中有两条记录
不一致	Inconsistency：数据间存在矛盾或冲突	出生日期2000年，年龄却写50岁
格式错误	Format Error：数据格式不符合规范要求	日期写成"2026/13/01"（月份超界）

数据质量问题的来源与影响

问题来源：
数据采集（传感器故障、人工录入错误）、数据传输（网络丢包、格式转换丢失）、数据集成（多源异构冲突、命名不一致）、数据存储（存储损坏、编码问题）、业务变更（规则变化未同步更新）

不良影响：
分析结论错误（Garbage In, Garbage Out）、模型性能下降（训练数据含噪声导致过拟合或偏差）、决策失误（基于错误数据的商业判断）、合规风险（数据不准确违反监管要求）、资源浪费（清洗脏数据消耗大量时间和算力）

4.2 缺失值与噪声处理

缺失值处理方法（Missing Value Handling）

方法	描述	优缺点
忽略元组	删除含缺失值的整条记录	简单但丢失信息，缺失多时不可用
人工填写	由领域专家手动补全缺失值	准确但耗时，不适合大规模数据
全局常量	用统一常量（如"Unknown"、-1）填充	简单但可能引入偏差，误导模型
属性均值	用该属性所有非缺失值的均值填充	保持均值不变，但降低方差
同类均值	用同类别（同聚类）样本的均值填充	比全局均值更精确，需先分类
最可能值	用回归、贝叶斯、决策树预测填充	最准确但计算复杂，可能过拟合

噪声处理方法（Noise Handling / Smoothing）

分箱 Binning

将排序后的数据分到若干箱中，用箱内均值/中位数/边界值平滑

等宽分箱：每箱区间宽度相同

等频分箱：每箱数据个数相同

回归 Regression

用回归函数拟合数据，用预测值替换噪声点

线性回归：y = ax + b（a斜率，b截距）

多元回归：多自变量预测因变量

适合有函数关系的数值型数据

聚类 Clustering

将相似数据聚为簇，远离簇中心的点视为噪声

常用算法：K-Means、DBSCAN

DBSCAN可自动识别噪声点（低密度区域）

离群点分析

Outlier Analysis：检测并移除或修正离群点

统计方法：3σ原则、IQR法（箱线图）

距离方法：KNN距离、LOF局部离群因子

计算示例：分箱平滑（原始数据排序后：4, 8, 15, 21, 21, 24, 25, 28, 34, 100，分3箱，每箱3个值）

原始分箱：箱1=[4, 8, 15]，箱2=[21, 21, 24]，箱3=[25, 28, 34]（注：100为异常值，此处仅演示前9个值）

均值平滑（Mean Smoothing）：箱内所有值替换为箱均值　箱1→[9, 9, 9]（(4+8+15)/3=9），箱2→[22, 22, 22]，箱3→[29, 29, 29]

中位数平滑（Median Smoothing）：箱内所有值替换为箱中位数　箱1→[8, 8, 8]，箱2→[21, 21, 21]，箱3→[28, 28, 28]

边界平滑（Boundary Smoothing）：每个值替换为最近的箱边界（最小值或最大值）　箱1→[4, 4, 15]（8离4更近），箱2→[21, 21, 24]，箱3→[25, 25, 34]（28离25更近）

缺失值填充示例：若某学生"数学成绩"缺失，全班数学均值=82分→用82填充；若已知该生为"优等生"类别，优等生数学均值=91分→用91填充（同类均值更精确）

4.3 异常值检测与处理

异常值的三种类型（Outlier Types）

点异常
Point Outlier
单个数据点与其余数据显著不同
例：月收入数据中出现1亿元

上下文异常
Contextual Outlier
在特定上下文中异常，全局看正常
例：重庆气温35℃在1月异常

集体异常
Collective Outlier
一组数据整体异常，单个点正常
例：网络流量突然持续激增

异常值检测方法（Outlier Detection Methods）

统计方法 Statistical
3σ原则：超出μ±3σ视为异常（正态分布下仅0.27%概率）
Z-score：$z = \frac{x-\mu}{\sigma}$，|z|>3为异常
IQR法：超出[Q1-1.5IQR, Q3+1.5IQR]为异常

距离/密度方法
KNN距离：到第k个最近邻的距离过大为异常
LOF（Local Outlier Factor）：局部密度低于邻域为异常，LOF>1
DBSCAN：低密度区域的点标记为噪声

聚类/分类方法 Clustering & Classification
聚类方法：远离所有簇中心的点为异常；小簇（大小低于阈值）整体视为异常簇
一类分类（One-Class SVM）：仅用正常样本训练模型，偏离正常区域的为异常
孤立森林（Isolation Forest）：通过随机划分树，路径越短越容易被孤立→越可能是异常

异常值的处理策略（Handling Strategies）

删除 Remove
确认是错误数据时直接删除
适用于：录入错误、传感器故障
注意：不要误删真实异常

修正 Correct
用均值/中位数/预测值替换
适用于：可推断正确值的异常
方法：同缺失值填充策略

保留异常值的场景（异常值≠错误，可能是有价值的信号）

欺诈检测：信用卡异常消费→可能是盗刷，异常值是检测目标
网络安全：异常流量→可能是DDoS攻击，异常值是入侵信号
医疗诊断：异常生理指标→可能是疾病征兆，异常值是诊断依据
工业质检：异常传感器读数→可能是设备故障，异常值是预警信息

计算示例：IQR法检测异常值

某公司10名员工月薪（千元）：8, 9, 10, 11, 12, 13, 14, 15, 16, 100
排序后：Q1=第25%位置=10，Q2=中位数=(12+13)/2=12.5，Q3=第75%位置=15
IQR = Q3 - Q1 = 15 - 10 = **5**
下界 = Q1 - 1.5×IQR = 10 - 7.5 = **2.5**
上界 = Q3 + 1.5×IQR = 15 + 7.5 = **22.5**
结论：月薪100千元 > 上界22.5，判定为**异常值**（可能是高管或录入错误，需人工核实）



大数据预处理与质控

CONTENTS

01 数据对象与属性类型
Data Objects and Attribute Types

02 数据的基本统计描述
Basic Statistical Description of Data

03 度量数据的相似性和相异性
Measuring Data Similarity and Dissimilarity

04 数据清洗
Data Cleaning

05 数据归约
Data Reduction

06 数据变换与离散化
Data Transformation and Discretization

07 数据降维
Dimensionality Reduction

5.1 数据集成概念与问题

数据集成（Data Integration）：将多个数据源（如数据库、数据仓库、API、文件）中的数据合并到一个统一的数据存储中，消除数据孤岛，为后续分析和建模提供完整、一致的数据基础。

核心目标：统一数据视图、消除冗余与冲突、提升数据质量、支持跨源分析。典型架构：ETL（Extract-Transform-Load，抽取-转换-加载）、ELT、数据联邦（Data Federation）、数据湖（Data Lake）。

数据集成中的四大关键问题

实体识别问题
Entity Identification
同一现实实体在不同源中名称/编码不同
例：A表"customer_id"，B表"cust_no"
需通过元数据、主键、业务规则匹配

冗余问题
Redundancy
属性或元组在集成后重复出现
属性冗余：A表"年收入"，B表"年薪"
元组冗余：同一客户在两表各有一条记录

数据值冲突
Data Value Conflict
同一实体的同一属性在不同源中值不同
例：A表年龄"25"，B表年龄"26"
原因：单位不同、精度不同、更新时间不同

元组重复
Duplicate Tuples
集成后出现完全相同或近似相同的记录
例：同一订单在两系统各录入一次
需去重（Deduplication）和记录链接（Record Linkage）

示例：客户数据集成中的冲突与解决

CRM系统：客户ID=1001，姓名"张三"，年龄25，年收入12万
ERP系统：客户编号=C1001，客户名"张 三"，年龄26，年薪120000元
问题：实体识别（ID不同）、值冲突（年龄25vs26）、格式差异（"张三"vs"张 三"，12万vs120000元）
解决：通过手机号匹配实体→取最新年龄→统一姓名格式和金额单位→去重合并为一条记录

数据集成的三种典型架构

ETL（Extract-Transform-Load，抽取-转换-加载）
从数据源抽取→在中间层转换（清洗、格式化、聚合）→加载到目标数据仓库。是传统数据仓库的标准架构，适合批量处理、结构化数据。工具：Apache NiFi、Talend、Informatica、DataX。

数据联邦（Data Federation）
不移动数据，通过虚拟层将多个异构数据源映射为统一视图，查询时实时从各源获取数据。适合数据量大、不适合复制的场景，减少数据冗余。工具：Denodo、Teiid、Flink CDC。

数据湖（Data Lake）
以原始格式存储结构化、半结构化、非结构化数据的集中式存储库，支持后续按需处理和分析。适合大数据场景，存储成本低但治理要求高。技术：Hadoop HDFS、Amazon S3、Delta Lake、Iceberg。

重庆大学 CHONGQING UNIVERSITY

5.2 冗余分析与数据归约概述

冗余分析方法（Redundancy Analysis）

标称属性：卡方检验

Chi-Square Test（χ²检验）

$$\chi^2 = \sum_{i=1}^{c}\sum_{j=1}^{r}\frac{(o_{ij}-e_{ij})^2}{e_{ij}}$$

o_ij=观测频数，e_ij=期望频数

χ²越大→两属性越相关（冗余）

自由度df=(c-1)(r-1)，c列数r行数

数值属性：相关系数

Pearson Correlation Coefficient

$$r_{A,B} = \frac{\sum_{i=1}^{n}(a_i-\bar{A})(b_i-\bar{B})}{n\sigma_A\sigma_B}$$

a_i/b_i=属性A/B的第i个值，Ā/B̄=均值

σ_A/σ_B=标准差，n=样本数

|r|越接近1→越相关（冗余），r=0→不相关

协方差（Covariance）与冗余判定

协方差（Covariance）：$Cov(A,B) = \frac{1}{n}\sum_{i=1}^{n}(a_i-\bar{A})(b_i-\bar{B})$，Cov>0正相关，Cov<0负相关，Cov=0不相关

冗余判定：若两属性相关系数|r|>0.8（或卡方检验p值<0.05），认为存在冗余，可删除其中一个属性以降低维度

注意：相关≠因果（Correlation does not imply causation），高相关可能是第三方因素导致，需结合业务逻辑判断

数据归约（Data Reduction）概述

定义：在保持原始数据信息完整性的前提下，通过降低数据维度或压缩数据量，获得更小的数据表示，从而提升分析效率、降低存储和计算成本。

核心目标：降维（减少属性数）、压缩（减少元组数或值范围）、加速（提升算法运行效率）、降噪（去除无关和冗余信息）。

数据归约的四大策略

数据立方体聚集

Data Cube Aggregation

对多维数据进行上卷（Roll-up）聚合，从细粒度到粗粒度

例：日销售→月销售→年销售

属性子集选择

Attribute Subset Selection

从原始属性中选择最有区分力的子集，删除冗余/无关属性

方法：逐步选择、决策树、L1正则化

维度归约

Dimensionality Reduction

通过线性/非线性变换将高维数据映射到低维空间

方法：PCA、LDA、t-SNE、UMAP、自编码器

数值归约

Numerosity Reduction

用参数模型（回归）或非参数模型（直方图/聚类）表示数据

方法：线性回归、对数线性模型、抽样、聚类

计算示例：身高与体重的相关系数（5名学生：身高[160,165,170,175,180]cm，体重[50,55,60,65,70]kg）

身高均值Ā=170，体重均值B̄=60；身高标准差σ_A≈7.07，体重标准差σ_B≈7.07；n=5

协方差Cov = [(160-170)(50-60)+(165-170)(55-60)+(170-170)(60-60)+(175-170)(65-60)+(180-170)(70-60)]/5 = (100+25+0+25+100)/5 = 50

相关系数r = Cov/(σ_A×σ_B) = 50/(7.07×7.07) = 50/50 = 1.0（完全正相关，身高和体重存在线性冗余，可只保留一个属性）



大数据预处理与质控

CONTENTS

01 数据对象与属性类型
Data Objects and Attribute Types

02 数据的基本统计描述
Basic Statistical Description of Data

03 度量数据的相似性和相异性
Measuring Data Similarity and Dissimilarity

04 数据清洗
Data Cleaning

05 数据归约
Data Reduction

06 数据变换与离散化
Data Transformation and Discretization

07 数据降维
Dimensionality Reduction

6.1 数据变换策略（Data Transformation Strategies）

数据变换（Data Transformation）：将数据从一种表示形式转换为另一种更适合挖掘或分析的表示形式，使数据更规范、更紧凑、更有信息量，是连接原始数据与算法模型的关键桥梁。

核心目标：去除噪声、统一尺度、提升信息密度、适配算法输入要求。以下是五种经典变换策略。

策略一：平滑 Smoothing

定义：去除数据中的噪声，使数据趋势更平滑

方法：

- **分箱**（Binning）：按箱内均值/中位数/边界平滑
- **回归**（Regression）：用回归函数拟合数据
- **聚类**（Clustering）：相似值归为簇，远离簇中心为噪声

应用：传感器数据去噪、时间序列平滑

策略二：聚集 Aggregation

定义：对数据进行汇总或聚合，从细粒度到粗粒度

方法：

- **数据立方体**（Data Cube）：多维OLAP聚合
- **上卷**（Roll-up）：沿概念层次向上聚合
- **分组聚合**：GROUP BY + SUM/AVG/COUNT

应用：日销售→月销售→年销售，降低数据量

策略三：数据泛化 Generalization

定义：将低层/原始概念映射到高层概念

方法：

- **概念层次**（Concept Hierarchy）：预定义的抽象层次
- **属性泛化**：具体值→类别标签
- **阈值控制**：每个属性值出现次数阈值

应用：街道→区→市→省，具体年龄→青年/中年/老年

策略四：规范化 Normalization（详见6.2）

定义：将属性值按比例缩放到特定范围，消除量纲影响，使不同属性具有可比性

三种常用方法：

- **最小-最大规范化**（Min-Max Normalization）：线性变换到[0,1]或[new_min, new_max]
- **Z-score规范化**（Zero-Mean / Standard Score）：均值为0，标准差为1，$v' = \frac{v-\mu}{\sigma}$
- **小数定标规范化**（Decimal Scaling）：移动小数点位置，$v' = \frac{v}{10^j}$，j为使max(|v'|)<1的最小整数

应用：K-Means、KNN、神经网络等对尺度敏感的算法输入前必须规范化

策略五：属性构造 Attribute Construction

定义：从现有属性中构造新的属性，丰富特征空间，提升模型表达能力

方法：

- **算术组合**：由现有属性的加减乘除构造新属性
- **比率构造**：构造比率型属性（如人均收入=总收入/人口数）
- **交叉特征**：多个标称属性的组合（如"性别×职业"）
- **时间特征**：从时间戳提取年/月/日/星期/节假日等

应用：特征工程（Feature Engineering），是提升机器学习模型性能的关键手段

示例：学生成绩数据的变换应用

原始数据：学生[姓名, 数学(0-150分), 英语(0-150分), 出生日期]　数学均值=110，标准差=15；英语均值=105，标准差=20

平滑：用分箱去除个别异常成绩　**聚集**：按班级聚合平均分　**泛化**：出生日期→年龄段（青年/中年）　**规范化**：数学Z-score=(分数-110)/15，英语Z-score=(分数-105)/20，消除两科满分相同但分布不同的影响　**属性构造**：构造"总分=数学+英语"、"文理科倾向=英语-数学"、"入学年份=出生日期年份"

重庆大学 CHONGQING UNIVERSITY

6.2 规范化与离散化（Normalization and Discretization）

三种规范化方法对比

方法	公式	特点与适用
最小-最大 Min-Max	$v' = \frac{v - min_A}{max_A - min_A}(new_{max} - new_{min}) + new_{min}$	线性变换到[new_min, new_max]，保留原始分布关系；对异常值敏感，适合有明确上下界的数据
Z-score 零均值	$v' = \frac{v - \mu_A}{\sigma_A}$	均值μ=0，标准差σ=1；对异常值比Min-Max稳健；适合近似正态分布、无明确上下界的数据，最常用
小数定标 Decimal	$v' = \frac{v}{10^j}$	移动小数点j位，j为使max(|v'|)<1的最小整数；保留原始数据分布，适合数值范围较大的数据

规范化计算示例（收入数据，单位：元）

原始收入：[5000, 10000, 15000, 20000, 50000]元

min=5000，max=50000，均值μ=20000，标准差σ≈16733

最小-最大规范化（到[0,1]）：

5000→0，10000→0.111，15000→0.222，20000→0.333，50000→1.0

Z-score规范化（v'=(v-20000)/16733）：

5000→-0.896，10000→-0.598，15000→-0.299，20000→0，50000→1.793

小数定标规范化：max=50000，j=5（10^5=100000），所有值除以100000：

5000→0.05，10000→0.1，15000→0.15，20000→0.2，50000→0.5

离散化（Discretization）：将连续数值属性转换为离散区间（标称属性）

无监督离散化（不使用类别标签）

分箱 Binning：

- **等宽分箱**（Equal-Width）：每箱区间宽度相同，易受异常值影响
- **等频分箱**（Equal-Frequency / Equal-Depth）：每箱数据个数相同，对异常值稳健

直方图分析 Histogram：

根据直方图分布自然划分区间边界，如V-最优直方图、最大差异直方图

聚类分析 Clustering：

用K-Means等算法将值聚类，每个簇对应一个离散区间

有监督离散化（使用类别标签）

决策树分析 Decision Tree：

以该连续属性为分裂特征构建决策树，以树的分裂点作为离散化边界

常用算法：ID3、C4.5、CART（基尼系数/信息增益）

基于信息增益的离散化：

选择使信息增益最大的划分点，递归划分直到满足停止条件

基于卡方检验的离散化：

ChiMerge算法：自底向上合并相邻区间，直到卡方检验不显著

有监督方法通常比无监督方法产生更有区分力的区间

离散化示例与应用

示例：年龄离散化

连续年龄[0-100]→离散区间：

- 等宽分箱（每箱20岁）：0-20, 21-40, 41-60, 61-80, 81-100
- 业务分箱：儿童(0-12), 少年(13-17), 青年(18-40), 中年(41-60), 老年(61+)

离散化的作用：

- 降低数据复杂度，提升算法效率
- 使连续属性可用于只接受标称属性的算法（如朴素贝叶斯）
- 增强模型鲁棒性，减少过拟合
- 便于数据理解和可视化



大数据预处理与质控

CONTENTS

01 数据对象与属性类型
Data Objects and Attribute Types

02 数据的基本统计描述
Basic Statistical Description of Data

03 度量数据的相似性和相异性
Measuring Data Similarity and Dissimilarity

04 数据清洗
Data Cleaning

05 数据归约
Data Reduction

06 数据变换与离散化
Data Transformation and Discretization

07 数据降维
Dimensionality Reduction

7.1 数据降维概念与维度灾难（Curse of Dimensionality）

数据降维（Dimensionality Reduction）：在尽可能保留原始数据关键信息的前提下，将高维数据（d维）映射到低维空间（k维，k<<d），从而降低计算复杂度、去除冗余噪声、提升模型性能、便于可视化。

核心目标：信息损失最小化 + 维度最大化降低。评价指标：重构误差（Reconstruction Error）、可解释方差比（Explained Variance Ratio）。

维度灾难（Curse of Dimensionality）：由Richard Bellman于1961年提出，指随着数据维度d的增加，在固定样本量下数据空间的体积指数级增长，导致数据变得极度稀疏，许多数据分析和机器学习算法的性能急剧下降的现象。

本质：高维空间中，所有点之间的距离趋于相等，最近邻和最远邻的区分度消失，距离度量失效。

维度灾难的四大表现

数据稀疏性
Data Sparsity
d维单位超立方体体积=1，n个样本的平均间距=(1/n)^(1/d)
d增大→间距趋近于0→样本几乎不覆盖空间
例：1000个样本，d=2时覆盖良好，d=100时极度稀疏

距离度量失效
Distance Concentration
高维中最近邻与最远邻距离比趋近于1
即 lim(d→∞) [(d_max - d_min) / d_min] → 0
所有点"等距"，KNN、聚类等基于距离的算法失效

计算复杂度爆炸
Computational Complexity
许多算法时间/空间复杂度随d指数增长
最近邻搜索：O(nd)，d=1000时计算量巨大
核方法、高维索引结构在高维下性能急剧下降

过拟合风险增加
Overfitting Risk
高维中模型参数多，容易拟合噪声而非真实模式
VC维随维度增加，模型复杂度上升
需要更多训练样本，样本复杂度与d正相关

降维方法的分类

按变换性质分类：
- **线性降维**（Linear）：假设数据位于低维线性子空间，用线性变换矩阵W映射。代表：PCA（主成分分析）、LDA（线性判别分析）、SVD（奇异值分解）、NMF（非负矩阵分解）
- **非线性降维**（Non-linear / Manifold Learning）：假设数据位于低维流形（Manifold）上，捕捉非线性结构。代表：t-SNE（t分布随机邻域嵌入）、UMAP（均匀流形近似与投影）、Isomap（等距映射）、LLE（局部线性嵌入）、自编码器（Autoencoder）

按是否使用标签分类：
- **无监督降维**：不使用类别标签，如PCA、t-SNE、UMAP
- **有监督降维**：使用类别标签最大化类间差异，如LDA

特征选择 vs 特征提取（两种降维路径）

特征选择（Feature Selection）：从原始d个属性中选择k个最有价值的属性子集，不改变属性的物理含义，保留可解释性。
- **过滤法**（Filter）：按统计指标独立评分，如卡方检验、信息增益、相关系数、互信息
- **包装法**（Wrapper）：用特定模型评估子集，如递归特征消除RFE、前向/后向搜索
- **嵌入法**（Embedded）：训练过程中自动选择，如L1正则化（Lasso）、决策树特征重要性

特征提取（Feature Extraction）：将原始d维属性通过函数映射到k维新属性，新属性是原始属性的组合，可能失去原始物理含义但保留信息。如PCA、LDA、t-SNE、自编码器。

选择策略：需要可解释性→特征选择；需要最大化信息保留→特征提取

7.2 线性降维：PCA与LDA

PCA 主成分分析（Principal Component Analysis）

核心思想：寻找一组正交的主成分方向，使数据在这些方向上的**方差最大**，从而用最少的维度保留最多的信息。第一主成分（PC1）方差最大，第二主成分（PC2）与PC1正交且方差次大，依此类推。
本质：对协方差矩阵进行特征值分解（Eigendecomposition），特征值=该方向方差，特征向量=主成分方向。

PCA算法步骤（五步）

Step 1 标准化：对每个属性做Z-score规范化，消除量纲影响（方差大的属性不应主导结果）
Step 2 计算协方差矩阵：$C = \frac{1}{n-1}X^T X$，C为d×d对称矩阵，C_ij=属性i与j的协方差，其中X为n×d标准化后的数据矩阵，n为样本数
Step 3 特征值分解：$Cv_i = \lambda_i v_i$，λ_i为特征值（方差），v_i为特征向量（主成分方向）
Step 4 选择Top-k主成分：按特征值降序排列，选择前k个特征向量组成投影矩阵W（d×k），k由累计方差贡献率决定（如保留95%方差）
Step 5 投影降维：$X_{new} = XW$，得到n×k的低维表示

LDA 线性判别分析（Linear Discriminant Analysis）

核心思想：有监督降维方法，利用类别标签，寻找使**类间散度最大、类内散度最小**的投影方向，即最大化Fisher判别准则（Fisher's Criterion）。
本质：与PCA追求方差最大不同，LDA追求类别可分性最大，投影后不同类别尽可能分开，同类尽可能紧凑。降维后维度最多为c-1（c为类别数）。

LDA核心公式与散度矩阵

类间散度矩阵（Between-class Scatter Matrix）：$S_b = \sum_{i=1}^{c} n_i (\mu_i - \mu)(\mu_i - \mu)^T$
其中 c=类别数，n_i=第i类样本数，μ_i=第i类均值向量，μ=全局均值向量，衡量不同类别均值之间的差异
类内散度矩阵（Within-class Scatter Matrix）：$S_w = \sum_{i=1}^{c} \sum_{x \in D_i} (x - \mu_i)(x - \mu_i)^T$
其中 D_i=第i类样本集合，衡量同类样本围绕其均值的离散程度
Fisher判别准则：$J(w) = \frac{w^T S_b w}{w^T S_w w}$，最大化J(w)即最大化类间散度/类内散度比
求解：广义特征值问题 $S_b w = \lambda S_w w$，取前k个最大特征值对应的特征向量组成投影矩阵

PCA vs LDA 对比与选择

对比维度	PCA 主成分分析	LDA 线性判别分析
监督类型	无监督（Unsupervised），不使用类别标签	有监督（Supervised），必须使用类别标签
优化目标	最大化投影后方差（保留最多信息）	最大化类间散度/类内散度比（类别可分性）
最大降维维度	k ≤ d（原始维度），可降到任意维度	k ≤ c-1（c为类别数），二分类最多降1维
适用场景	无标签数据、探索性分析、去噪、特征提取、可视化	有标签分类任务、特征提取用于分类、人脸识别

7.3 非线性降维：t-SNE、UMAP与应用案例

t-SNE（t分布随机邻域嵌入）

全称：t-distributed Stochastic Neighbor Embedding（t分布随机邻域嵌入），由Laurens van der Maaten和Geoffrey Hinton于2008年提出。
核心思想：在高维空间中用高斯分布计算点间相似概率，在低维空间中用t分布（自由度为1，即柯西分布）计算相似概率，通过KL散度（Kullback-Leibler Divergence）最小化两个分布的差异。
高维相似概率：$p(j|i) = \exp(-||x_i-x_j||^2 / 2\sigma_i^2) / \Sigma_{k\neq i} \exp(-||x_i-x_k||^2 / 2\sigma_i^2)$
低维相似概率：$q_{ij} = (1+||y_i-y_j||^2)^{-1} / \Sigma_{k\neq l} (1+||y_k-y_l||^2)^{-1}$
目标函数：$C = KL(P||Q) = \Sigma_i \Sigma_j p_{ij} \cdot \log(p_{ij} / q_{ij})$，用梯度下降最小化KL散度
关键参数：perplexity（困惑度，通常5-50，影响局部邻域大小）、learning_rate（学习率，通常100-1000）、n_iter（迭代次数，通常1000+）

UMAP（均匀流形近似与投影）

全称：Uniform Manifold Approximation and Projection（均匀流形近似与投影），由Leland McInnes和John Healy于2018年提出，基于拓扑数据分析和黎曼几何理论。
核心思想：假设高维数据位于低维黎曼流形（Riemannian Manifold）上，通过构造模糊单纯复形（Fuzzy Simplicial Complex）建模高维拓扑结构，然后在低维空间中寻找最相似的拓扑表示。
算法步骤：
1. 构造k近邻图（k-NN Graph），每个点连接k个最近邻
2. 计算每条边的隶属度（Membership Strength），用局部距离自适应确定
3. 在低维空间中初始化点，用交叉熵（Cross-Entropy）损失优化低维表示
4. 目标：$L = \Sigma_{(i,j)\in E} [\, \mu_{ij}\log(\mu_{ij}/\nu_{ij}) + (1-\mu_{ij})\log((1-\mu_{ij})/(1-\nu_{ij})) \,]$

关键参数：n_neighbors（近邻数，通常10-50，平衡局部/全局结构）、min_dist（最小距离，通常0.0-0.5，控制点间紧凑程度）、metric（距离度量，默认欧氏）

PCA vs t-SNE vs UMAP 三种降维方法对比

对比维度	PCA 线性降维	t-SNE 非线性降维	UMAP 非线性降维
计算速度	快（$O(nd^2)$，可增量计算）	慢（$O(n^2)$，大数据集需Barnes-Hut近似）	较快（$O(n \log n)$，适合大数据集）
全局结构	保留好（方差最大方向）	保留差（侧重局部邻域，簇间距离不可信）	保留较好（兼顾局部和全局结构）
可解释性	好（主成分可解释为原始属性组合）	差（低维坐标无明确物理含义）	较差（低维坐标无明确物理含义）
主要用途	去噪、特征提取、数据压缩、预处理	高维数据可视化（2D/3D散点图）	高维数据可视化、大数据集降维、预处理

应用案例：MNIST手写数字数据集降维可视化（60000张28×28=784维灰度图像，降维到2维）

PCA结果：10个数字类别有一定分离但大量重叠，前两个主成分仅解释约17%方差，全局结构可见但类别区分度不足
t-SNE结果：10个数字类别形成清晰的10个簇，同类数字聚集在一起，不同类明显分开，可视化效果极佳；但簇间距离不代表真实相似度，且计算慢（60000样本需数分钟）
UMAP结果：同样形成清晰的10个簇，且比t-SNE更好地保留了簇间的全局关系（如数字1和7较近、4和9较近），计算速度比t-SNE快5-10倍，是当前最流行的高维可视化工具
实践建议：预处理阶段用PCA去除噪声和冗余（如先降到50维），再用t-SNE/UMAP做最终2D可视化；t-SNE适合小数据集精细可视化，UMAP适合大数据集和需要保留全局结构的场景。



大数据预处理与质控

BIG DATA

Thank You!